

ABSCHLUSSVORTRAG

SENSORBASIERTER ORIENTIERUNGSSINN
MIT KÜNSTLICHEN NEURONALEN NETZEN
UND ENTSCHEIDUNGSBÄUMEN

Tom Dymel

16.06.2021

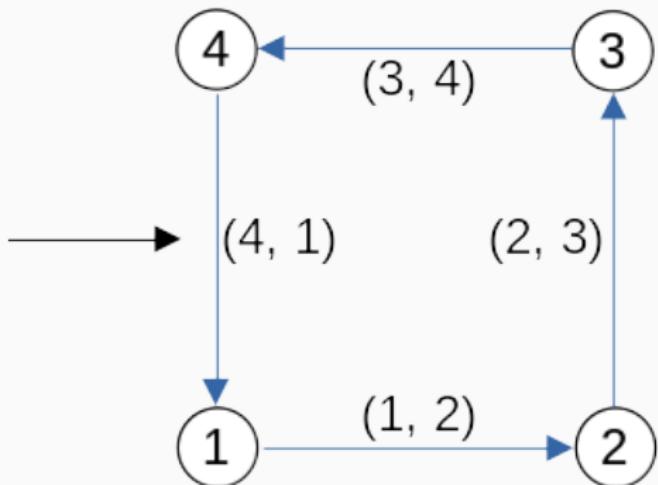
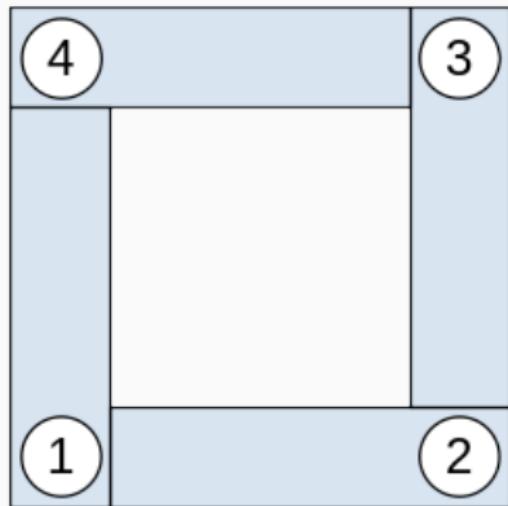
Masterarbeit

Technische Universität Hamburg

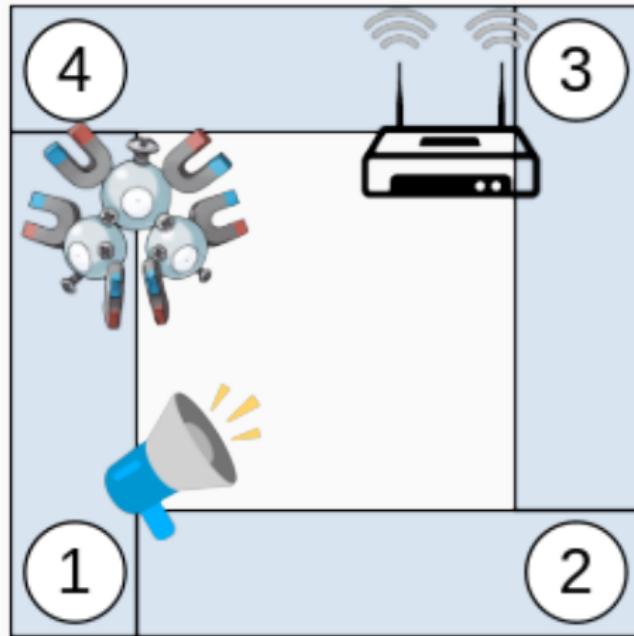
MOTIVATION UND ZIELE

- Motivation
 - Orientierungssinn von Tieren und Menschen
 - Indoor-Lokalisierung hohe Infrastrukturkosten
 - Mian untersuchte FFNN und simulierte Daten
 - Entscheidungsbäume potentiell effizienter
- Ziele
 - Diskrete Standortbestimmung
 - Nutzung von mehreren Sensoren
 - Ausgewählte Features bewerten

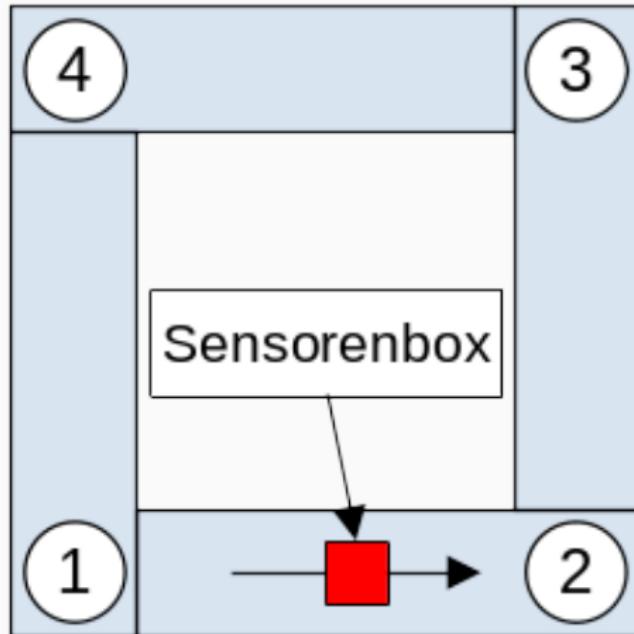
ANSATZ ZUR DISKREten STANDORTBESTIMMUNG I



ANSATZ ZUR DISKREten STANDORTBESTIMMUNG II

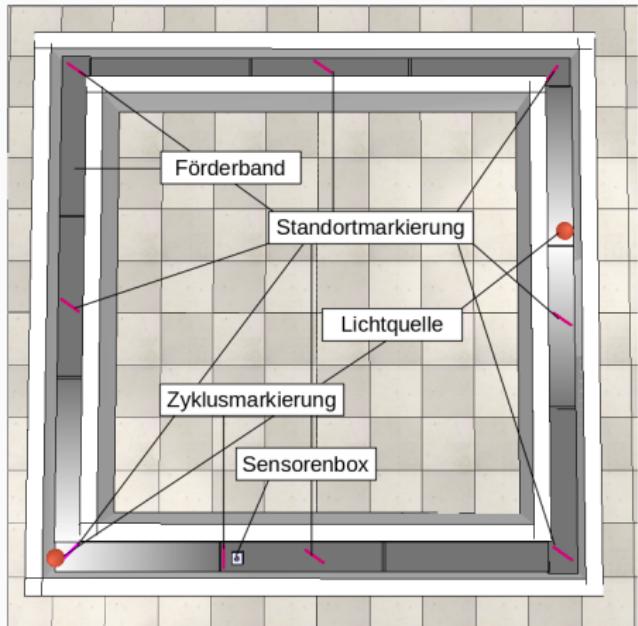


ANSATZ ZUR DISKREten STANDORTBESTIMMUNG III

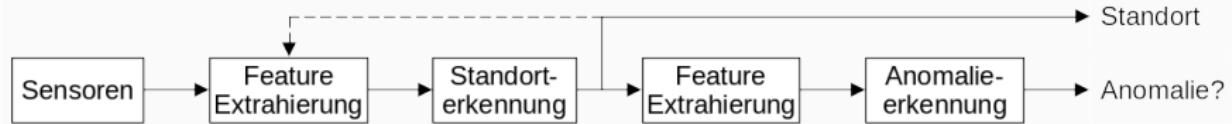


SENSOREN

- Accelerometer
- Gyroskop
- Licht
- Magnetfeld
- Temperatur
- Geräusche
- WLAN-Zugangspunkte



MODELL

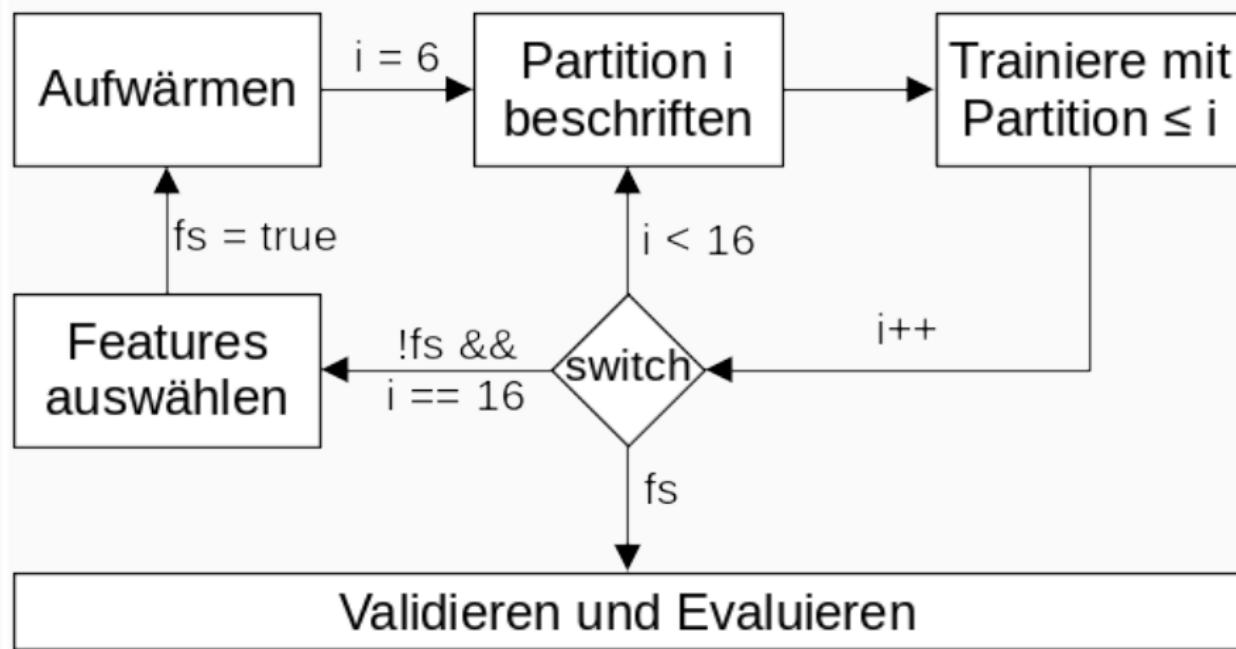


FEATURE-EXTRAHIERUNG

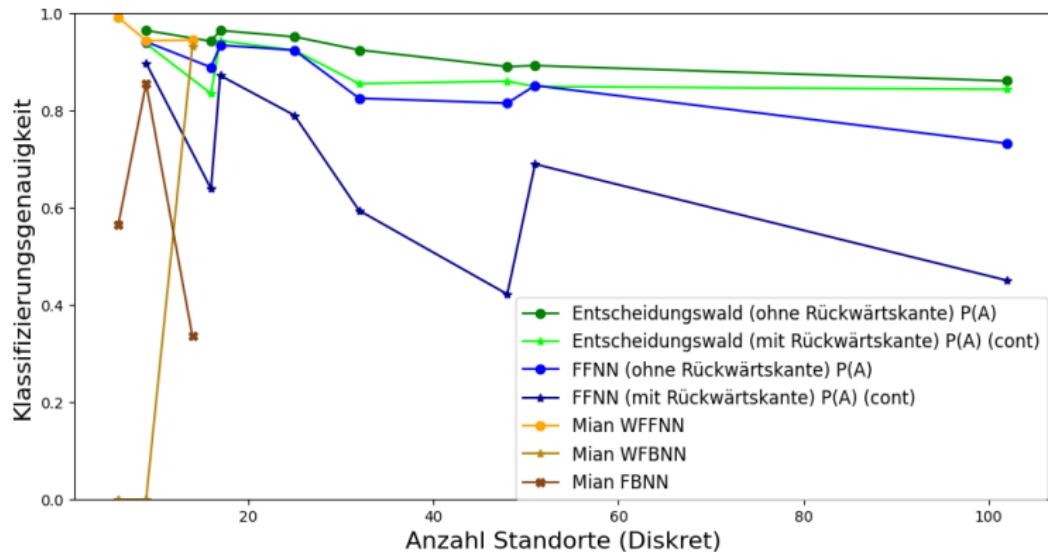
Sensordaten	σ	Min.	Max.	\emptyset	Wert
Accelerometer	X	X	X	X	X
Gyroskop	X	X	X	X	X
Ausrichtung zum Magnetfeld	X	X	X	X	X
Temperatur	X	X	X	X	X
Licht	X	X	X	X	X
Geräusch	X	X	X	X	X
WLAN-Zugangspunkte	-	-	-	-	X
Letzter Standort	-	-	-	-	X
Letzter unterschiedlicher Standort	-	-	-	-	X
Zeit	X	-	-	-	-

TRAINING DER ML-MODELLE

Partition i:	1 - 5	6 - 15	16 - 20
Phase:	Aufwärmen	Beschriften mit Modell	Validieren
Beschriftet in %:	0	$100 \cdot \min(1, 0.5 + (i - 6)^2 \div 128)$	-



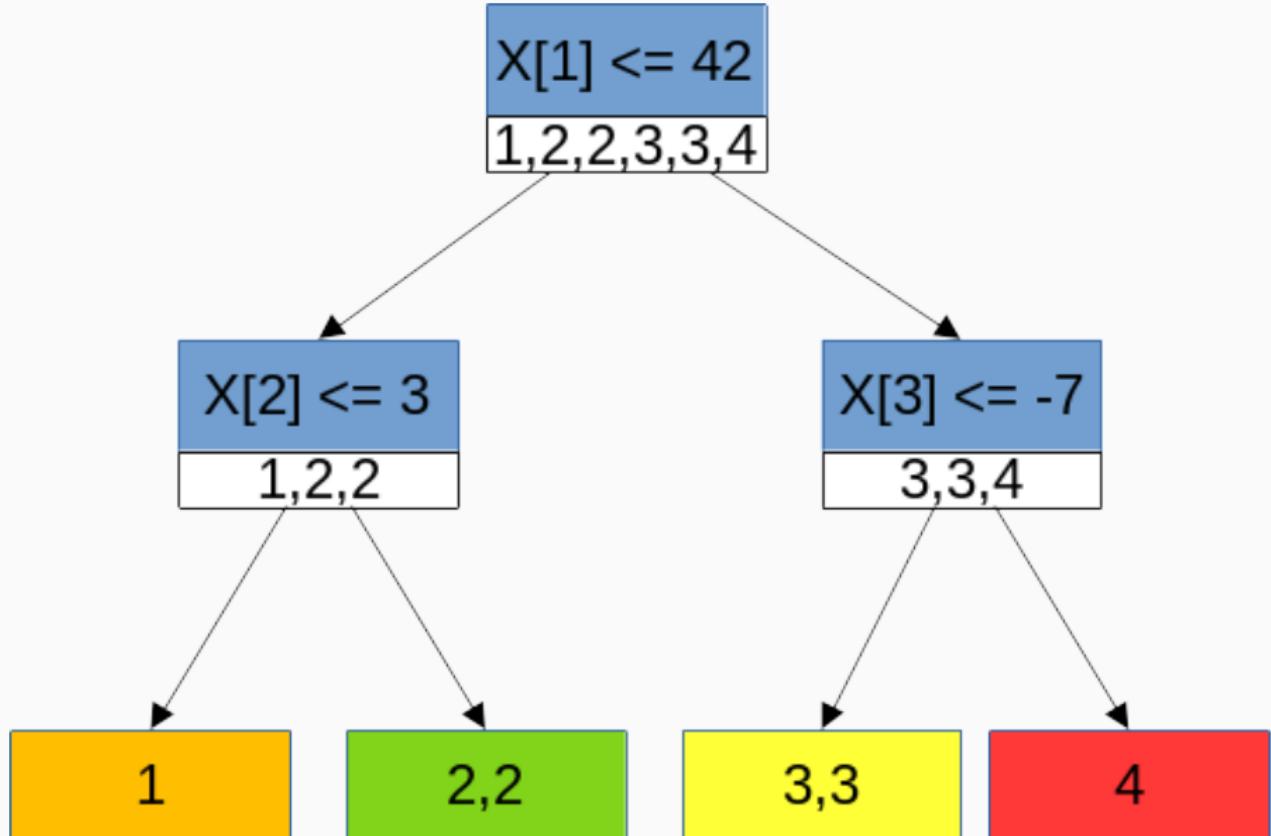
KLASSIFIZIERUNGSGENAUIGKEIT ÜBER STANDORTKOMPLEXITÄTEN



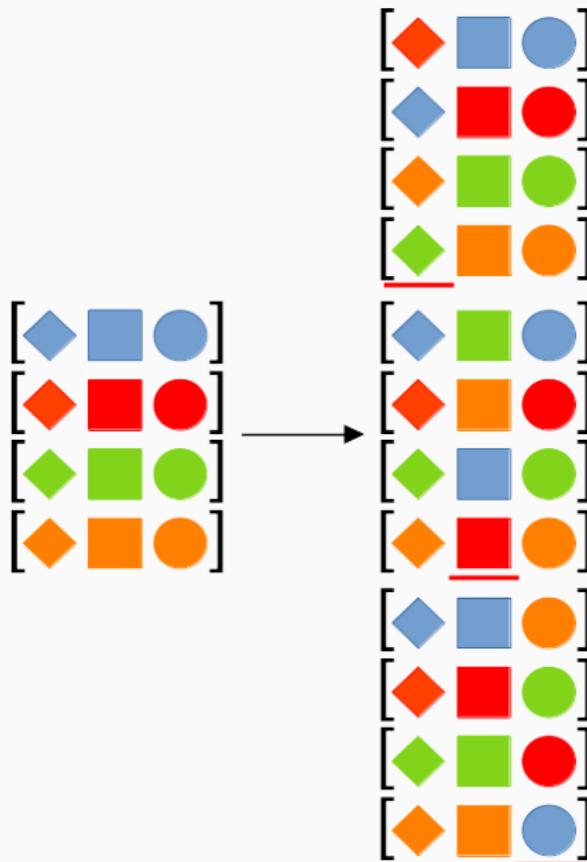
WICHTIGKEIT VON FEATURES I

1. Basierend auf Entscheidungsregeln und Trainingsdaten
2. Modifizieren der Testmenge und Fehler zur Originalmenge messen, z. B. Permutationswichtigkeit oder Nullung

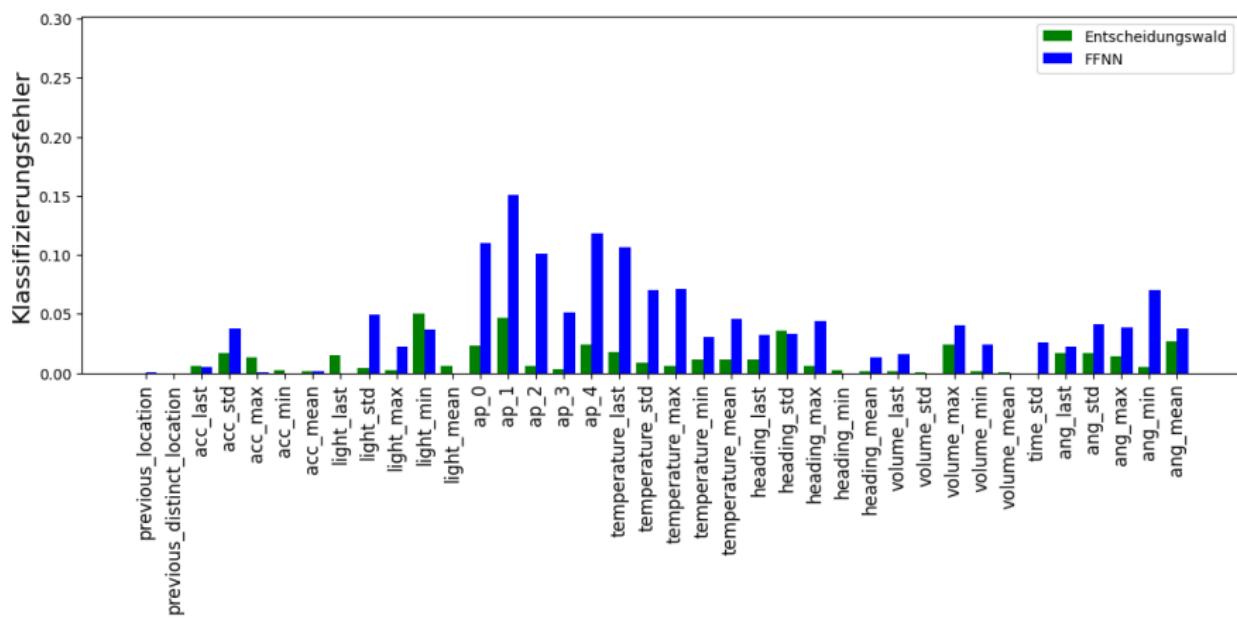
WICHTIGKEIT VON FEATURES II - feature_importances_



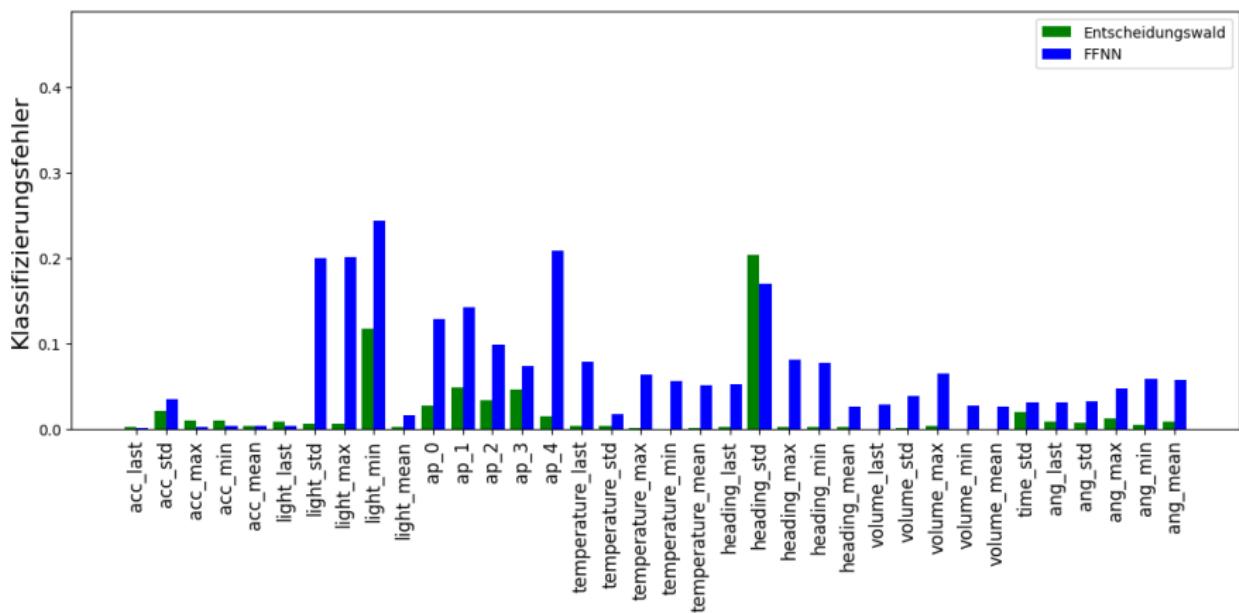
WICHTIGKEIT VON FEATURES III - PERMUTATIONSWICHTIGKEIT



PERMUTATIONSWICHTIGKEIT - ML-MODELLE MIT RÜCKWÄRTSKANTE



PERMUTATIONSWICHTIGKEIT - ML-MODELLE OHNE RÜCKWÄRTSKANTE



FEHLERTOLERANZ

Testmenge	Entscheidungswald	FFNN	Entscheidungswald	FNNN
	mit Rückwärtskante		ohne Rückwärtskante	
Licht	4.46%-Pkt.	4.65%-Pkt.	5.28%-Pkt.	6.93%-Pkt.
Geräusch	3.20%-Pkt.	5.00%-Pkt.	1.63%-Pkt.	5.11%-Pkt.
Temperatur	15.15%-Pkt.	6.60%-Pkt.	8.10%-Pkt.	13.50%-Pkt.
Ausrichtung zum Magnetfeld	3.32%-Pkt.	19.94%-Pkt.	2.51%-Pkt.	2.78%-Pkt.
WLAN-Zugangspunkte	2.60%-Pkt.	22.65%-Pkt.	3.74%-Pkt.	14.13%-Pkt.
Accelerometer	1.41%-Pkt.	9.52%-Pkt.	0.62%-Pkt.	1.33%-Pkt.
Gyroskop	8.52%-Pkt.	4.58%-Pkt.	0.91%-Pkt.	3.30%-Pkt.
Permutierte Testmenge	2.27%-Pkt.	-0.13%-Pkt.	0.47%-Pkt.	0.93%-Pkt.
Durchschnitt	5,8%-Pkt.	9,1%-Pkt.	2,91%-Pkt.	6,00%-Pkt.

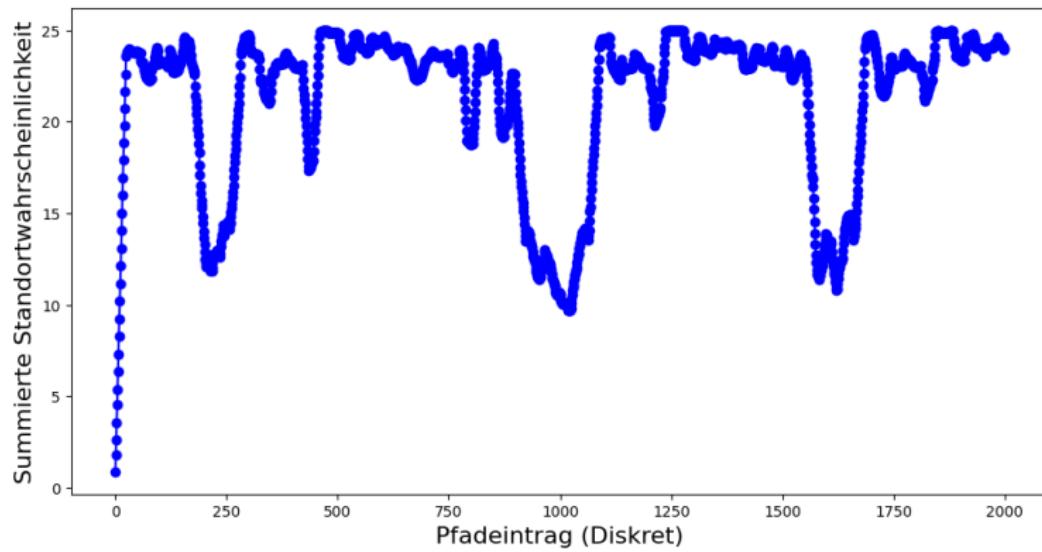
RESSOURCENNUTZUNG

- Entscheidungswälder benötigen deutlich mehr Programmspeicher
- Entscheidungswälder benötigen deutlich weniger RAM
- Entscheidungswälder sind deutlich effizienter
- Programmgröße skaliert mit Standortkomplexität
- FFNNs zwischen 54% und 97,6% kleiner als Mians FFNNs
- Entscheidungswälder bis zu 720% größer als Mians FFNNs
- Für beide ML-Modelle existieren Mikrocontroller mit genug RAM und Programmspeicher

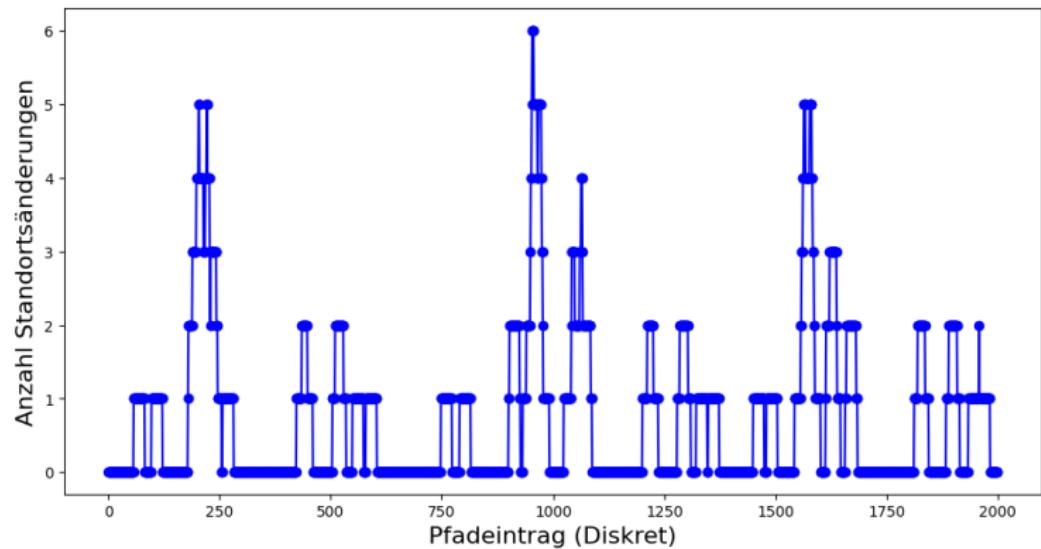
ANOMALIEERKENNUNG

- Klassifizierung, dass momentaner Standort nicht trainiert wurde
- Unendliche viele mögliche Anomalien
- Training basierend auf Sensordaten nicht sinnvoll
- Klassifizierung ungewöhnlichen Verhaltes des Standorterkennungsmodells

SUMMIERTE KLASIFIZIERUNGSGENAUIGKEIT IN DATENFENSTER



ANZAHL STANDORTÄNDERUNGEN IN DATENFENSTER



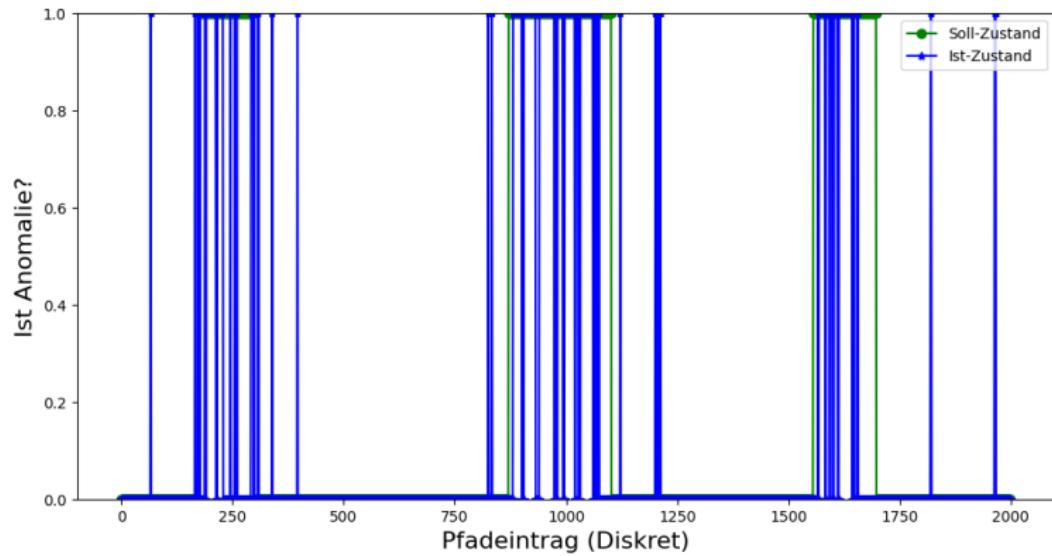
FEATURE-EXTRAHIERUNG

- Abweichung zu \emptyset Standortänderungen
- Abweichung zu \emptyset Standortwahrscheinlichkeit
- Standardabweichung Top 5 Standortwahrscheinlichkeiten
- Topologieverletzung

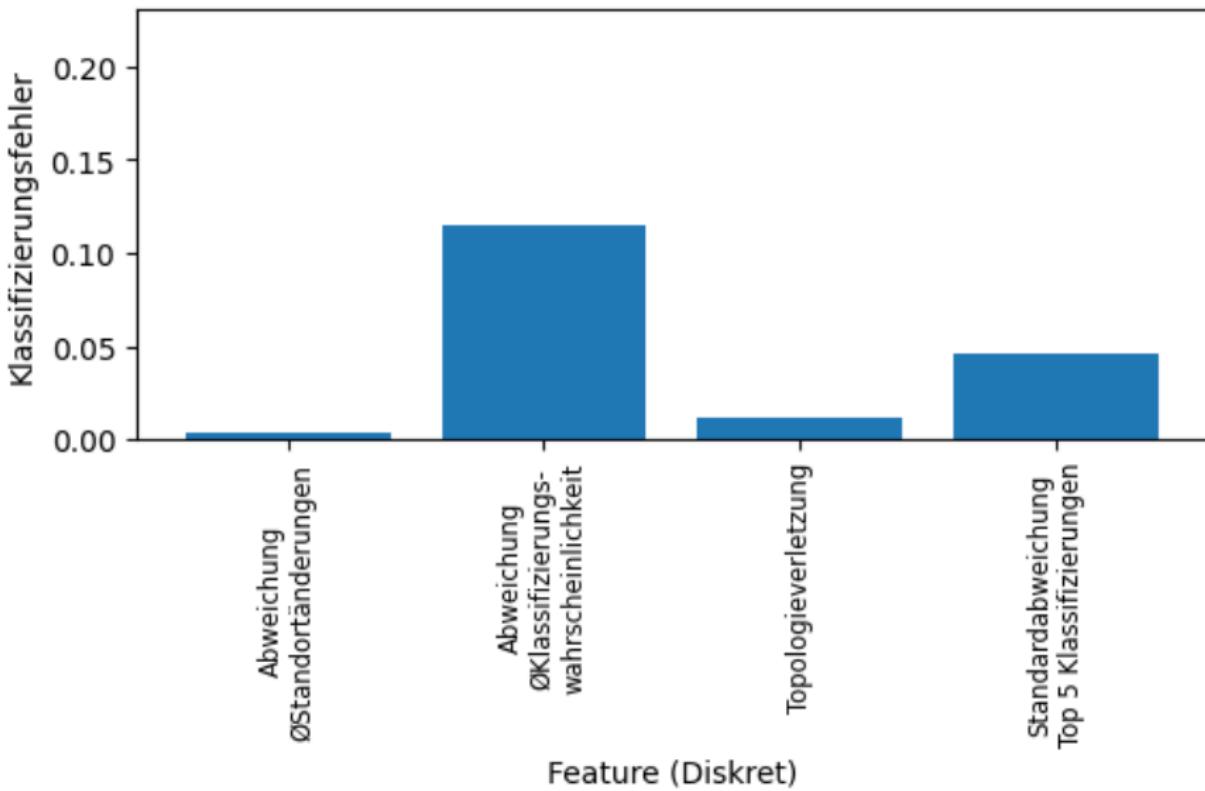
KLASSIFIZIERTUNGSERGEBNISSE

- FFNN konnte **nicht** erfolgreich trainiert werden
- Entscheidungswald kann 52,52% der Anomalien erkennen
- 2,95% Falsch-Positiv Rate
- Klassifizierungsgenauigkeit abhängig von Erkennungsrate von ML-Modell und Standortkomplexität
- Topologiemodell nur bei hoher Erkennungsrate gut

KLASSIFIZIERUNGSERGEBNISSE



PERMUTATIONSWICHTIGKEIT



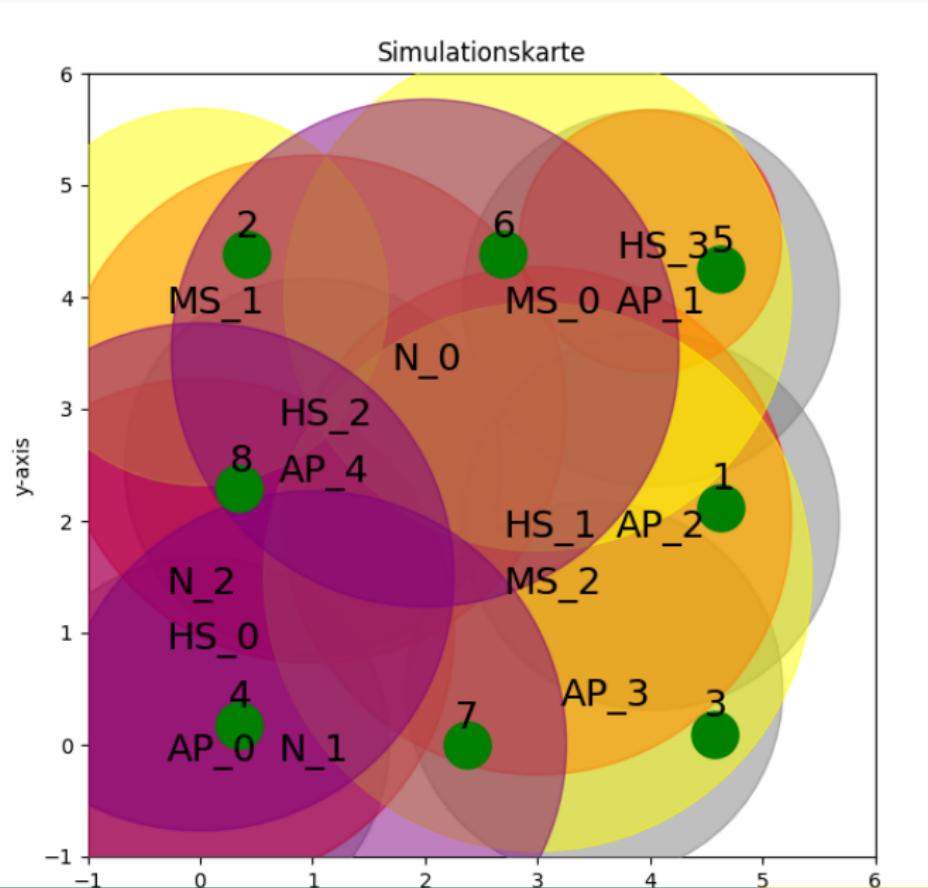
ERKENNTNISSE DIESER ARBEIT

- Entscheidungswälder skalieren besser als FFNN
- ML-Modelle ohne Rückwärtskante besser als mit
- 98,62% bei 9 Standorten, 87,35% bei 102 Standorten
- Anomalieerkennung: Bis zu 52,58% bei Fehlerrate von 2,95%
- Kleine Datenfenster sind ausreichend
- Geringere Ausführungszeit und klein genug
- Orte zu bestimmen ist besser als Orte und Pfade zu bestimmen
- Feature-Wichtigkeit abhängig vom Einsatzszenario
- Entscheidungswald benötigt weniger Trainingsdaten

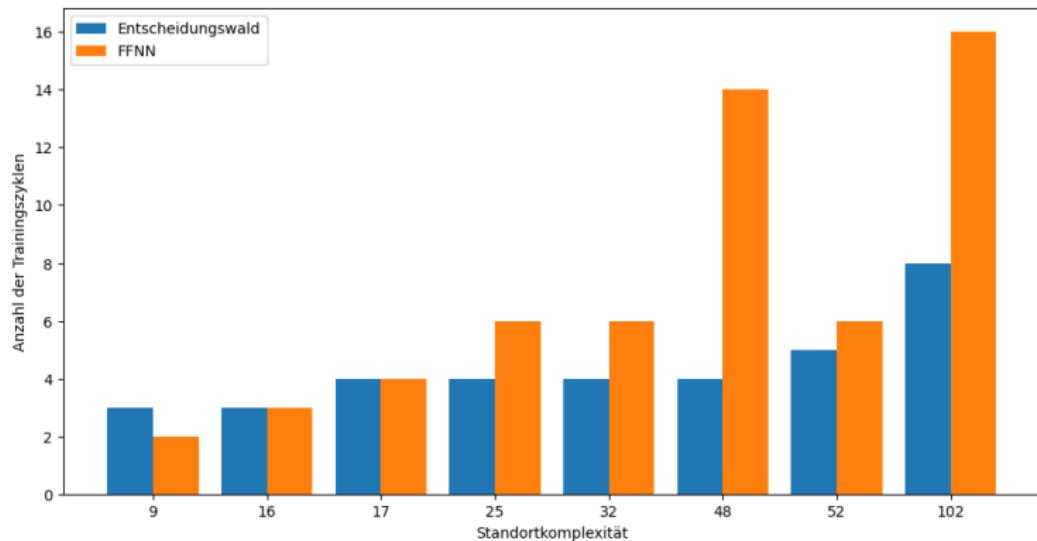
FRAGEN?

DEMO

SIMULATIONSKARTE VON „SIMPLE SQUARE“



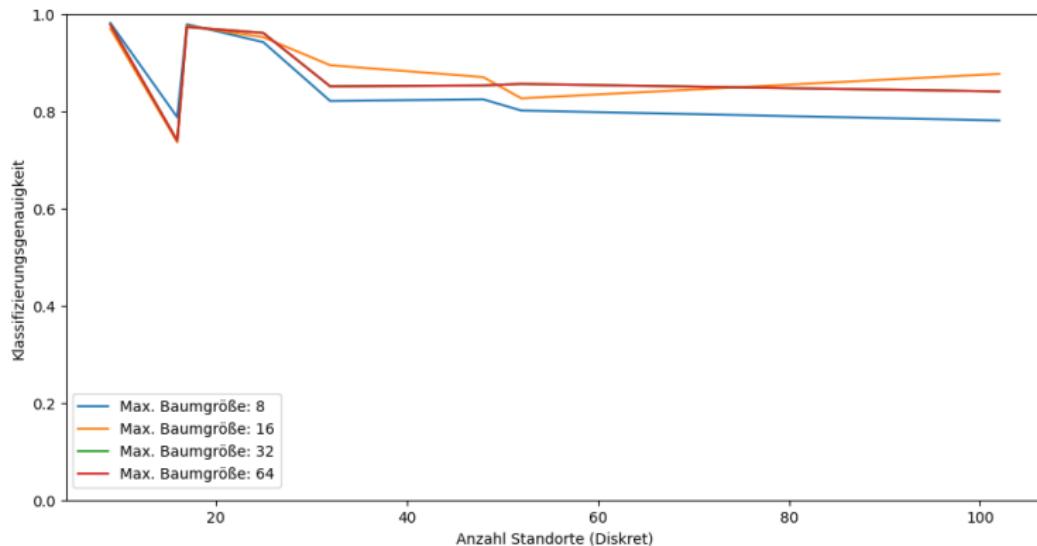
TRAININGSDATEN PRO ZYKLUS



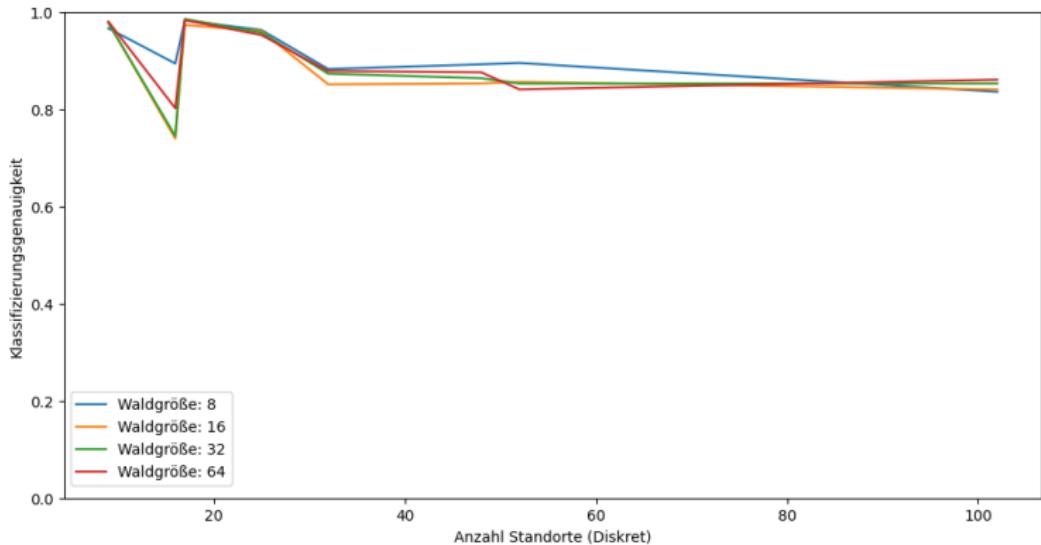
ANOMALIEERKENNUNG: KLASIFIZIERUNGSERGEBNISSE

Standorte	9	16	17	25	32	48	52	102
<i>P(A)</i>								
DT	82,59%	81,19%	87,14%	84,91%	79,06%	83,47%	81,93%	76,00%
FFNN	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%
Top. (DT)	84,77%	30,57%	83,51%	79,76%	28,63%	24,97%	80,55%	29,47%
Top. (KNN)	86,10%	52,17%	77,72%	79,30%	45,06%	41,92%	74,77%	43,55%
Anteil korrekt klassifiziert, indem Anomalie vorlag								
DT	34,86%	35,52%	52,58%	50,92%	32,21%	50,64%	23,21%	1,92%
FFNN	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%
Anteil korrekt klassifiziert, indem keine Anomalie vorlag								
DT	96,14%	94,41%	97,05%	95,83%	92,48%	93,13%	98,96%	97,18%
FFNN	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%

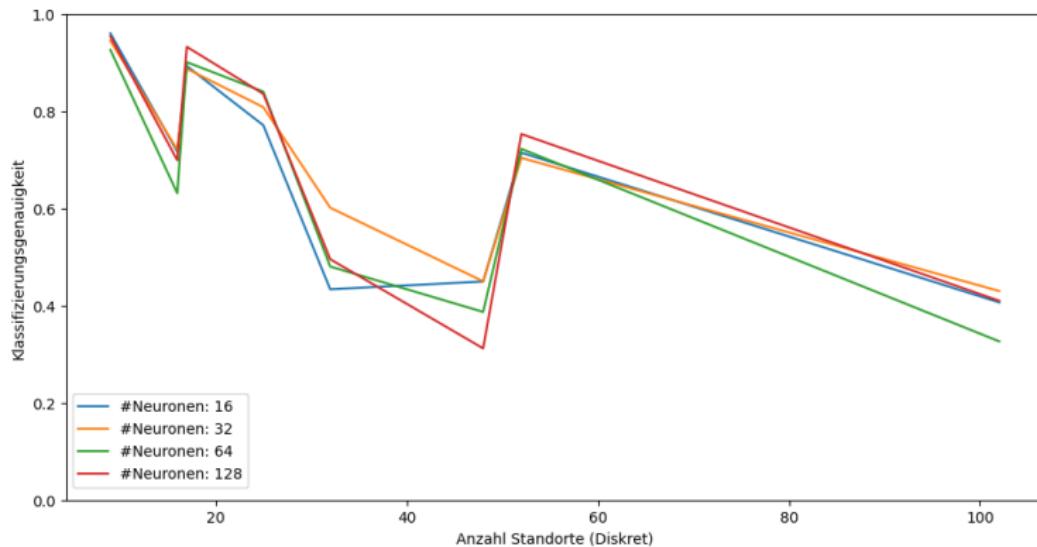
$P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON MAXIMALER BAUMHÖHE



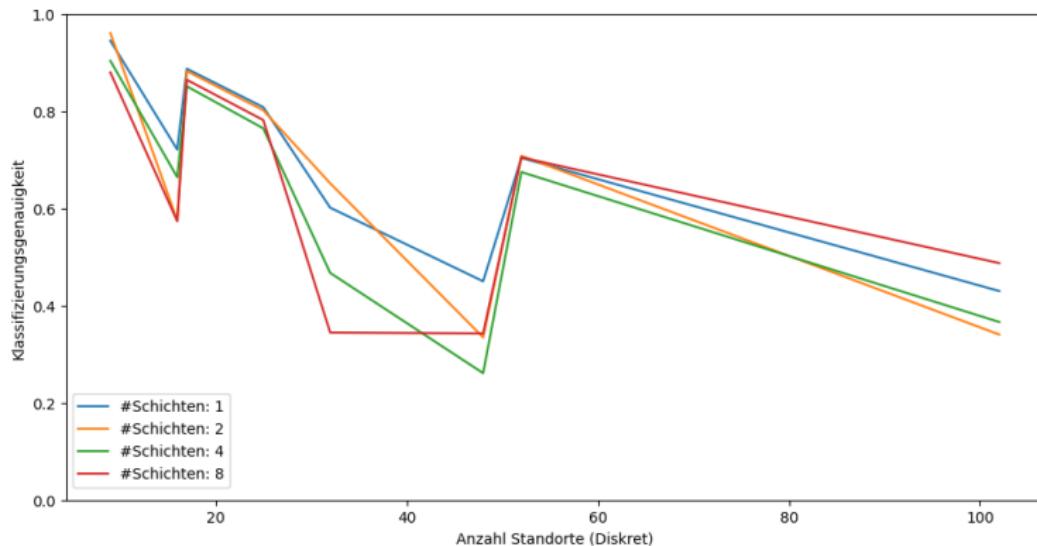
$P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON WALDGRÖÙE



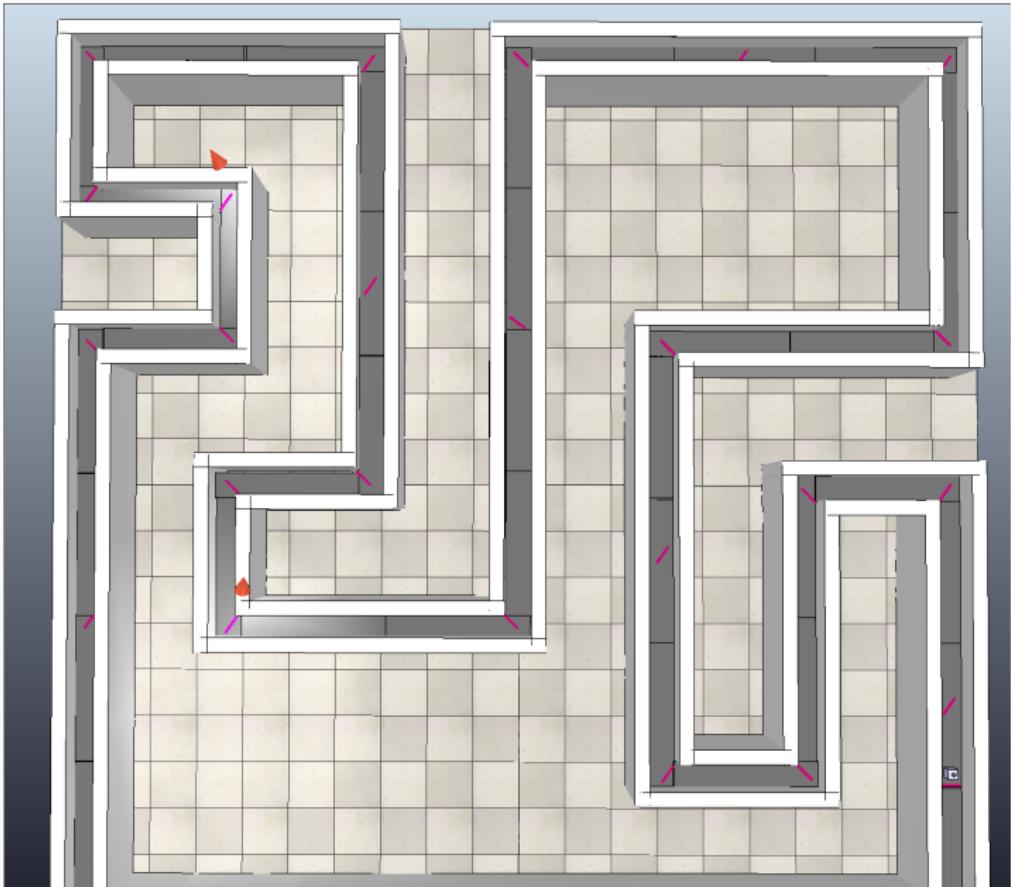
$P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON ANZAHL NEURONEN



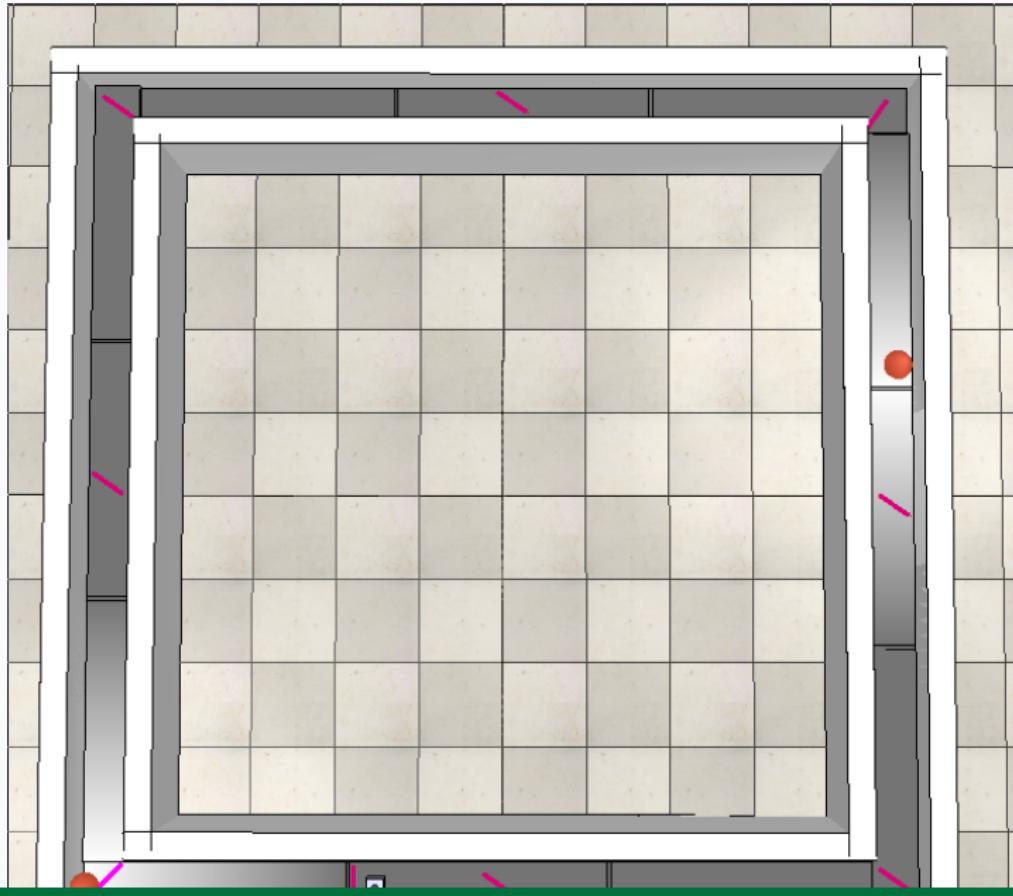
$P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON ANZAHL VERDECKTE SCHICHTEN



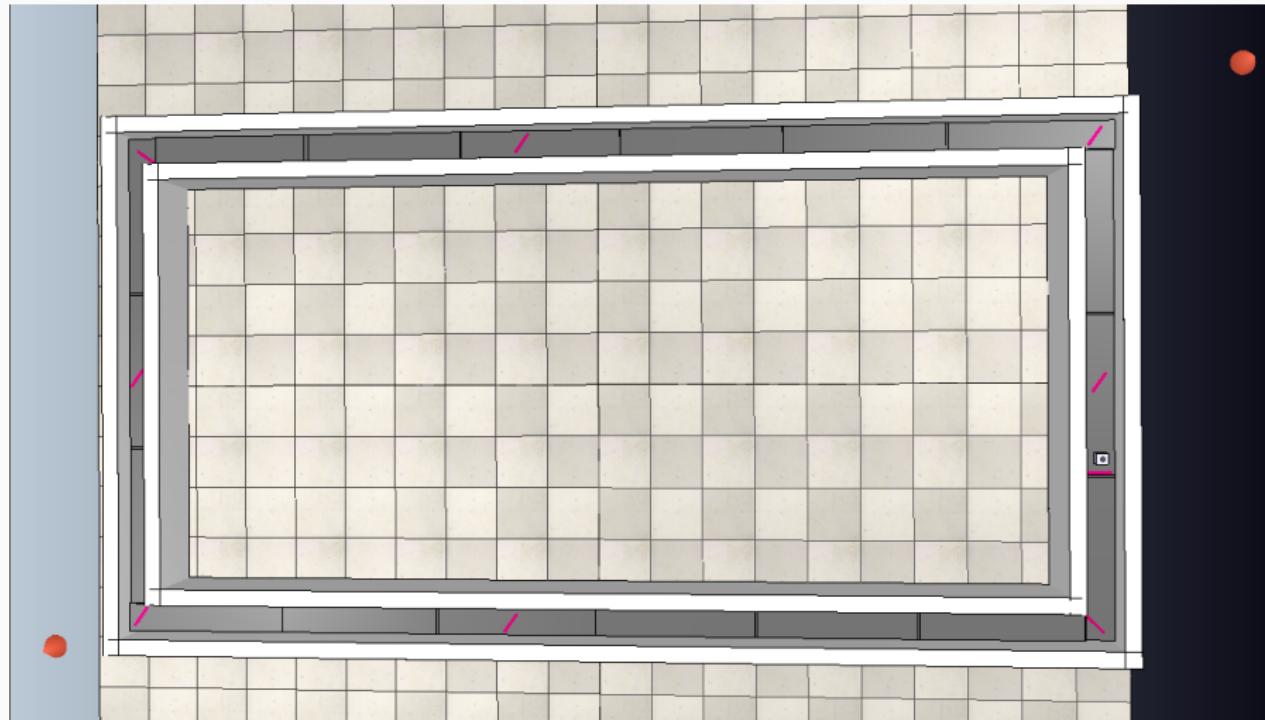
ROUTE: "MANY CORNERS"



ROUTE: "SIMPLE SQUARE"



ROUTE: "LONG RECTANGLE"



ROUTE: "RECTANGLE WITH RAMP"

