

# ABSCHLUSSVORTRAG

SENSORBASIERTER ORIENTIERUNGSSINN  
MIT KÜNSTLICHEN NEURONALEN NETZEN  
UND ENTSCHEIDUNGSBÄUMEN

---

Tom Dymel

16.06.2021

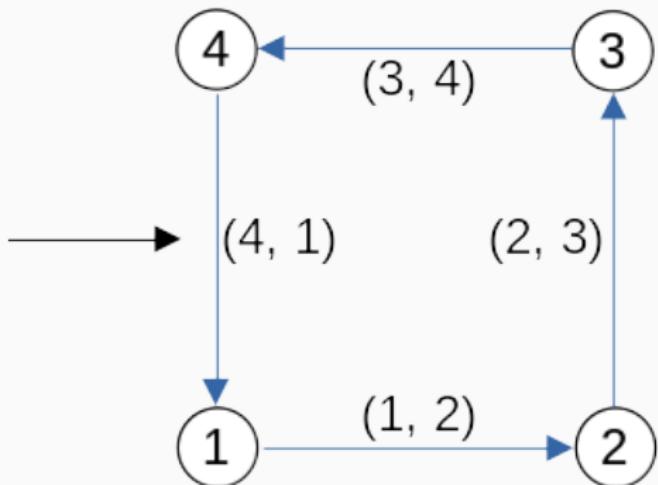
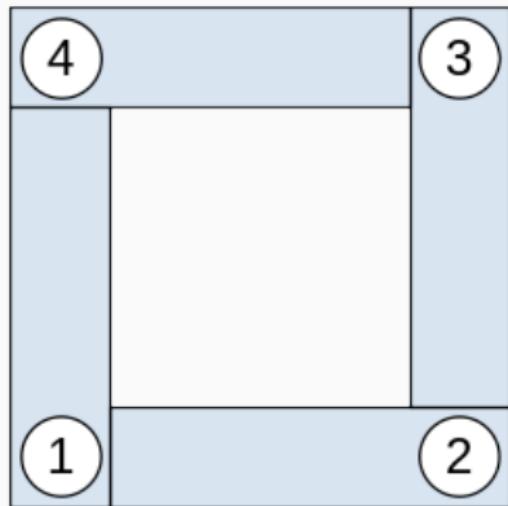
Masterarbeit

Technische Universität Hamburg

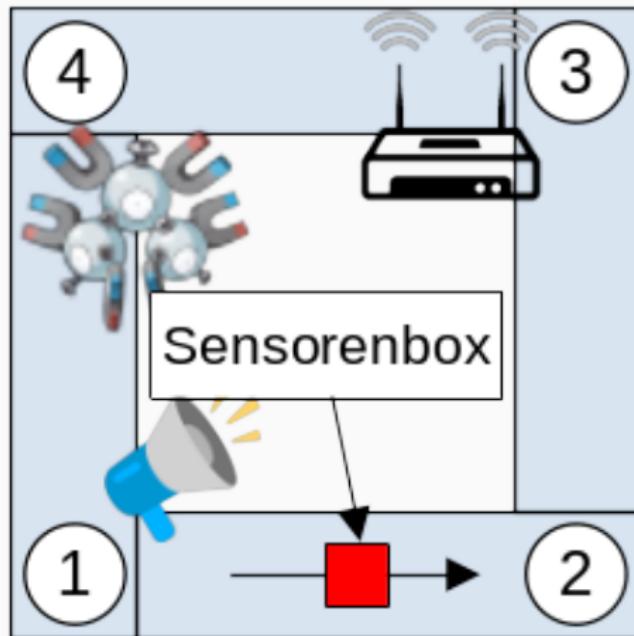
# MOTIVATION UND ZIELE

- Motivation
  - Orientierungssinn von Tieren und Menschen
  - Mian untersuchte FFNN und simulierte Daten
  - Entscheidungsbäume potentiell effizienter
- Ziele
  - Diskrete Standortbestimmung
  - Nutzung von mehreren Sensoren
  - Ausgewählte Features bewerten

# ANSATZ ZUR DISKREten STANDORTBESTIMMUNG I

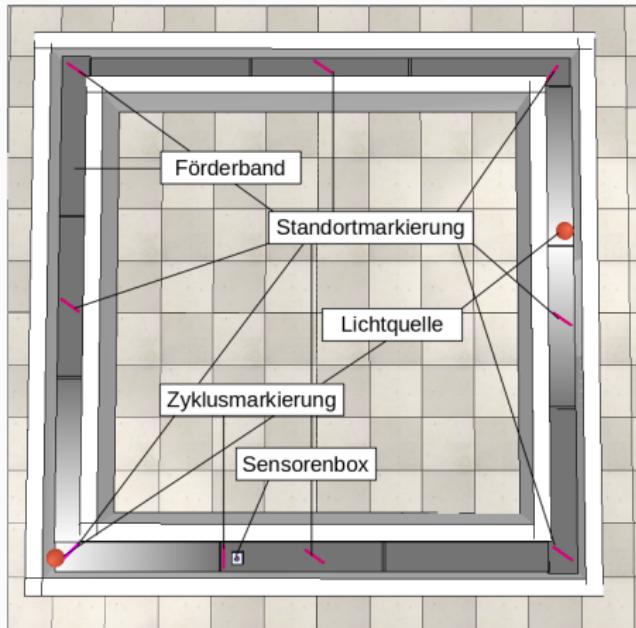


# ANSATZ ZUR DISKRETEN STANDORTBESTIMMUNG II

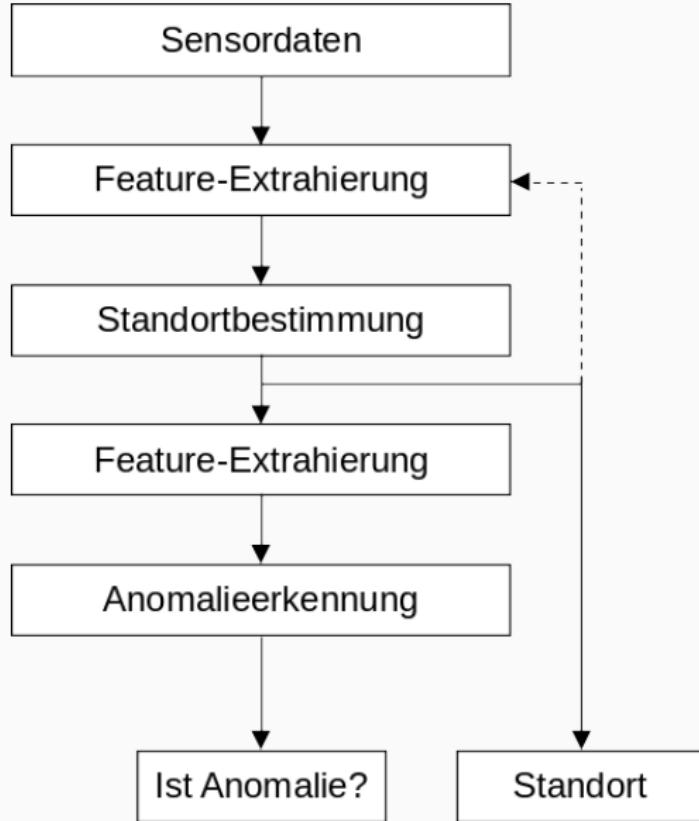


# SENSOREN

- Accelerometer
- Gyroskop
- Licht
- Magnetfeld
- Temperatur
- Geräusche
- WLAN-Zugangspunkte



# MODELL

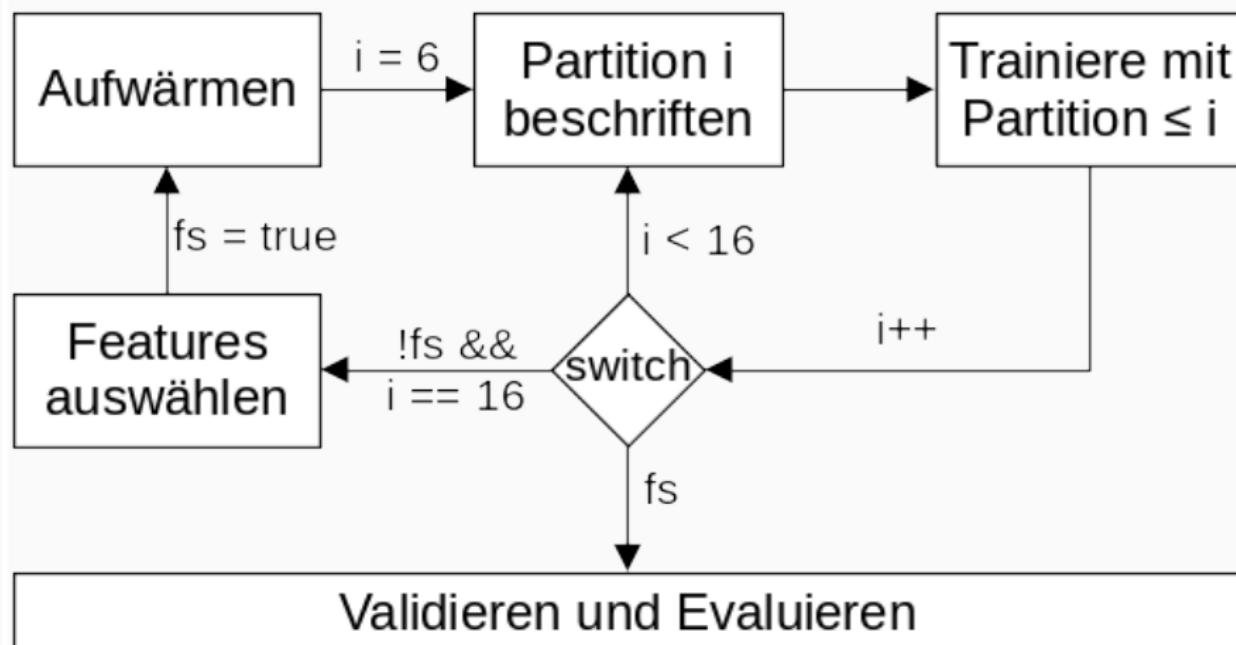


## EXTRAHIERTE FEATURES

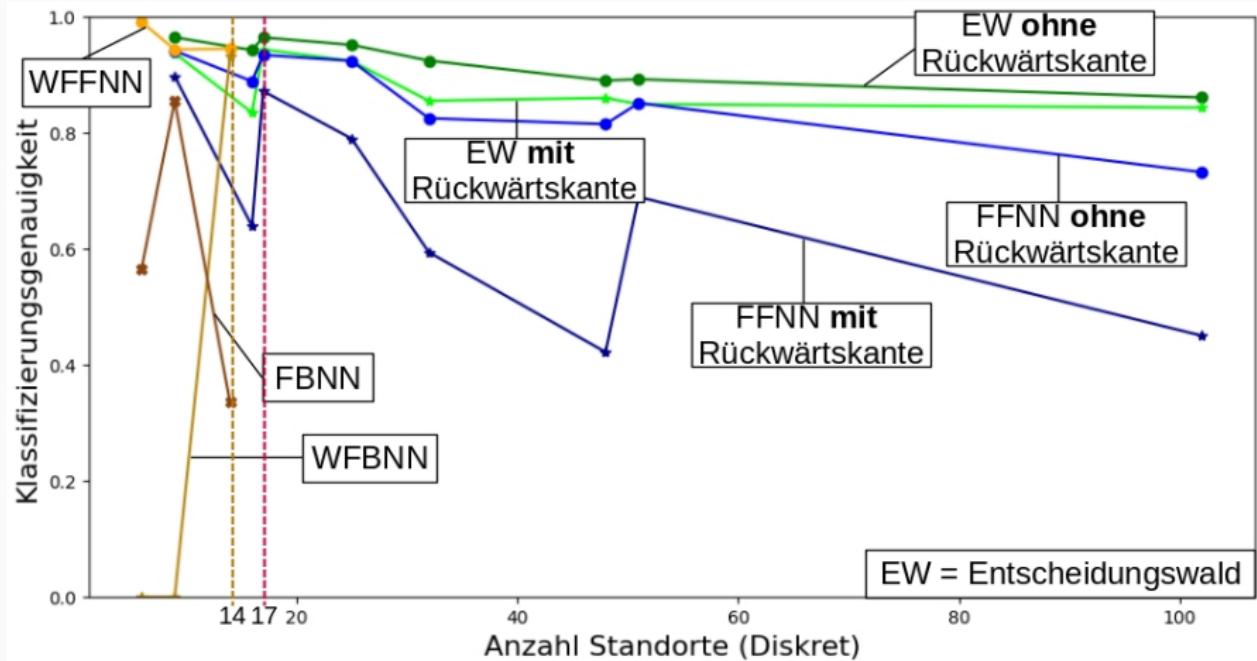
Sensordaten	$\sigma$	Min.	Max.	$\emptyset$	Wert
Accelerometer	X	X	X	X	X
Gyroskop	X	X	X	X	X
Ausrichtung zum Magnetfeld	X	X	X	X	X
Temperatur	X	X	X	X	X
Licht	X	X	X	X	X
Geräusch	X	X	X	X	X
WLAN-Zugangspunkte	-	-	-	-	X
Letzter Standort	-	-	-	-	X
Letzter unterschiedlicher Standort	-	-	-	-	X
Zeit	X	-	-	-	-

# TRAINING DER ML-MODELLE

Partition i:	1 - 5	6 - 15	16 - 20
Phase:	Aufwärmen	Beschriften mit Modell	Validieren
Beschriftet in %:	0	$100 \cdot \min(1, 0.5 + (i - 6)^2 \div 128)$	-

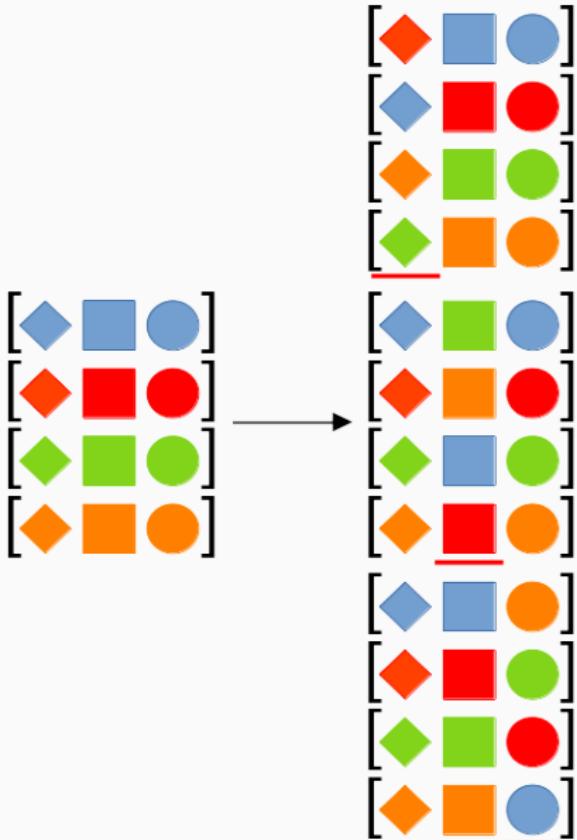


# KLASSIFIZIERUNGSGENAUIGKEIT ÜBER STANDORTKOMPLEXITÄTEN

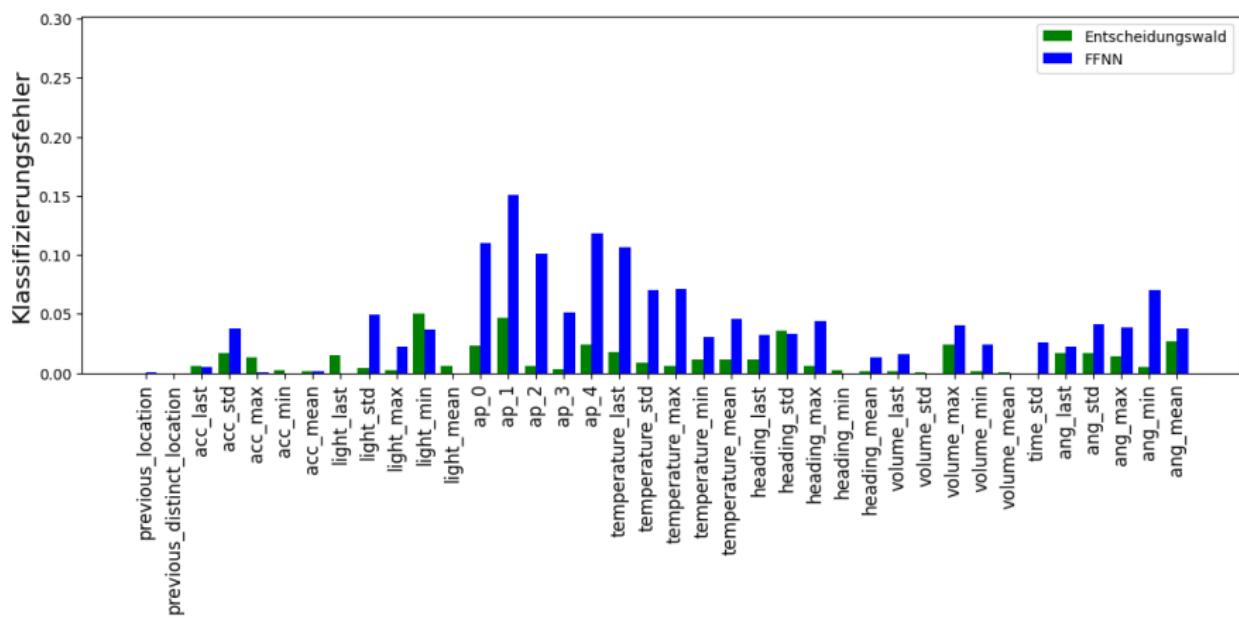


# WICHTIGKEIT VON FEATURES

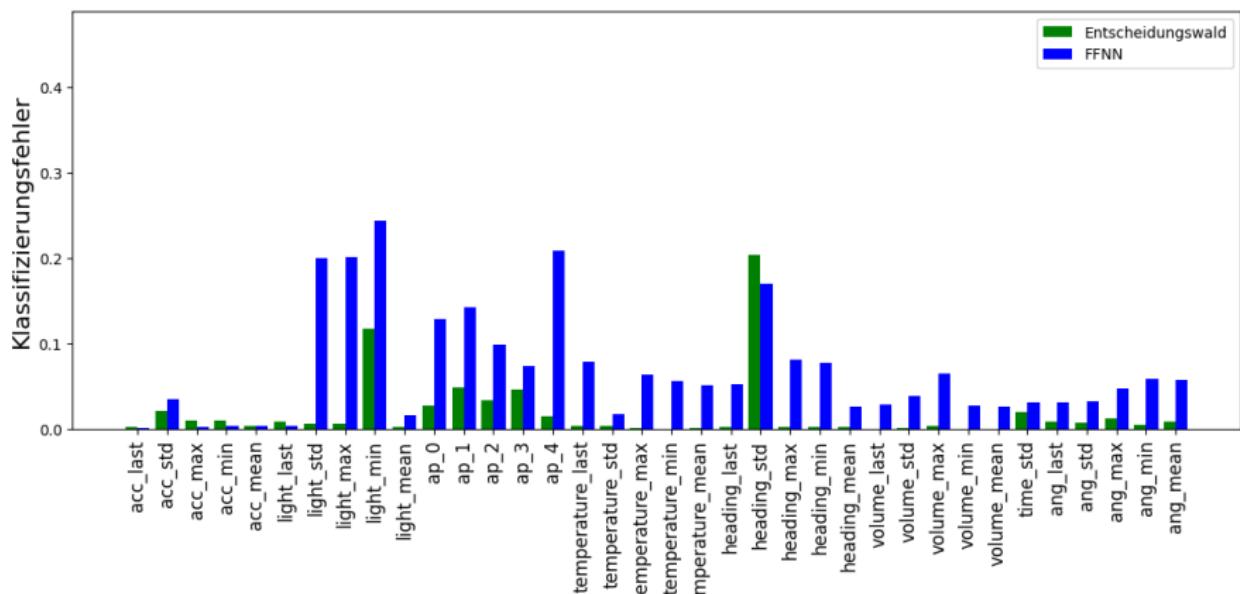
1. Basierend auf Entscheidungsregeln und Trainingsdaten
2. Modifizieren der Testmenge und Fehler zur Originalmenge messen, z. B. Permutationswichtigkeit oder Nullung



# PERMUTATIONSWICHTIGKEIT - ML-MODELLE MIT RÜCKWÄRTSKANTE



# PERMUTATIONSWICHTIGKEIT - ML-MODELLE OHNE RÜCKWÄRTSKANTE



# FEHLERTOLERANZ

Testmenge	Entscheidungswald	FFNN	Entscheidungswald	FNNN
	mit Rückwärtskante		ohne Rückwärtskante	
Licht	4.46%-Pkt.	4.65%-Pkt.	5.28%-Pkt.	6.93%-Pkt.
Geräusch	3.20%-Pkt.	5.00%-Pkt.	1.63%-Pkt.	5.11%-Pkt.
Temperatur	15.15%-Pkt.	6.60%-Pkt.	8.10%-Pkt.	13.50%-Pkt.
Ausrichtung zum Magnetfeld	3.32%-Pkt.	19.94%-Pkt.	2.51%-Pkt.	2.78%-Pkt.
WLAN-Zugangspunkte	2.60%-Pkt.	22.65%-Pkt.	3.74%-Pkt.	14.13%-Pkt.
Accelerometer	1.41%-Pkt.	9.52%-Pkt.	0.62%-Pkt.	1.33%-Pkt.
Gyroskop	8.52%-Pkt.	4.58%-Pkt.	0.91%-Pkt.	3.30%-Pkt.
Permutierte Testmenge	2.27%-Pkt.	-0.13%-Pkt.	0.47%-Pkt.	0.93%-Pkt.
Durchschnitt	5,8%-Pkt.	9,1%-Pkt.	2,91%-Pkt.	6,00%-Pkt.

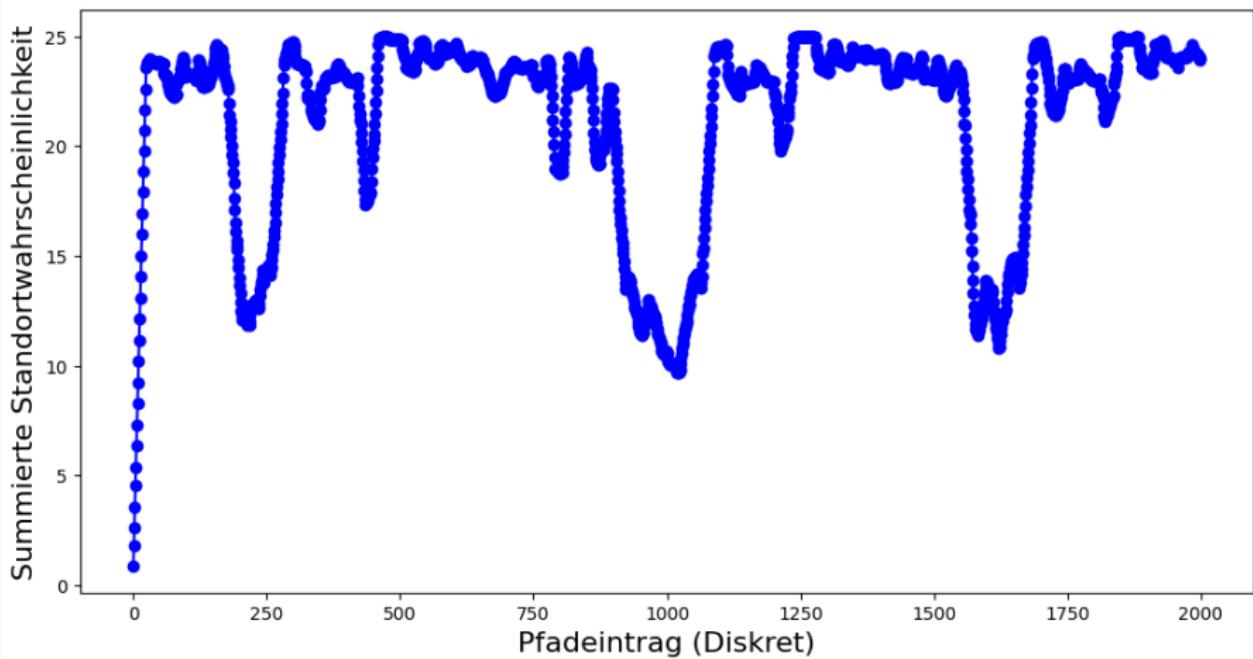
# RESSOURCENNUTZUNG

- Entscheidungswälder benötigen deutlich mehr Programmspeicher
- Entscheidungswälder benötigen deutlich weniger RAM
- Entscheidungswälder sind deutlich effizienter
- Programmgröße skaliert mit Standortkomplexität
- FFNNs zwischen 54% und 97,6% kleiner als Mians FFNNs (70KB bis 3KB)
- Entscheidungswälder bis zu 720% größer als Mians FFNNs (ca. 1MB)

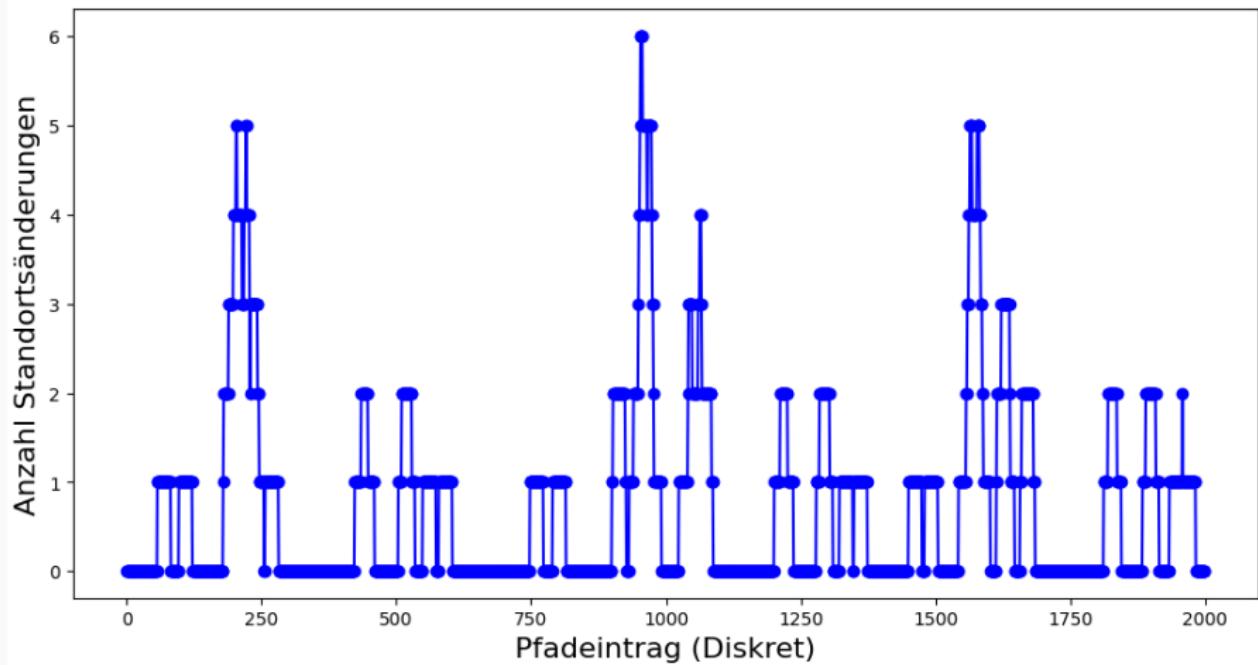
# ANOMALIEERKENNUNG

- Anomalie := Klassifizierung: Momentaner Standort wurde nicht trainiert
- Unendliche viele mögliche Anomalien
- Training basierend auf Sensordaten nicht sinnvoll
- Klassifizierung ungewöhnlichen Verhaltes des Standortbestimmungsmodells

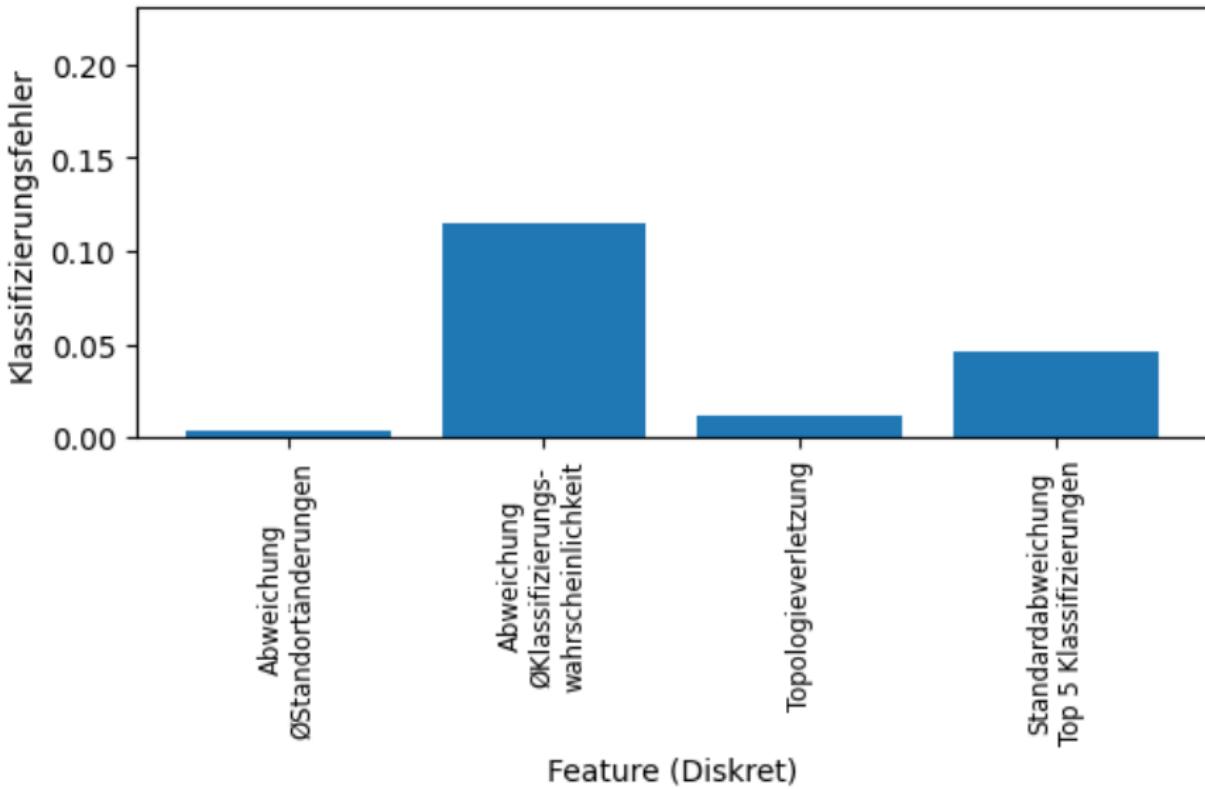
# SUMMIERTE KLASIFIZIERUNGSGENAUIGKEIT IN DATENFENSTER



# ANZAHL STANDORTÄNDERUNGEN IN DATENFENSTER

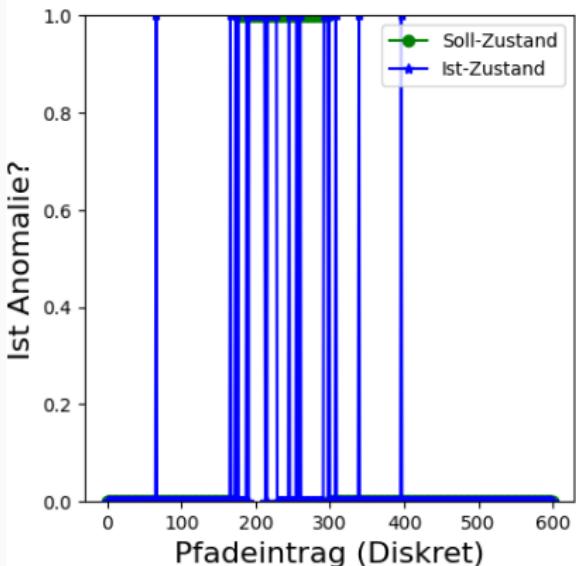


# PERMUTATIONSWICHTIGKEIT



# KLASSIFIZIERUNGSERGEBNISSE

- FFNN konnte **nicht** erfolgreich trainiert werden
- Entscheidungswald kann 52,52% der Anomalien erkennen
- 2,95% Falsch-Positiv Rate
- Klassifizierungsgenauigkeit abhängig von Erkennungsrate von ML-Modell und Standortkomplexität

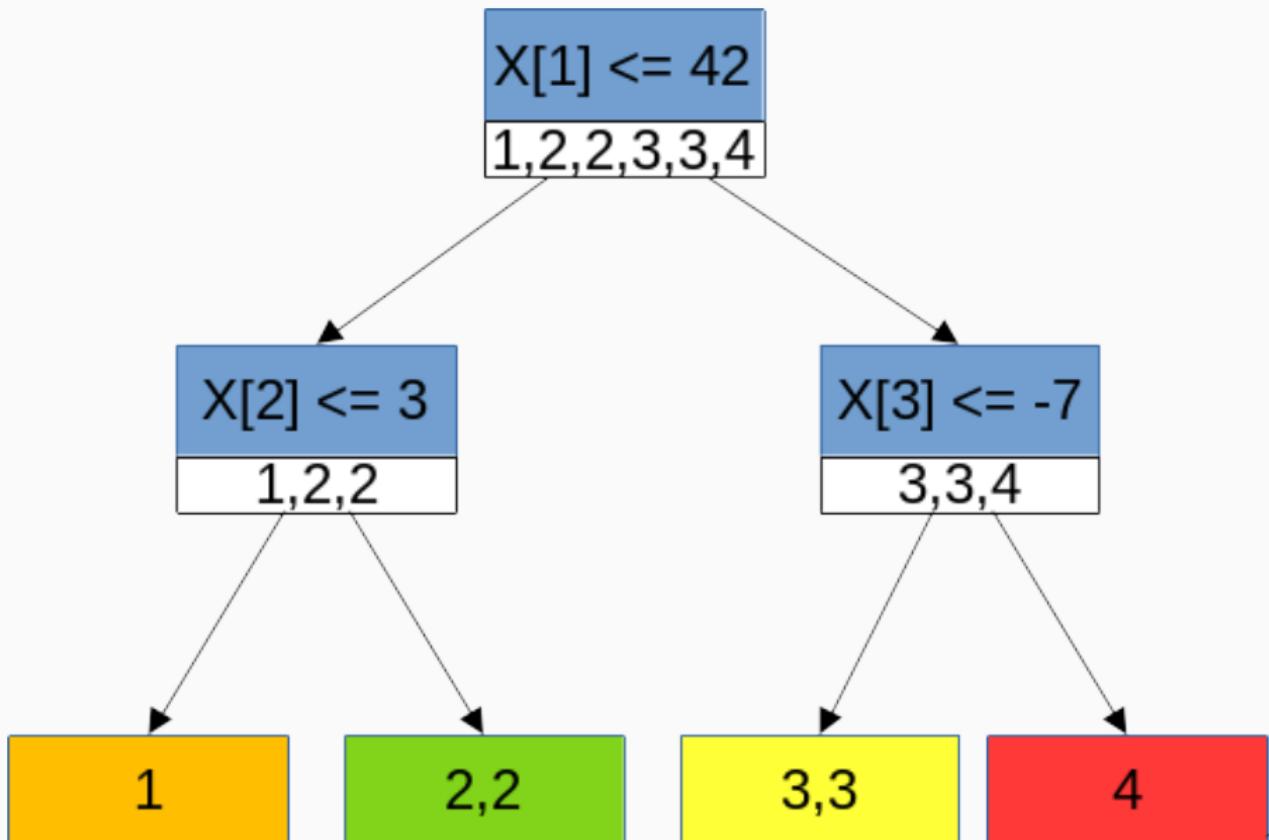


## ERKENNTNISSE DIESER ARBEIT

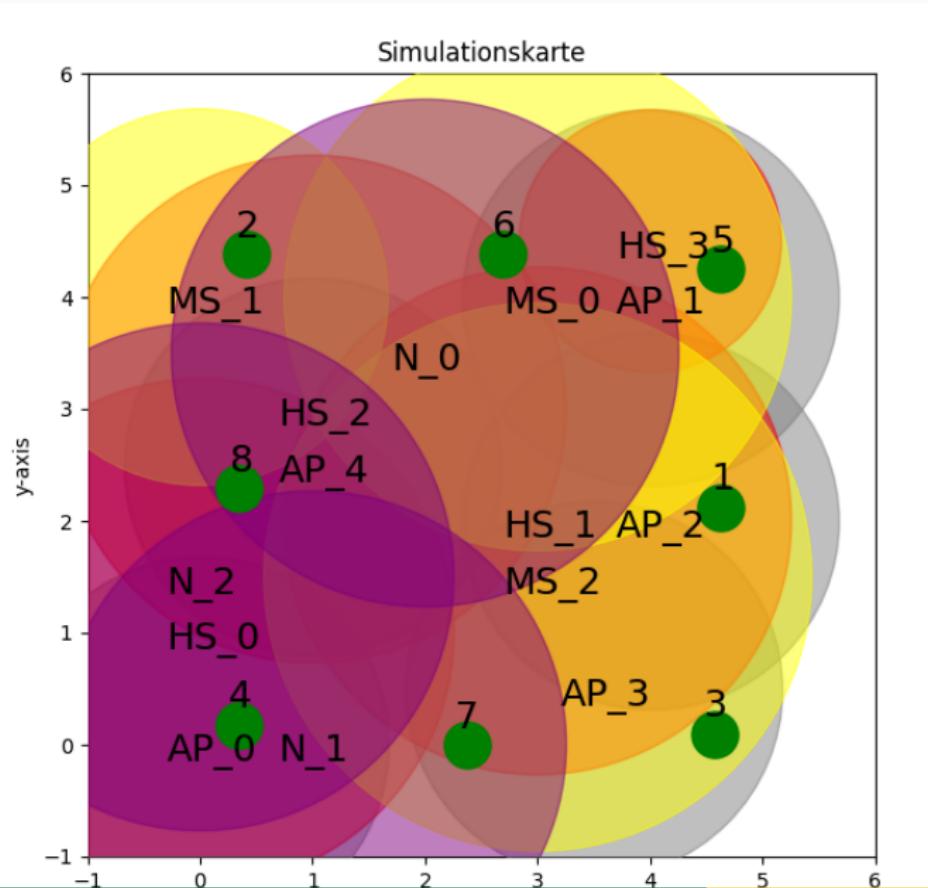
- Entscheidungswälder skalieren besser als FFNN
- ML-Modelle ohne Rückwärtskante besser als mit
- 98,62% bei 9 Standorten, 87,35% bei 102 Standorten
- Anomalieerkennung: Bis zu 52,52% bei Fehlerrate von 2,95%
- Kleine Datenfenster sind ausreichend
- Geringere Ausführungszeit und klein genug
- Orte zu bestimmen ist besser als Orte und Pfade zu bestimmen
- Feature-Wichtigkeit abhängig vom Einsatzszenario

FRAGEN?

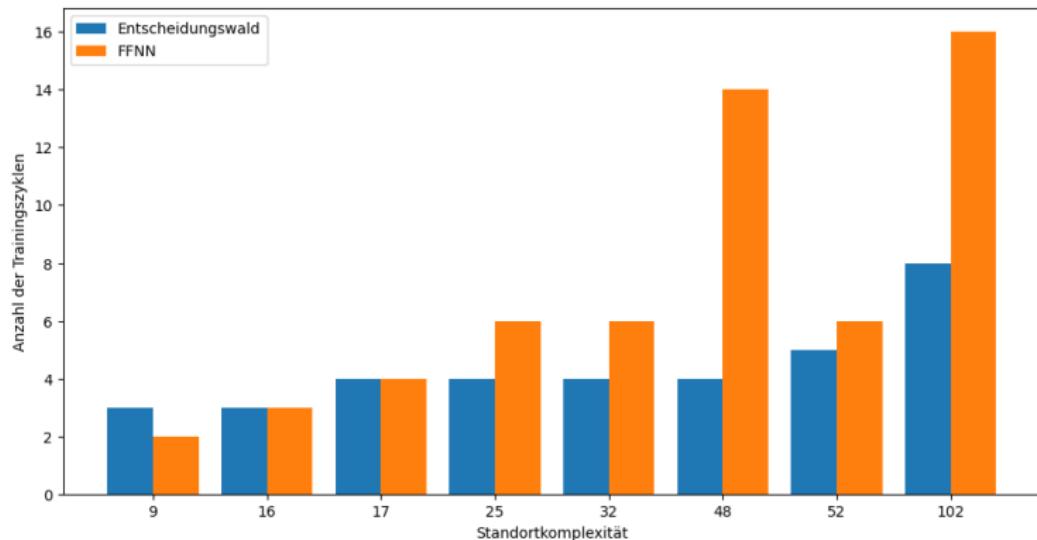
## WICHTIGKEIT VON FEATURES - feature\_importances\_



# SIMULATIONSKARTE VON „SIMPLE SQUARE“



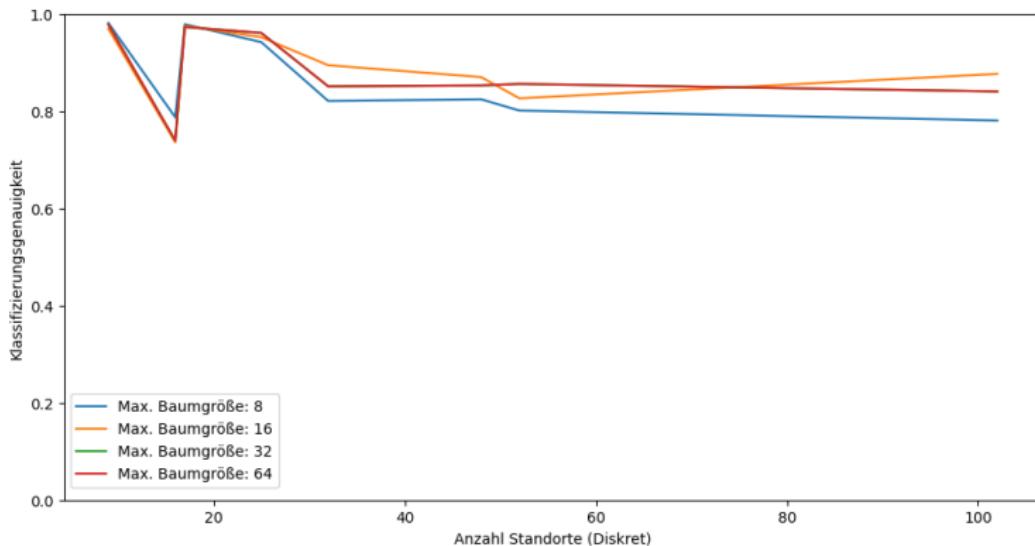
# TRAININGSDATEN PRO ZYKLUS



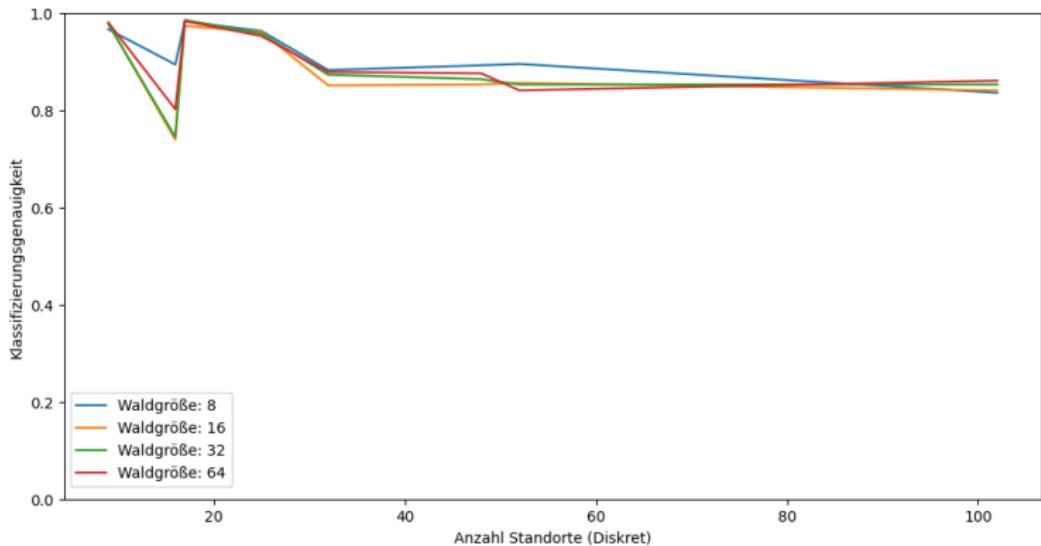
# ANOMALIEERKENNUNG: KLASIFIZIERUNGSERGEBNISSE

Standorte	9	16	17	25	32	48	52	102
<i>P(A)</i>								
DT	82,59%	81,19%	87,14%	84,91%	79,06%	83,47%	81,93%	76,00%
FFNN	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%
Top. (DT)	84,77%	30,57%	83,51%	79,76%	28,63%	24,97%	80,55%	29,47%
Top. (KNN)	86,10%	52,17%	77,72%	79,30%	45,06%	41,92%	74,77%	43,55%
Anteil korrekt klassifiziert, indem Anomalie vorlag								
DT	34,86%	35,52%	52,58%	50,92%	32,21%	50,64%	23,21%	1,92%
FFNN	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%
Anteil korrekt klassifiziert, indem keine Anomalie vorlag								
DT	96,14%	94,41%	97,05%	95,83%	92,48%	93,13%	98,96%	97,18%
FFNN	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%

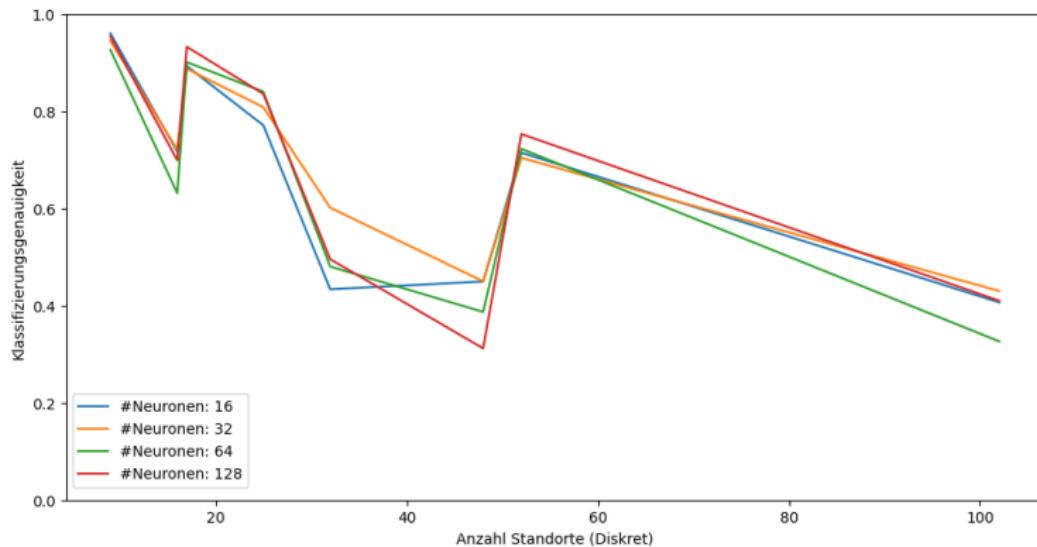
# $P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON MAXIMALER BAUMHÖHE



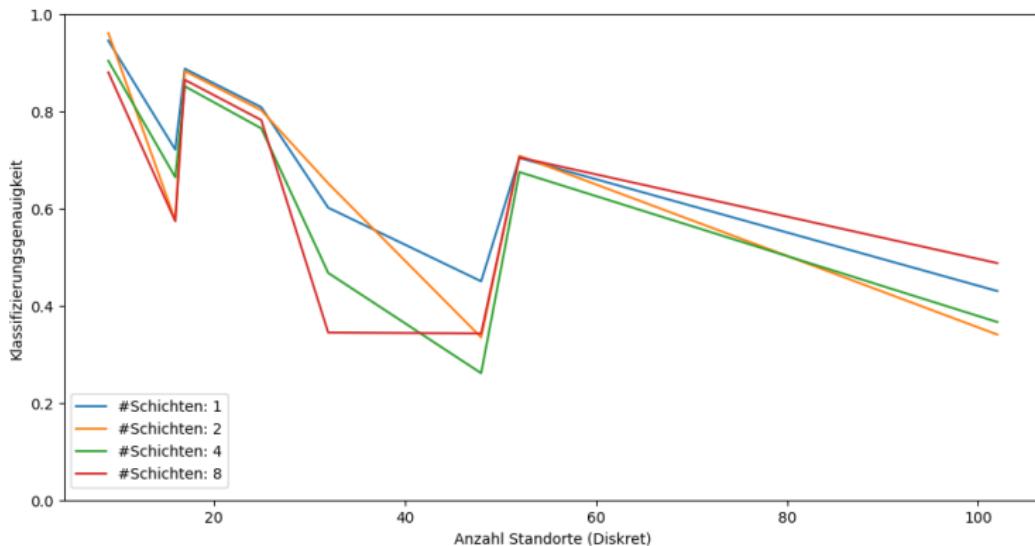
# $P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON WALDGRÖÙE



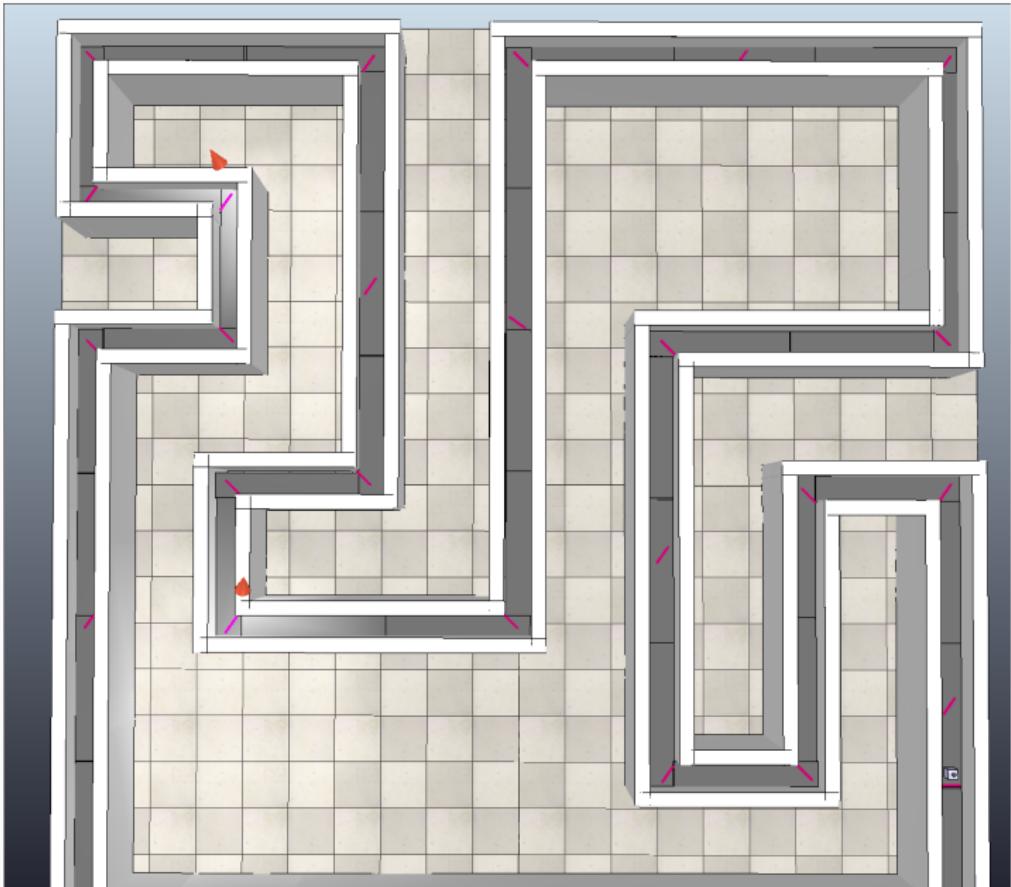
# $P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON ANZAHL NEURONEN



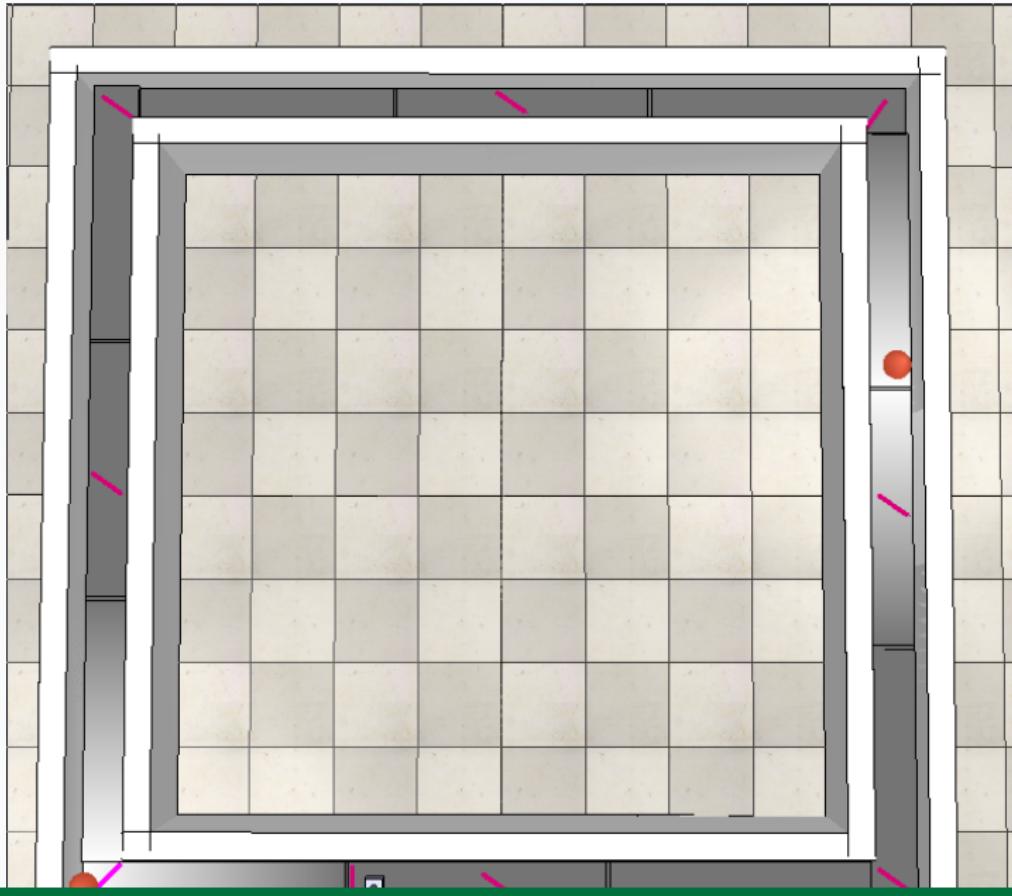
# $P(B \leq 5)_{\text{CONT}}$ - AUSWIRKUNG VON ANZAHL VERDECKTE SCHICHTEN



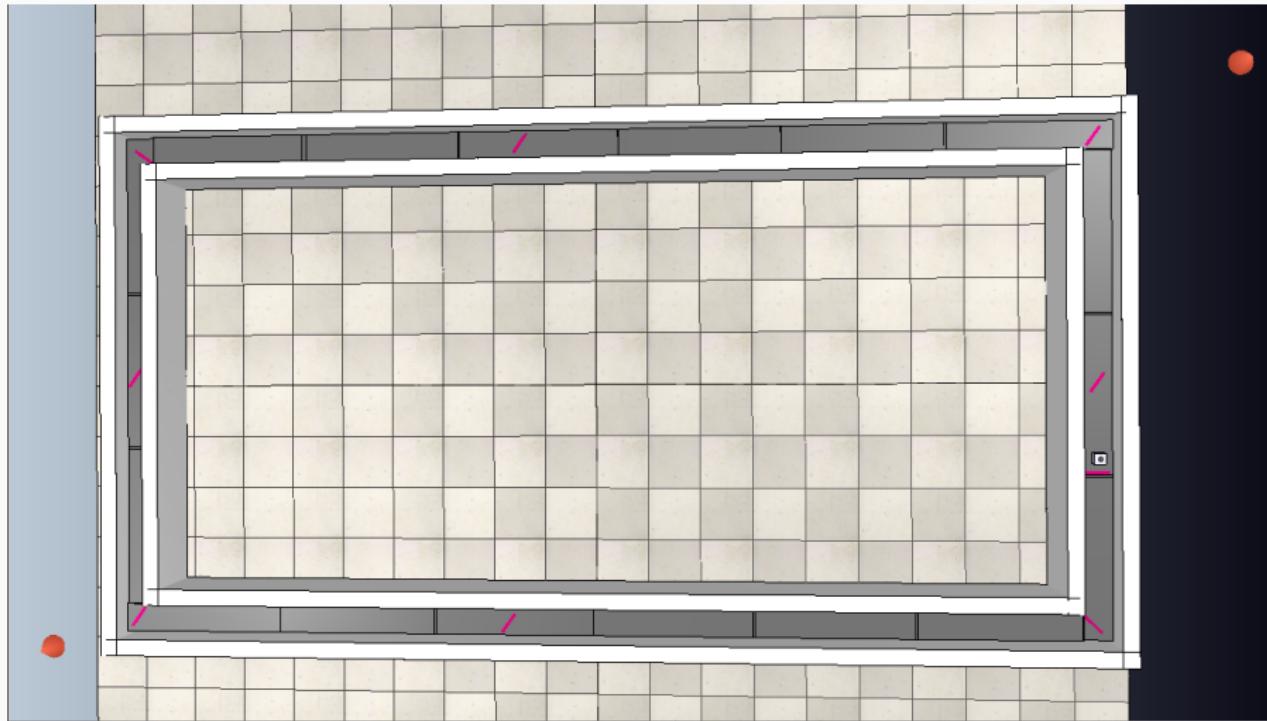
# ROUTE: "MANY CORNERS"



## ROUTE: "SIMPLE SQUARE"



# ROUTE: "LONG RECTANGLE"



## ROUTE: "RECTANGLE WITH RAMP"

