

Masterarbeit

Computer Science

Sensorbasierter Orientierungssinn mit künstlichen neuronalen Netzen und Entscheidungsbäumen

von

Tom Dymel

Juni 2021

Betreut von

Dr. rer. nat. Marcus Venzke
Institut für Telematik, Technische Universität Hamburg

Erstprüfer | Prof. Dr. rer. nat. Volker Turau
Institut für Telematik
Technische Universität Hamburg

Zweitprüfer | Prof. Dr. sc. techn. Christian Schuster
Institut für Theoretische Elektrotechnik
Technische Universität Hamburg

Danksagung

Vorerst möchte ich mich bei dem Institut für Telematik bedanken, dass ich meine Masterarbeit zu diesem spannenden Thema verfassen durfte. Insbesondere möchte ich Dr. Marcus Venzke für die umfangreiche Betreuung bedanken. Zuletzt möchte ich mich bei Malte Laukötter, Jannik Friemann und Isabella Tran für ihre Korrekturen bedanken.

Eidesstattliche Erklärung

Ich, TOM DYMEL (Student im Studiengang Computer Science an der Technischen Universität Hamburg, Matr.-Nr. 21651529), versichere an Eides statt, dass ich die vorliegende Masterarbeit selbstständig verfasst und keine anderen als die angegebenen Hilfsmittel verwendet habe. Die Arbeit wurde in dieser oder ähnlicher Form noch keiner Prüfungskommission vorgelegt.

Hamburg, 3. Juni 2021

Tom Dymel

Inhaltsverzeichnis

1 Einleitung	1
2 Entscheidungsbäume	3
2.1 Scikit-Learn	3
2.2 Einzelne Entscheidungsbäume	4
2.3 Ensemble-Methoden	5
2.4 Training mit Scikit-Learn	7
2.5 Ressourcenbedarf auf dem Mikrocontroller	7
2.5.1 Ausführungszeit und Energieverbrauch	8
2.5.2 Programmgröße und RAM	9
3 Künstliche Neuronale Netze	11
3.1 Keras	13
3.2 Training von KNNs	13
3.3 Lernalgorithmen	14
3.4 Aktivierungsfunktionen	17
3.5 Ressourcenbedarf auf dem Mikrocontroller	19
4 Standortbestimmung	21
4.1 Orientierungssinn von Menschen und Tieren	21
4.2 Indoor- und Outdoor-Lokalisierung	22
4.3 WiFi basierte Indoor-Lokalisierung mit Transfer Lernen	23
4.4 Indoor-Lokalisierung mit Magnet- und Lichtsensoren	23
4.5 Sensorbasierter Orientierungssinn mit FFNN	24
5 Machine Learning Modelle	27
5.1 Standortkodierung	28
5.2 Entscheidungswald	29
5.3 Feed Forward neuronales Netzwerk	30
5.4 Training der ML-Modelle	30
5.5 Anomalieerkennung	32
6 Trainings- und Testdaten	35
6.1 Sensordaten aus Simulator CoppeliaSim	35
6.2 Mit eigenen Modellen ergänzte Sensordaten	37
6.2.1 Magnetfeldsensor	37
6.2.2 Temperatursensor	40
6.2.3 Geräuschsensor	41
6.2.4 WLAN-Zugangspunkte	42
6.3 Simulation von Interrupts	42
6.4 Feature-Extrahierung	43

INHALTSVERZEICHNIS

6.5	Synthetische Daten	45
6.6	Anomaliedaten	46
7	Evaluation	49
7.1	Metriken	50
7.2	Klassifizierungsgenauigkeit der Standorte	51
7.2.1	Vergleich mit Mians Ergebnissen	51
7.2.2	Einfluss der Standortkomplexität	53
7.2.3	Einfluss der Hyperparameter	54
7.3	Klassifizierungsgenauigkeit der Anomalien	54
7.4	Wichtigkeit der Features	56
7.5	Fehlertoleranz	60
7.6	Benötigte Trainingsdaten	63
7.7	Programmspeicher	63
7.8	RAM	65
7.9	Ausführungszeit und benötigte Energie	67
8	Diskussion	71
9	Schlussfolgerungen	73
A	Inhalt des USB-Sticks	75
B	Bildanhänge	77
C	Tabellenanhänge	89
	Literaturverzeichnis	97

Einleitung

Als *Lokalisierung* wird der Prozess bezeichnet die Position von einem Gerät oder Nutzer*innen in einem Koordinatensystem zu bestimmen [BHE00]. Diese Information wird von technischen Systemen genutzt, um deren Dienste anzubieten, z. B. Tracking- oder Navigationssysteme. Ein bekanntes Beispiel ist das *Global Positioning System* (GPS) [KH05]. Bei GPS berechnet das empfangende Gerät seine Position basierend auf den empfangenden Signalen der Satelliten.

In Gebäuden ist die Signalstärke der GPS-Satelliten jedoch stark eingeschränkt, sodass die Ortung ungenau wird oder überhaupt nicht funktioniert. Aus diesem Grund werden für die *Indoor*-Lokalisation andere Ansätze verfolgt. Je nach Genauigkeit können Objekte mit Sennern, RFID Tags oder Barcodes markiert werden [XZYN16]. Meistens wird eine komplexe Infrastruktur benötigt, die Lokalisierungssysteme vergleichsweise teuer machen.

Eine weitere Art der Lokalisation ist der Orientierungssinn von Menschen und Tieren. Anhand von Orientierungspunkten wird von einem Punkt zu einem anderen Punkt navigiert. Beispielsweise Honigbienen navigieren auf Basis von gelernten Orientierungspunkten, um die Nahrungsquelle und das Nest zu finden [MGC⁺96].

In dieser Arbeit wird die diskrete Standortbestimmung basierend auf Sensordaten untersucht, d. h. eine Art der Lokalisierung, in der keine Koordinaten, sondern diskrete Standorte gefunden werden sollen. Dabei soll eine bestimmte Anzahl von Standorten anhand verschiedener Sensorwerte unterschieden werden. Dies ähnelt dem zuvor beschriebenen Orientierungssinn. Mit Hilfe maschinellen Lernens sollen künstliche neuronale Netze (KNNs) und Entscheidungsbäume auf Basis von ausgewählten Features, d. h. Attribute und Eigenschaften der Daten, trainiert werden. Diese Arbeit baut auf den Ergebnissen von Mian auf, der die diskrete Standortbestimmung mit Hilfe von Feed Forward neuronalen Netzwerken (FFNNs) untersucht hatte [Mia21].

1 EINLEITUNG

Mian nutzte drei Sensoren und große FFNNs, um 14 Standorte bestimmen zu können. Zusätzliche Sensoren können das Problem potenziell vereinfachen, wodurch kleinere Modelle verwendet und mehr Standorte unterschieden werden können.

Zur Erstellung dieser Arbeit wurde ein Evaluierungsprozess der Sensordaten erstellt, mit dem Standorte und Anomalien mit Hilfe von ML-Modellen unterschieden werden. Dafür wurden Sensordaten mit CoppeliaSim simuliert, da Echtdaten eines Prototyps zum Zeitpunkt dieser Arbeit noch nicht verfügbar sind. Die simulativ erfassten Sensordaten wurden mit weiteren Sensordaten auf Basis vereinfachter Modelle ergänzt. Es wurde die Klassifizierungsgenauigkeit der ML-Modelle untersucht im Hinblick auf Skalierbarkeit der Anzahl der Standorte sowie Robustheit gegenüber möglicher Fehler. Außerdem wurde die Klassifizierungsgenauigkeit des Anomalieerkennungsmodells untersucht. Auch wurde der Speicher- und Energiebedarf für den Betrieb auf einem batteriestützten Mikrocontroller geschätzt. Insgesamt wurden 256 ML-Modelle zur Standortbestimmung von 9 bis 102 Standorten und zwei ML-Modelle zur Anomalieerkennung evaluiert.

Kapitel 2 führt Entscheidungsbäume und Ensemble-Methoden ein. Kapitel 3 führt künstliche neuronale Netze (KNN) mit dem Fokus auf FFNNs ein. In Kapitel 4 wird auf den Stand der Forschung für die Standortbestimmung mit Hilfe von maschinellen Lernen (ML) eingegangen. Das Trainieren der ML-Modelle mit Entscheidungsbäumen und FFNNs wird in Kapitel 5 erläutert. Kapitel 6 geht auf die Generierung von Trainings- und Testdaten auf Basis von Simulationen ein. Darauf folgt die Evaluation der Klassifizierungsgenauigkeit, Fehlertoleranz und Ressourcennutzung in Kapitel 7. Kapitel 8 enthält einen kritischen Rückblick auf die Entscheidungen dieser Arbeit bevor Kapitel 9 Schlussfolgerungen zieht.

Entscheidungsbäume

Ein Entscheidungsbaum ist ein Baum mit dem Entscheidungen getroffen werden [Qui90]. Das geschieht, indem der Baum von der Wurzel zu einem Blatt traversiert wird. Dabei bestimmt ein Test in jedem inneren Knoten, mit welchem Kindknoten fortgefahrene wird. Jedes Blatt entspricht einer Entscheidung des Entscheidungsbaums. Es wird unterschieden zwischen Bäumen, die versuchen eine der vordefinierten Klassen zu klassifizieren (Klassifizierer) und solchen, die versuchen den nächsten Wert vorherzusagen (Regressoren).

Die Konstruktion eines optimalen binären Entscheidungsbaumes ist NP-Vollständig [LR76]. Den optimalen Klassifizierer zu finden ist folglich sehr aufwendig. Aus diesem Grund werden bei der Konstruktion Heuristiken verwendet, die nur lokal die beste Entscheidung treffen. Zudem werden einzelne Entscheidungsbäume in einem Ensemble zu einen Entscheidungswald zusammengefasst, um den Fehler eines einzelnen Baumes zu reduzieren [lea20b].

2.1 Scikit-Learn

Diese Arbeit verwendet die Python ML-Bibliothek *Scikit-Learn*. Scikit-Learn bietet verschiedene ML Algorithmen mit einem High-Level Interface an [PVG⁺11]. Zur Konstruktion der Entscheidungsbäume wird der Algorithmus von CART verwendet [lea20a]. Die Bibliothek kann Klassifizierer und Regressoren generieren.

Nachfolgend wird nur von Klassifizierern ausgegangen, da nur diese für diese Arbeit benötigt werden. Diese bieten zahlreiche Hyperparameter an, um die Konstruktion des Entscheidungsbaumes zu steuern. In dieser Arbeit wird der Hyperparameter `max_depth` verwendet, der die maximale Baumhöhe beschränkt und somit den Programmspeicherverbrauch begrenzt.

2 ENTScheidungsbäume

Scikit-Learn bietet Ensemble-Methoden an, um Entscheidungswälder zu trainieren. Ein wichtiger Parameter dieser Methoden ist `n_estimators`. Er steuert die Größe des Ensembles bzw. die Waldgröße. Somit hat auch dieser Parameter Einfluss auf den Programmspeicherverbrauch.

2.2 Einzelne Entscheidungsbäume

Ein einzelner Entscheidungsbaum ist eine rekursive Datenstruktur um Entscheidungsregeln darzustellen [Qui90]. Jeder innere Knoten ist ein *Test*, welcher eine arbiträre Anzahl von sich gegenseitig ausschließenden Ergebnissen hat. Das Ergebnis eines Tests bestimmt mit welchem Kindknoten fortgefahrene wird. Die Blätter des Baumes stellen die Entscheidungen dar bzw. die Klassen des Entscheidungsbaumklassifizierers. Abbildung 2.1 zeigt einen binäreren Entscheidungsbaum, in dem jeder Test zwei mögliche Ergebnisse hat. Das Trainieren von



■ Abbildung 2.1: Beispiel eines binären Entscheidungsbaums mit 3 möglichen Ergebnissen.

Entscheidungsbäumen ist eine Art von *Supervised Learning*, d. h. aus einer beschrifteten Trainingsmenge werden Regeln abgeleitet, um das korrekte Mapping von Input zu Output abzubilden [GL09]. Die Trainingsmenge besteht aus Feature-Mengen, die mit Klassen beschriftet sind [Ste09]. Die Generalisierungsfähigkeit ist abhängig von der Trainingsmenge. Zum einen sollte die Trainingsmenge möglichst repräsentativ sein für die Aufgabe, die gelernt werden soll. Zum anderen sollten die verwendeten Features eine Partitionierung aller Klassen ermöglichen [PGP98].

Entscheidungsbäume werden heuristisch konstruiert, da die Konstruktion eines optimalen Entscheidungsbäumes NP-Vollständig ist [LR76]. Zu diesen Algorithmen gehören beispielsweise ID3 [Qui86], C4.5 [Qui92] oder CART [BFSO84]. Die Aufgabe ist durch gezielte Trennungen eine Partitionierung der Trainingsmenge zu erzeugen, sodass möglichst nur Einträge mit der gleichen Beschriftung in einer Partitionierung enthalten sind. Die Algorithmen unterscheiden sich in ihrer Strategie [Qui86].

Scikit-Learn implementiert eine optimierte Version des **CART** (Classification And Regression Trees) Algorithmus [lea20a]. CART partitioniert die Trainingsmenge indem lokal immer die beste Teilung ausgewählt wird. Die beste Teilung ist die Teilungregel, die Einträge mit der gleichen Beschriftung möglichst gut von anderen Einträgen trennt. Dieser Vorgang wird rekursiv mit jeder Teilmenge wiederholt, bis keine weitere Teilung mehr möglich ist oder alle Einträge einer Partitionierung die gleiche Beschriftung tragen [Ste09].

2.3 Ensemble-Methoden

Ensemble-Methoden beschreiben wie mehrere Entscheidungsbäume trainiert werden, um eine möglichst hohe Diversität der einzelnen Entscheidungsbäume zu erzielen. Das Ergebnis eines Ensembles ist die Aggregation der Ergebnisse der einzelnen Entscheidungsbäume [D⁺02].

Der Wahlklassifizierer $H(x) = w_1h_1(x) + \dots + w_Kh_K(x)$ ist eine Möglichkeit die Einzelergebnisse $\{h_1, \dots, h_K\}$ gewichtet mit $\{w_1, \dots, w_K\}$ zu aggregieren [D⁺02]. Ein Ergebnis kann auf zwei Arten modelliert sein. Einerseits als eine Funktion $h_i : D^n \mapsto \mathbb{R}^m$, die einer n -dimensionalen Menge D^n jeder der m möglichen Klassen eine Wahrscheinlichkeit zuweist. Das Ergebnis ist eine Wahrscheinlichkeitsverteilung. Das diskrete Ergebnis der Klassifizierung ist die Klasse mit der höchsten Wahrscheinlichkeit in dem Ergebnis. Alternativ kann es als eine Funktion $h_i : D^n \mapsto M$ abgebildet werden, die diskret auf eine der möglichen Klassen in M verweist [Dym21]. In diesem Fall wird die Klasse ausgewählt, die am häufigsten unter allen Einzelergebnissen vorkam. In der Praxis wird die Aggregation der Wahrscheinlichkeitsverteilung genutzt [lea20b]. Analog ist $H : D^n \mapsto \mathbb{R}^m$ oder $H : D^n \mapsto M$ definiert [D⁺02]. Für gewöhnlich hat jeder Teilnehmer einer Wahl das gleiche Gewicht.

Bagging (**Bootstrap aggregating**) konstruiert Entscheidungswälder, indem es Entscheidungsbäume mit Teilmengen der Trainingsmenge trainiert. Abbildung 2.2 illustriert die Bagging Methode für n Entscheidungsbaummodelle. Zunächst wird die Trainingsmenge in n Teilmengen aufgeteilt [Bre96]. Der Inhalt der Teilmengen wird mit der „Bootstrap sampling“ Methode bestimmt. Diese zieht aus einer Grundmenge l -mal jeweils k -Einträge [Efr92]. Mit jeder Teilmenge wird ein Entscheidungsbaum trainiert [Bre96]. Die Einzelergebnisse werden aggregiert, z. B. mit dem Wahlklassifizierer.

Random Forest erweitert die Bagging-Methode [Bre01]. Für jeden Entscheidungsbaum der trainiert werden soll, wird zusätzlich zufällig eine Teilmenge der Feature-Menge ausgewählt.

2 ENTSCHEIDUNGSBÄUME



Abbildung 2.2: Klassifizierungsprozess mit der Bagging-Methode.

Extremely Randomized Trees (ExtraTrees) verwenden ebenfalls eine Teilmenge der Feature-Menge der Trainingsmenge beim Trainieren der einzelnen Entscheidungsbäume [GEW06]. Allerdings wird für jeden Entscheidungsbau die gesamte Trainingsmenge verwendet. Bei der Konstruktion wird nicht versucht die beste Teilungsregel zu finden, sondern es werden zufällig Teilungsregeln generiert, aus denen die Beste ausgewählt wird.

Beim Boosting werden nacheinander schwache Lerner auf einer Teilmenge trainiert, die gewichtet aggregiert werden [FS97]. Dadurch entsteht ein starker Lerner. Abbildung 2.3 illustriert, wie vier schwache Lerner trainiert werden. Jeder Lerner findet eine Funktion der die trainierte Teilmenge unterteilt. Anschließend werden sie gewichtet aggregiert. Dies konstruiert einen starken Lerner, der die gesamte Trainingsmenge unterteilt. Diese Arbeit verwendet für Boosting den Algorithmus AdaBoost [FS97] von Freund und Schapire.



Abbildung 2.3: Klassifizierungsprozess mit der Boosting-Methode.

2.4 Training mit Scikit-Learn

Die Konstruktion eines Entscheidungsbaumes mit Scikit-Learn ist nicht deterministisch [Dym21]. Bei der Konstruktion mit CART können zwei Teilungsregeln gefunden werden, die eine gleich gute Unterteilung erzeugen. In diesem Fall wählt Scikit-Learn zufällig eine Teilung aus. Dadurch werden anschließende Teilungen beeinflusst, die in einen der Fälle womöglich bessere Teilungen hätten finden können. Dieser Zufall ist steuerbar, indem der Startwert des Zufallgenerators auf einen vordefinierten Wert gesetzt wird.

Bei identischer Trainingsmenge und Konfiguration können folglich für verschiedene Startwerte unterschiedliche Modelle erzeugt werden. Aus diesem Grund kann das Training mit einem Startwert als Monte Carlo Methode verstanden werden, d. h. wiederholtes Ausführen unter verschiedenen Startwerten erhöht die Wahrscheinlichkeit, dass das beste Modell unter der angegebenen Konfiguration gefunden wird.

Dies bedarf, dass die Klassifizierungsgenauigkeit beim Training bereits ermittelt wird, damit das beste Modell ausgewählt werden kann. Dafür wird die Trainingsmenge in zwei Mengen unterteilt. Mit einer Teilmenge werden die Entscheidungsbäume unter verschiedenen Startwerten des Zufallgenerators trainiert und mit der anderen Teilmenge werden diese untereinander verglichen. Das Ergebnis des Trainingprozesses ist das Modell, dass auf letzterer Teilmenge die höchste Klassifizierungsgenauigkeit erzielt.

2.5 Ressourcenbedarf auf dem Mikrocontroller

Zukünftig soll das Modell auf einem Mikrocontroller ausgeführt werden. Mikrocontroller sind stark limitiert in ihrer Rechenleistung, Speicherkapazität, RAM und werden oft zudem mit einer Batterie betrieben. Aus diesem Grund ist der Energieverbrauch zu minimieren und das Modell muss innerhalb dieser Limitierungen operieren können.

2 ENTSCHEIDUNGSBÄUME

2.5.1 Ausführungszeit und Energieverbrauch

Der Energieverbrauch korreliert mit der Ausführungszeit. Je länger die CPU ausgeschaltet ist, desto weniger Energie wird verbraucht. Kurze Ausführungszeiträume vergrößern den Zeitraum, in dem die CPU ausgeschaltet sein kann. Die Ausführungszeit ist die Zeit die benötigt wird, um alle Instruktionen auszuführen [Dym21]. Jede Instruktion bedarf eine bestimmte Anzahl an CPU-Zyklen. Die Zeit pro Zyklus ist abhängig von der Taktrate der CPU.

Die Ausführungszeit eines Entscheidungswaldes setzt sich zusammen aus der Zeit für die Feature-Extrahierung, der Evaluierung aller im Ensemble enthaltenen Entscheidungsbäume und der Aggregierungsfunktion. Im schlimmsten Fall muss die gesamte Höhe eines Entscheidungsbäumes traversiert werden, um das Ergebnis zu bestimmen. Aus diesem Grund skaliert die Ausführungszeit mit der traversierten Höhe jedes Baumes.

Um die Instruktionen zu minimieren sollten Datentypen verwendet werden, die von der CPU mit höchstens einem Wort dargestellt werden können. Eine 8-Bit CPU würde zum Laden in Register eines 32-Bit Datentypen vier mal so viele Instruktionen benötigen wie bei einem 8-Bit Datentypen. Außerdem sollten Operationen verwendet werden, die durch native Hardware-Operationen abgebildet werden können. Ist dem nicht so, muss diese Operation durch Software ersetzt werden. Dies erfordert mehr Zyklen als eine native Operation in Hardware.

Zu Beachten bei der Minimierung ist, dass Instruktionen unterschiedlich viele Zyklen benötigen und Funktionsaufrufe Overhead erzeugen. Ein Beispiel dafür ist die Optimierung *Function Inlining* [LM99]. Der Aufruf von Funktionen kann einen hohen Overhead durch den Kontextwechsel erzeugen. Aus diesem Grund verringert diese Optimierung die Ausführungszeit, erhöht aber die Programmgröße signifikant. Im Umkehrschluss könnten durch die Verwendung von Funktionen der nutzen des Programmspeichers verringert werden, Ausführungszeit und Energieverbrauch aber erhöht werden.

2.5.2 Programmgröße und RAM

Die Programmgröße ist die Gesamtheit aller Instruktionen die für das Programm benötigt werden [Dym21]. Dabei ist der Anteil für die Entscheidungswälder integral und der Anteil für die perifären Funktionalitäten zu vernachlässigen. Die Programmgröße, die für einen Entscheidungswald benötigt wird, skaliert mit der Waldgröße und Höhe der einzelnen Entscheidungsbäume.

Die Höhe des Entscheidungsbaumes ist die Verzweigungstiefe der verschachtelten Tests. Jeder Test ist ein Vergleich mit einem Schwellenwert. Die Programmgröße für einen Vergleich setzt sich zusammen aus den Operationen, um die Operanden in die Register zu laden, und die Instruktion, um den Vergleich durchzuführen, sowie Abzweiginstruktionen. Wie in Kapitel 2.5.1 sind Instruktionen durch einen passenden Datentypen zu vermeiden.

Ein weiterer Faktor sind die Instruktionen, die zur Rückgabe des Klassifizierungsergebnis benötigt werden. In Kapitel 2.3 wurden verschiedene Möglichkeiten der Rückgabe diskutiert, die relevant bei dem Aggregierungsprozess eines Ensembles ist. Einerseits kann die Rückgabe eine Wahrscheinlichkeitsverteilung sein und andererseits eine diskrete Klasse. Bei m möglichen Klassen würde die erste Variante m -mal so viele Instruktion benötigen, wie die zweite Variante, da der Rückgabevektor zuvor mit der Wahrscheinlichkeitsverteilung gefüllt werden muss. In der Praxis werden aber weniger Instruktion benötigt, da es eine große Überschneidung der Wahrscheinlichkeitsverteilungen gibt, die zurück gegeben werden. Die Instruktionen, um den Rückgabevektor zu befüllen, können durch *Basic Blocks*, d. h. beschriftete Instruktionsblöcke, geschickt recycled werden. Zudem können Zuweisungen ausgelassen werden, die die Wahrscheinlichkeit 0 zuweisen, da der Vektor mit Nullen initialisiert wird. Dennoch werden signifikant mehr Instruktionen benötigt als bei der diskreten Variante. Aus diesem Grund wurde ein hybrider Ansatz vorgeschlagen, der im Falle eines eindeutigen Ergebnisses mit einer Toleranz von $\epsilon \in [0, 1]$ die diskrete Klasse statt der Wahrscheinlichkeitsverteilung zurück gibt.

Der benötigte RAM ist abhängig von der Größe der Feature-Menge und Anzahl zu klassifizierenden Klassen. Für die Rückgabe wird zwischen ein Byte und mQ Byte benötigt, wobei Q die Größe des verwendeten Datentypen ist, um eine Gleitkommazahl zu speichern.

2 ENTSCHEIDUNGSBÄUME

Künstliche Neuronale Netze

Das mathematische Modell von künstlichen neuronalen Netzen wurde von McCulloch und Pitts im Jahre 1943 erfunden [MP43]. Dieses Modell ist eine Abstraktion des biologischen Neuronen als logischer Mechanismus.

Das Nervensystem besteht aus einem Netz von Neuronen, die miteinander verbunden sind und über elektrische Impulse miteinander interagieren [Ros61]. Man unterscheidet beim biologischen Neuronen zwischen *Afferent*-Neuronen, *Efferent*-Neuronen und *Inter*-Neuronen. Afferent-Neuronen nehmen elektrische Signale von Organen entgegen und können als *Input* interpretiert werden. Efferent-Neuronen geben elektrische Signale an *Effektorzellen* weiter und können als *Output* interpretiert werden. Inter-Neuronen nehmen elektrische Signale von Afferent-Neuronen oder Inter-Neuronen entgegen und geben sie an Inter-Neuronen oder Efferent-Neuronen weiter. Wenn der Schwellenwert eines *Dendrite* von einem Neuronen durch ein elektrisches Signal erreicht wurde, wird ein elektrisches Signal über den *Axon* an ein anderes Neuron oder Effektorzellen übertragen.

Diese Charakteristiken werden mathematisch als ein Vergleich von einer gewichtete Summe von eingehenden Signalen mit einem Schwellenwert modelliert [HH19]. Dieser Zusammenhang wird durch (3.1) formalisiert.

$$y = \sigma\left(\sum_{i=1}^n \mathbf{w}_i \mathbf{x}_i + b\right) \quad (3.1)$$

Die Vergleichsoperation ist die *Aktivierungsfunktion* $\sigma : \mathbb{R} \mapsto \mathbb{R}$, die in diesem Fall die Stufenfunktion ist. Die Eingabe $\mathbf{x} \in \mathbb{R}^n$ wird mit $\mathbf{w} \in [0, 1]^n$ gewichtet und der *Bias* $b \in \mathbb{R}$ wird addiert. Der Bias stellt den Schwellenwert dar.

3 KÜNSTLICHE NEURONALE NETZE

Das künstliche neuronale Netz approximiert eine arbiträre Funktion f^* . Dazu findet es eine Menge von Parametern θ , wodurch $f^*(\mathbf{x}) \approx f(\mathbf{x}, \theta)$ möglichst gut von der Approximationsfunktion f abgebildet wird [BGC17].

Das KNN ist in Schichten organisiert. Analog zu den biologischen Neuronen, gibt es eine *Eingabeschicht* (engl. *Input-Layer*), *Ausgabeschicht* (engl. *Output-Layer*) und *verdeckte Schichten* (engl. *Hidden-Layer*). Dies wird in Abbildung 3.1 illustriert. Analog zur Aktivierung eines einzelnen Neuronen, dargestellt in (3.1), stellt (3.2) die Aktivierung einer Schicht dar [HH19].

$$\mathbf{a}_l = \sigma_l(\mathbf{z}_l), \quad \mathbf{z}_l := \mathbf{W}_l \mathbf{a}_{l-1} + \mathbf{b}_l \quad (3.2)$$




Abbildung 3.1: Beispiel eines FFNN mit vier Schichten und einer binären Ausgabeschicht.

Das allgemeine KNN verfügt über $L \in \mathbb{N}$ Schichten. Jede Schicht l verfügt über $n_l \in \mathbb{N}$ Neuronen. Die Aktivierungsfunktion $\sigma_l : \mathbb{R}^{n_l} \mapsto \mathbb{R}^{n_l}$ berechnet die Aktivierung mit der gewichteten Summe \mathbf{z}_l . Die gewichtete Summe setzt sich zusammen aus der Aktivierung der vorherigen Schicht \mathbf{a}_{l-1} die mit $W_l \in \mathbb{R}^{n_l \times n_{l-1}}$ gewichtet wird. Die Schwellenwerte der Neuronen werden durch die Biase $\mathbf{b}_l \in \mathbb{R}^{n_l}$ dargestellt. In (3.3) wird das allgemeine KNN mit einer rekursiven Funktion modelliert.

$$\mathbf{a}_1 := \mathbf{x}, \quad \mathbf{z}_l := \mathbf{W}_l \mathbf{a}_{l-1} + \mathbf{b}_l, \quad \mathbf{a}_l := \sigma_l(\mathbf{z}_l), \quad \mathbf{f}(\mathbf{x}) := \mathbf{a}_L \quad (3.3)$$

Diese Arbeit nutzt ausschließlich *Feed Forward neuronale Netzwerke*. Diese werden durch *dichte Schichten* (engl. *Dense-Layer*) charakterisiert, d. h. Schichten in denen alle Neuronen einer Schicht mit allen Neuronen der folgenden Schicht verbunden sind [BGC17].

3.1 Keras

Keras ist die am meisten genutzte *deep learning* API und wurde in Python geschrieben [ker21]. Dadurch ist sie kompatibel mit allen gängigen Betriebssystemen. Ihr Fokus ist eine intuitive und simple API anzubieten, sodass schnelle Iterationen im Entwicklungsprozess möglich sind. Trotzdem ist sie effizient und skalierbar, um die Kapazitäten großer Rechenverbunde auszunutzen.

Keras abstrahiert das ML System *Tensorflow*. Tensorflow implementiert ML Algorithmen, die dem Stand der Forschung entsprechen. Der Fokus ist auf effizientes Training der Modelle [ABC⁺16] gerichtet. Dafür nutzt es die Multikernarchitektur von CPUs, GPUs und spezialisierter Hardware, sogenannten TPUs (Tensor Processing Unit), aus. Es wurde als open-source Projekt veröffentlicht und ist weit verbreitet. Keras bietet die in dieser Arbeit benötigten Algorithmen an, weshalb es zum Trainieren von FFNNs verwendet wird.

3.2 Training von KNNs

Um die Zielfunktion f^* zu approximieren ist eine Kostenfunktion nötig, die den Abstand von der approximierten Funktion zur approximierenden Funktion angibt [Nie15]. Im Optimierungsprozess wird die Kostenfunktion minimiert. Oft wird die Kostenfunktion auch als *Verlustfunktion* (engl. *loss function*), *Fehlerfunktion* (engl. *error function*), oder *Zielfunktion* (engl. *objective function*) bezeichnet [BGC17]. Je nach Publikation können einige dieser Funktionen spezielle Bedeutungen haben, in dieser Arbeit haben sie aber die gleiche Bedeutung.

Das KNN wird für eine endliche Anzahl an Trainingsdurchläufen trainiert [Nie15]. Ein Trainingsdurchlauf einer Trainingsmenge wird als Epoche bezeichnet. Als *Backpropagation* wird der Algorithmus bezeichnet, der mit Hilfe des Lernalgorithmus den Fehler der Kostenfunktion rückwärts durch die Schichten des KNN propagiert, wodurch die Parameter θ angepasst werden. Der Lernalgorithmus steuert dabei, wie in dieser Epoche die Parameter mit den Trainingsdaten aktualisiert werden. Zu den Parametern gehört die Struktur des neuronalen Netzwerks, Aktivierungsfunktionen, Gewichte und Biase.

3 KÜNSTLICHE NEURONALE NETZE

Abhängig von der Strategie des Lernalgorithmus müssen die Gradienten rückwärts, rekursiv Schicht für Schicht zurück propagiert werden. Ziel ist es den Fehler unter Berücksichtigung der Parameter zurück zu propagieren. Dafür ist es nötig die Ableitungen von der Kostenfunktion zu den Parametern zu berechnen. Gleichung 3.3 zeigt, dass das Ergebnis einer Schicht die Aktivierung der gewichteten Summe des Ergebnisses der jeweiligen vorherigen Schicht ist. Um die Ableitungen unter Berücksichtigung der Parameter zu berechnen ist die Anwendung der Kettenregel nötig.

Angefangen mit dem Gradienten der Aktivierungen der Ausgabeschicht, wird der Fehler rekursiv zurück propagiert. Dabei wird in jeder Schicht die Korrektur auf die Parameter addiert. Anschließend kann der Vorgang für nächste Epoche wiederholt werden.

3.3 Lernalgorithmen

Die Lernalgorithmen bestimmen die Strategie, mit der die Parameter θ des KNN aktualisiert werden [HH19]. In dieser Arbeit wird ADAM verwendet, da dieser Algorithmus die Vorteile von (S)GD (Stochastic Gradient Descent) mit Momentum und RMSprop vereinigt [KB17, HH19].



■ Abbildung 3.2: Verschiedene Lernalgorithmen auf der Rosenbrock-Funktion [Ros60].

SGD ist eine Approximation von *Gradient Descent* (GD) [BGC17]. GD ist ein iterativer Algorithmus, der den Gradienten in Richtung des Extremum folgt und dementsprechend die Eingabeparameter aktualisiert.

In (3.4) wird der iterative Prozess zur Minimierung im eindimensionalen Fall gezeigt, wobei $\eta > 0$ eine angemessene *Lernrate*, θ der Eingabeparameter und C die Kostenfunktion ist. Ist die Lernrate zu groß könnte keine Verbesserung beobachtet werden, da das Maxima immer übersprungen wird. Ist die Lernrate zu klein könnte die Konvergenz sehr langsam sein. Wenn ein Sattelpunkt erreicht wird ist der Gradient 0. Aus diesem Grund können mit dieser Technik globale Extremum verfehlt werden.

$$\theta_{k+1} := \theta_k - \text{sign}(C'(\theta_k))\eta \quad (3.4)$$

Im mehrdimensionalen Fall (3.5) wird für jede Komponente des Eingabevektors dieser Prozess durchgeführt, sodass für jede Komponente die Richtung des Extremum verfolgt wird. Dies impliziert, dass GD für Eingabevektoren mit hohen Dimensionen sehr aufwendig zu berechnen ist.

$$\theta_{k+1} = \theta_k - \bigtriangledown C(\theta_k)\eta \quad (3.5)$$

Diese Methode konvergiert, wenn alle Komponenten des Gradienten 0 sind. Je größer die Dimension des Eingabevektor ist, desto aufwendiger ist die Berechnung.

SGD ist eine Approximation von GD. Es nutzt eine zufällige Teilmenge des Eingabevektors, den sogenannten *Mini-Batch*. Es wird angenommen, dass der Gradient des Mini-Batches ähnlich zum Gradienten des gesamten Eingabevektors ist. Folglich werden mit jedem Mini-Batch die Parameter des KNN aktualisiert, wodurch in jeder Epoche die Parameter mehr als einmal aktualisiert werden. Ziel dieser Approximation ist eine Laufzeitverbesserung.

(S)GD mit Momentum (3.6) versucht zu vermeiden, dass lokale Extremum gefunden werden anstatt globale Extremum, indem Momentum aus vorherigen Gradienten beibehalten wird, um aus lokalen Extremum wieder raus zu finden [HH19].

$$\mathbf{v}_{-1} = \mathbf{0}, \quad \mathbf{v}_k = \mathbf{v}_{k-1}\gamma + \bigtriangledown C(\theta_k), \quad \theta_{k+1} = \theta_k - \mathbf{v}_k\eta \quad (3.6)$$

Zur Berechnung wird ein Hilfsvektor \mathbf{v} verwendet, welcher das Momentum vergangener Gradienten darstellt. In jeder Iteration fließt ein Anteil γ , typischerweise $\gamma = 0.9$, vom Hilfsvektor in die Berechnung der neuen Eingabeparameter ein. Der Unterschied zu GD (3.5) ist der Anteil vergangener Gradienten.

3 KÜNSTLICHE NEURONALE NETZE

RMSprop ist eine Generalisierung von *Adagrad* [?]. Adagrad passt die Lernrate η an, sodass Komponenten des Eingabevektors die überrepräsentiert sind eine geringere Lernrate erhalten und unterrepräsentierte Komponenten eine im Verhältnis größere Lernrate [DHS11]. In (3.7) wird Adagrad skizziert, wobei sich iterativ die Lernrate antiproportional zur kummulierte Norm der Gradienten der Kostenfunktion verringert [LF19, KB17]. Dabei wird für ϵ eine kleine Zahl gewählt, um Teilen durch 0 zu vermeiden aber keinen signifikanten Einfluss auf die Berechnung zu haben.

$$\mathbf{g}_k = \nabla C_{j_k}(\boldsymbol{\theta}_k), \quad \mathbf{w}_k = \mathbf{w}_{k-1} + \mathbf{g}_k^2, \quad \boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \mathbf{g}_k \circ \frac{\eta}{\sqrt{\mathbf{w}_k + \epsilon}} \quad (3.7)$$

Das Problem an Adagrad ist, dass die Lernrate zu schnell gegen 0 konvergieren kann, wodurch das Zielextrema nicht erreicht wird [BGC17]. RMSprop [HSS12] (3.8) löst dieses Problem, indem anstatt die Gradienten zu summieren, ein exponentiell gewichteter gleitender Mittelwert verwendet wird [BGC17].

$$\begin{aligned} \mathbf{w}_{-1} &= \mathbf{0}, & \mathbf{g}_k &= \nabla C_{j_k}(\boldsymbol{\theta}_k) \\ \mathbf{w}_k &= \mathbf{w}_{k-1}\gamma + \mathbf{g}_k^2(1-\gamma), & \boldsymbol{\theta}_{k+1} &= \boldsymbol{\theta}_k - \mathbf{g}_k \circ \frac{\eta}{\sqrt{\mathbf{w}_k + \epsilon}} \end{aligned} \quad (3.8)$$

Adam (3.9) vereint RMSprop und (S)GD mit Momentum, wobei $\gamma_1 < \gamma_2 < 1$ [KB17] ist. Adam beinhaltet RMSprop und hat eine Momentum Komponente, indem das Moment der ersten Ordnung mit exponentieller Gewichtung approximiert wird [BGC17]. Zudem korrigiert Adam den Bias das Momente der ersten und zweiten Ordnung der durch die Initialisierung entsteht.

$$\begin{aligned} \mathbf{v}_{-1} &= \mathbf{w}_{-1} = \mathbf{0}, & \mathbf{g}_k &= \nabla C_{j_k}(\boldsymbol{\theta}_k) \\ \mathbf{v}_k &= (\mathbf{v}_{k-1}\gamma_1 + \mathbf{g}_k(1-\gamma_1))/(1-\gamma_1^k) \\ \mathbf{w}_k &= (\mathbf{w}_{k-1}\gamma_2 + \mathbf{g}_k^2(1-\gamma_2))/(1-\gamma_2^k) \\ \boldsymbol{\theta}_{k+1} &= \boldsymbol{\theta}_k - \mathbf{v}_k \circ \frac{\eta}{\sqrt{\mathbf{w}_k + \epsilon}} \end{aligned} \quad (3.9)$$

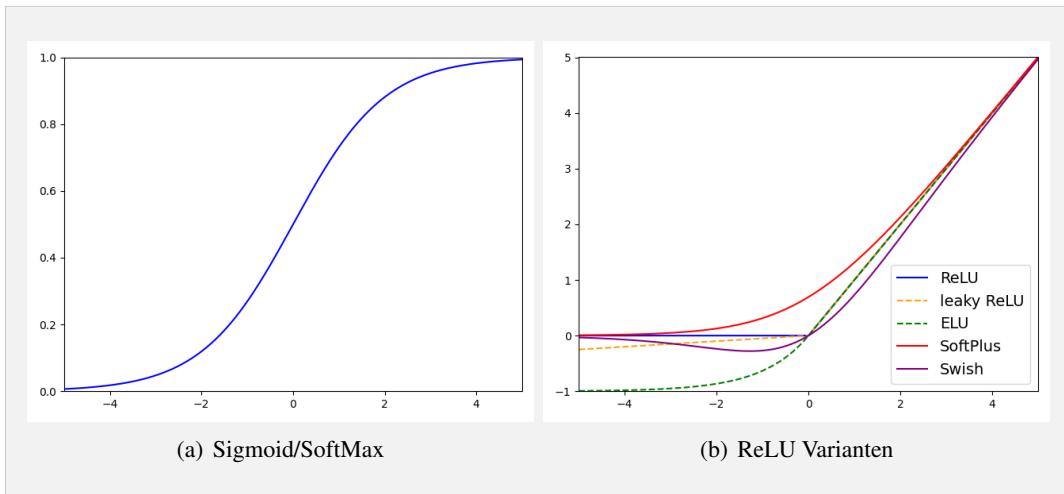


Abbildung 3.3: Für diese Arbeit relevante Aktivierungsfunktionen.

3.4 Aktivierungsfunktionen

Die Aktivierungsfunktion entscheidet ob ein Neuron aktiviert wird oder nicht [NIGM18]. Sie können entweder linear oder nicht-linear sein. Es ist aber nötig nicht-lineare Funktionen zu verwenden, damit jede kontinuierliche Funktion approximiert werden kann [ADIP21]. Sie unterscheiden sich in ihren Eigenschaften und Berechnungskosten, was eine besondere Rolle für Mikrocontroller spielt.

In der frühen Geschichte der neuronalen Netzwerke wurde die *Sigmoid*-Funktion (3.10) viel verwendet, da sie asymptotisch begrenzt, kontinuierlich und nicht-linear ist [ADIP21]. Heute wird sie oft in der Ausgabeschicht für binäre Klassifizierungsprobleme eingesetzt [NIGM18]. Allerdings ist sie für tiefe neuronale Netzwerke ungeeignet, da der Gradient zwischen 0 und 0.25 ist und dadurch im Backpropagation-Prozess bereits nach wenigen Schichten gegen 0 geht. Die *SoftMax*-Funktion (3.11) oder normalisierte Exponentialfunktion berechnet für einen Eingabevektor eine Wahrscheinlichkeitsverteilung. Die Einträge dieser Verteilung können für die Wahrscheinlichkeiten der einzelnen Klassen eines multivariat Klassifizierungsproblem interpretiert werden.

$$\text{sigmoid}(x) = \frac{1}{1+e^{-x}} \quad (3.10)$$

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (3.11)$$

3 KÜNSTLICHE NEURONALE NETZE

Zur *ReLU*-Familie [ADIP21] gehört die *ReLU*-Funktion [GBB11, KMK15, EUD18, Alc18] und ihre Varianten [MHN13], sowie die *SoftPlus*- [DBB⁺01] und *Swish*-Funktion [RZL17]. *ReLU* (3.12) steht für „*rectified linear function*“ und wird häufig in modernen neuronalen Netzwerken verwendet [ADIP21]. Sie ist nicht differenzierbar bei 0 und die Ableitung für negative Eingaben ist 0. Dies kann zu *sterbenden Neuronen* (*engl. dying neurons*) führen, da der Bias so negativ wird, sodass das Neuron nicht mehr aktiviert wird. Zudem ist der Trainingsprozess verlangsamt, wenn der Gradient konstant 0 ist. Dafür ist die Ableitung der Funktion ansonsten 1, was den Backpropagation-Prozess vereinfacht, da der Gradient neutral zur Aktivierungsfunktion ist.

$$\text{ReLU}(x) = \max(x, 0) \quad (3.12)$$

Varianten sind beispielsweise *leaky ReLU* [MHN13] (3.13) und *ELU* (*exponential linear unit*) (3.14) [CUH16], welche versuchen die Defizite des konstanten 0 Gradienten zu lösen, indem der negative Teil der Funktion nicht 0 ist.

$$\text{leaky_ReLU}_\alpha(x) = \begin{cases} x & , \text{wenn } x \geq 0 \\ \alpha x & , \text{ansonsten } (\alpha \in \mathbb{R}_0^+) \end{cases} \quad (3.13)$$

$$\text{ELU}_\alpha(x) = \begin{cases} x & , \text{wenn } x \geq 0 \\ \alpha(e^x - 1) & , \text{ansonsten } (\alpha \in \mathbb{R}_0^+) \end{cases} \quad (3.14)$$

SoftPlus (3.15) ist analytisch, dafür im Vergleich zu *ReLU* aufwendiger zu berechnen ist [ADIP21].

$$\text{softplus}(x_i) = \ln(e^x + 1) \quad (3.15)$$

Eine weitere Variante ist *Swish* [RZL17] (3.16). Sie ist analytisch aber nicht monoton. Im Vergleich zu *ReLU* ist sie aufwendig zu berechnen. Ihre Autoren behaupten aber, dass dadurch bessere Ergebnisse erzielt werden können, ohne andere Parameter zu ändern.

$$\text{swish}(x_i) = \frac{x e^x}{e^x + 1} \quad (3.16)$$

3.5 Ressourcenbedarf auf dem Mikrocontroller

Der Speicherverbrauch eines neuronalen Netzes ist abhängig von der Anzahl der Gewichte und Biase, sowie der Größe des verwendeten Datentypen [Kub19]. Ein FFNN mit 3 Schichten der Größe n_1, n_2, n_3 hat $n_1n_2 + n_2n_3$ Gewichte und $n_2 + n_3$ Biase. Die Gewichte und Biase sind für gewöhnlich Gleitkommazahlen. Diese können mit 4 und 8 Byte dargestellt werden. Als Alternative können auch Festkommazahlen verwendet werden, die 2 Byte benötigen [Gie20].

Die Ausführungszeit des KNN ist stark abhängig von der Hardware. Das KNN kann sowohl im RAM abgelegt werden oder im Flash-Speicher [Eng18]. Wenn es im Flash-Speicher abgelegt werden muss, müssen die Gewichte bei der Ausführung in den RAM und die Register geladen werden. In Yao's Experimenten hat dies die Ausführungszeit um bis zu 74% verlangsamt [Jia17].

Außerdem wird Multiplikation und Division zur Evaluierung des KNNs benötigt [Eng18]. Wenn die Hardware keine Unterstützung dafür anbietet, müssen diese Operationen durch Software ergänzt werden. Diese sind dann signifikant komplexer zu berechnen im Vergleich zu hardwareunterstützten Operationen.

Die Ausführungszeit ist auch abhängig von der Struktur des Netzwerkes [Gie20]. Je mehr Gewichte ein KNN hat, desto mehr Multiplikationen müssen durchgeführt werden. Zudem wird in jeder Schicht eine Aktivierungsfunktion angewendet, die ebenfalls sehr aufwendige Berechnungen benötigen kann [VKK⁺20].

Es gibt verschiedene Optimierungen, die die Ausführungszeit und den Speicherbedarf verringern. Giese hat in seiner Arbeit festgestellt, dass das Löschen von Gewichten (engl. pruning) oder das Gruppieren von ähnlichen Gewichten (engl. quantization) signifikante Verbesserungen sowohl des Speicherverbrauchs als auch bei der Ausführungszeit zeigt [Gie20]. Denkbar sind auch Compiler-Optimierungen, die sich sowohl auf Ausführungszeit, Speicherbedarf und Energiebedarf auswirken können. Giese stellte fest, dass sowohl der Speicherbedarf verringert werden kann, als auch die Ausführungszeit.

Um den Energieverbrauch zu bestimmen ist ein Energiemodell nötig, das den Energieverbrauch von einzelnen Instruktionen im Zusammenhang mit Speicher und Caches genau beschreibt [RLF18]. Diese sind aber durch die Komplexität moderner Architekturen nicht verfügbar oder ungenau. Allgemein kann jedoch der Energieverbrauch proportional zur Ausführungszeit betrachtet werden [CGSS14].

3 KÜNSTLICHE NEURONALE NETZE

Standortbestimmung

Als Standortbestimmung, oder *Lokalisierung*, wird der Prozess bezeichnet die Position von einem Gerät oder Nutzer in einem Koordinatensystem zu bestimmen [BHE00]. Unterschieden wird dabei zwischen *Indoor-* und *Outdoor-Lokalisierung* [ZGL19, BHE00]. Bei Indoor-Lokalisierung wird ein Szenario innerhalb von Gebäuden betrachtet und bei Outdoor-Lokalisierung ein Szenario unter dem freien Himmel.

Weiterhin wird unterscheiden zwischen *Device-Based-* und *Device-Free-Lokalisierung* [XZYN16]. Bei Device-Based-Lokalisierung bestimmt das Gerät selbst die Position, wohingegen bei der Device-Free-Lokalisierung die Position von einer Infrastruktur bestimmt wird.

4.1 Orientierungssinn von Menschen und Tieren

Lokalisierung ist aber nicht nur beschränkt auf Geräte. Menschen und Tiere haben einen Orientierungssinn, der die Navigation anhand von Orientierungspunkten ermöglicht [KSA17, MGC⁺96]. Beispielsweise hängt die Navigation von Honigbienen stark von den Orientierungspunkten ab [MGC⁺96]. Anstatt die direkte Route zu wählen, fliegen Honigbienen die Orientierungspunkte ab, um zu ihrem Ziel zu gelangen. Dabei ist die Navigation robust gegenüber leichten Veränderungen der Orientierungspunkte.

Neben Honigbienen zeigen Vögel, Insekten oder Meereslebewesen verschiedene Arten von Navigation durch Ausnutzen ihrer Sinne [ABLM14]. So gibt es Vögel und Insekten, die anhand der Position der Sonne und ihrer inneren Uhr navigieren. Nachtaktive Singvögel hingegen scheinen sich anhand der Sterne zu orientieren. Viele Tiere haben auch einen Sinn, um das Magnetfeld der Erde wahrzunehmen und navigieren basierend auf diesem magnetischen Kompass.

4 STANDORTBESTIMMUNG

4.2 Indoor- und Outdoor-Lokalisierung

GPS ist eine weit verbreites Standortbestimmungssystem im Outdoor-Kontext und kann für eine Vielzahl von Anwendungen eingesetzt werden, z. B. Tracking, Navigation oder Rettungsaktionen [KH05]. Es skaliert zu einer arbiträren Anzahl von Nutzern, da es einen device-based Ansatz verwendet. Die Geräte berechnen aus den empfangenden Signalen von mehreren Satelliten ihre Position. Dabei ist die Standortbestimmung bis zu 5 m genau [SS18], wobei es Varianten gibt, die noch bessere Auflösungen erzielen können [PE96]. Der Energieverbrauch ist sehr hoch [JCC⁺13], wodurch es ungeeignet für kleine batteriegestützte Systeme ist. In einem Indoor-Kontext kann GPS aber meistens nicht eingesetzt werden, da das Gebäude die benötigte Signalstärke zu den Satteliten beeinträchtigen kann [XZYN16, JLP06]. Aus diesem Grund ist es für batteriegestützte Mikrocontroller im Indoor-Bereich suboptimal.

Indoor-Lokalisierung bedarf meist einer hohen Auflösung, muss sicherheitskritische Vorgaben einhalten, energieeffizient sein, skalierbar sein und geringe Kosten haben [XZYN16]. Es gibt verschiedene Ansätze, die entweder device-based oder device-free sind.

Device-based Ansätze nutzen die Sensoren des Geräts, um die Position zu bestimmen [XZYN16]. Beispielsweise können visuelle Features mit der Kamera extrahiert werden [PH19, CPC⁺11], RSS Messungen des WiFi Netzwerkes durchgeführt werden [PZYH08], Bewegungs- oder Lichtsensoren verwendet werden [PH19, WYM18, XZYN16]. Der Vorteil sind die geringen Infrastrukturkosten [XZYN16].

Device-free Ansätze bedürfen einer Infrastruktur, um Objekte im Interessebereich wahrzunehmen [XZYN16]. Diese werden zum Beispiel für Überwachungsszenarien eingesetzt [QWZ⁺18]. Ansätze nutzen beispielsweise die bestehende Kamerainfrastruktur aus [KBP⁺19], WiFi basierte Ansätze [QWZ⁺18], Infrarot basierte Ansätze [KH10] oder RFID basierte Ansätze [YLL⁺15].

4.3 WiFi basierte Indoor-Lokalisierung mit Transfer Lernen

Pan et al. untersuchten Indoor-Lokalisierung basierend auf WiFi RSS Daten [PZYH08]. Der Empfänger misst die *Received Signal Strength* (RSS) mehrerer Sender. Dadurch steht ein Vektor von Signalstärken zur Verfügung aus dem die Position approximiert werden kann.

Pan et al. stellen fest, dass bei ML Ansätzen oft zwei Annahmen getroffen werden. Zum einen wird eine *Offline*-Phase vorausgesetzt mit ausreichend beschrifteten Daten, d. h. eine Trainingsphase bevor das Modell eingesetzt wird. Zum anderen wird angenommen, dass das gelernte Modell statisch über Zeit, Raum und Geräte ist.

In der Praxis können sich Modelle jedoch über die Zeit ändern, z. B. wenn Mitarbeiter Mittags zur Kantine gehen. Es kann schwierig sein ausreichend Daten für große Gebäude zu sammeln. Verschiedene Geräte können verschiedene Sensorwerte erfassen. Dies führt zu einen erheblichen Kalibrierungsaufwand der ML Modelle.

Pan et al. schlagen Transfer Learning vor, um dieses Problem zu lösen. Transfer Learning befasst sich mit dem Problem, wenn Trainings- und Testdaten verschiedener Verteilungen folgen oder in verschiedenen Feature-Räumen repräsentiert sind. Die gewonnene Erfahrung beim Training soll dabei auf das neue, ähnliche Problem übertragen werden. Dafür müssen Beziehungen gefunden werden, die den Erfahrungstransfer ermöglichen.

Sie trainierten ein *Hidden Markov Model* (HMM), wobei die Ortserkennung als Klassifizierungsproblem diskreter Orte modelliert wurde. Auf ihren Testdaten waren sie signifikant besser als Ansätze ohne Transfer Learning.

4.4 Indoor-Lokalisierung mit Magnet- und Lichtsensoren

Wang et al. haben einen Indoor-Lokalisierungsansatz untersucht, der Magnetfelddaten und Lichtsensordaten eines Smartphones nutzt, um die Position des Gerätes zu bestimmen [WYM18]. In einem Vorverarbeitungsschritt kombinieren die Autoren Magnetfelddaten und Lichsensordaten. Damit wird ein Deep LSTM (**L**ong **S**hort **T**erm **M**emory NN) trainiert.

Die Autoren merken an, dass viele Ansätze RSS oder CSI (**C**hannel **S**tate **I**nformation) nutzen, um Indoor-Lokalisierungsmodelle zu generieren. Diese sind aber unzerverlässig, wenn die Signalstärke schlecht ist oder nicht verfügbar, z. B. in einem Parkhaus. Dahingegen ist das Magnetfeld und Licht omnipresent. Die Magnetfelddaten weisen eine geringe Varianz auf.

4 STANDORTBESTIMMUNG

Diskrete Orte können aber durch Anomalien unterschieden werden, die durch Interferenz von Gebäuden und Geräten verursacht wird. Licht ist ebenfalls meistens vorhanden und weist Unterschiede durch Intensität und Form der Lampe, sowie Schatten und Reflektion auf. Durch die Kombination dieser Daten können eine Vielzahl von diskreten Orten unterschieden werden.

Die Autoren verglichen zwei Szenarien. Das erste Szenario ist ein Labor, welches viele Tische, Stühle und Computer enthält. Das zweite Szenario ist ein langer Korridor. In ihren Ergebnissen ist in beiden Szenarien der Fehler zum größten Teil unterhalb 0,5 m. Der größte Fehler betrug im Labor 3,7 m und im Korridor 6,5 m. Im Vergleich zu einem Modell, dass lediglich die Magnetfelddaten nutzt, erwies sich das Modell, das die Kombination nutzte, als deutlich besser.

4.5 Sensorbasierter Orientierungssinn mit FFNN

Dieser Arbeit ging die Arbeit von Mian voran, der sich zum gleichen Thema mit FFNN auseinander gesetzt hat [Mia21]. Mian nutzte den Simulator CoppeliaSim, um Daten von verschiedenen komplexen Routen zu generieren. Die Routen unterschieden sich dabei in der Anzahl verschiedener Orte und Pfade die für einen Zyklus einer Route verwendet werden können. Die aufgenommenen Daten enthalten Sensorwerte für Beschleunigung, Gyroskop, Licht und Beschriftungen für die Standorte. Dabei werden als Standorte die Teilstücke der Routen bezeichnet aus denen die Route zusammengesetzt ist.

Mian entschied sich die aufgenommen Sensordaten vorzuverarbeiten. Zunächst werden die Sensoren für fünf Stichproben über den Median geglättet. Aus den resultierenden Sensorwerten wird die Veränderung zum vorherigen Sensorwert für jeden Sensor ermittelt. Für jeden Sensor wird als Feature der Betrag dieser Differenz verwendet. Um Muster aus einer Folge von Feature-Mengen zu inferieren hat Mian ein Datenfenster eingeführt, über das hintereinander liegende Feature-Mengen zu einer Feature-Menge konkatiniert werden. Zudem werden die zuletzt besuchten Standorte in Form einer exponentiell fallenden Funktion über die Zeit als weitere Features hinzugefügt.

4.5 SENSORBASIERTER ORIENTIERUNGSSINN MIT FFNN

Mit dieser Eingabe trainierte Mian ein FFNN mit einer Rückwärtskante (FBNN) von der Ausgabe- zur Eingabeschicht, um die zuletzt bestimmten Standorte als Features nutzen zu können. Die Rückwärtskante wurde im Training simuliert, indem die Trainingsdaten in zwei Teilmengen partitioniert wurden. Mit der ersten Teilmenge wurde das FFNN mit korrekt beschrifteten Trainingsdaten trainiert. Das trainierte FFNN wurde dann genutzt, um die Standorte der zweiten Teilmenge zu bestimmen. Daraufhin wurde das FFNN mit der zweiten Teilmenge trainiert, bevor es auf einer Testmenge validiert wurde.

Mian unterscheidet vier Modellarchitekturen: FFNN, FBNN, WFFNN (FFNN mit sensorisches Gedächtnis) und WFBNN (FBNN mit sensorisches Gedächtnis). Er stellte fest, dass das FFNN nicht in der Lage war verschiedene Standorte zu unterscheiden, unabhängig von der Anzahl der verdeckten Schichten und dessen Anzahl von Neuronen.

Das FBNN hingegen konnte bei einer Route mit einem Pfad und sechs Standorten Testgenauigkeiten von bis zu 98,12% erzielen. Allerdings bedarf es dafür zwei verdeckte Schichten mit jeweils 64 Neuronen. Mit weniger Schichten oder Neuronen wurden deutlich schlechtere Ergebnisse erzielt. Bei mehr Pfaden und Standorten wurden ebenfalls schlechtere Ergebnisse erzielt, obwohl Anzahl der Neuronen pro verdeckte Schicht auf 256 erhöht wurde. Bei einer Route mit zwei Pfaden und neun Standorten wurden Testgenauigkeiten von 85,56% erzielt und bei drei Pfaden und 14 Standorten wurden Testgenauigkeiten von 33,57% erzielt.

Mit der Einführung eines Datenfensters (WFFNN und WFBNN) hat sich die Klassifizierungsgenauigkeit signifikant erhöht. Ein WFFNN mit zwei verdeckten Schichten mit jeweils 64 Neuronen und einem sensorischen Gedächtnis von 50 konnte eine Testgenauigkeit von 99,13% bei einem Pfad und sechs Standorten erreichen. Die Testgenauigkeiten bei zwei Pfaden und 9 Standorten war 94,41%. Bei drei Pfaden und 14 Standorten wurde mit einer verdeckten Schicht mit 56 Neuronen und einem sensorischen Gedächtnis von 200 mit dem WFFNN 94,51% erzielt und mit dem WFBNN 93,26%.

Mian stellte fest, dass sich die Klassifizierungsgenauigkeiten besser sind, wenn eine Lichtquelle an Standorten gesetzt wird, an denen sich die neuronalen Netze unsicher sind. Allerdings würden Fehler durch den Sensor oder Veränderungen der Lichtverhältnisse einen größeren Einfluss auf die Klassifizierungsgenauigkeit des Modells haben.

Mian konklidierte, dass ein Kompromiss zwischen Klassifizierungsgenauigkeit und Modellgröße geschlossen werden müsste, da die Modellgröße und Klassifizierungsgenauigkeit proportional mit der Anzahl der verdeckten Schichten und Neuronen, sowie der Datenfenstergröße zusammenhinge.

4 STANDORTBESTIMMUNG

Machine Learning Modelle

In dieser Arbeit wird die Device-Based Indoor-Lokalisation auf Basis von Sensorwerten untersucht. Der Ansatz ist inspiriert vom Orientierungssinn von Menschen und Tieren. Dabei werden diskrete Standorte unterschieden, sowie ob eine Anomalie entdeckt wurde, d. h. ob das Modell sich an einem unbekannten Standort oder auf einem unbekannten Pfad befindet.

Abbildung 5.1 zeigt die Architektur des verfolgten Ansatzes. Zunächst werden aus den Sensorwerten Features extrahiert. Die resultierende Feature-Menge wird dann vom ML-Modell genutzt, um den Standort zu klassifizieren. Zuletzt wird auf Basis historischer Daten und dem Klassifizierungsergebnis von einem weiteren ML-Modell zur Anomalieerkennung bestimmt, ob eine Anomalie vorliegt.




Abbildung 5.1: Architektur des verfolgten Ansatzes.

Mian verwendete eine ähnliche Architektur [Mia21]. Sein (W)FBNN zur Standortbestimmung hatte ebenfalls eine Rückwärtskante, um die zuletzt erkannten Standorte als Features zu verwenden. Die gestrichelte Linie signalisiert, dass, ähnlich zu Mian, auch ML-Modelle ohne Rückwärtskante evaluiert werden. In dieser Arbeit wird zusätzlich versucht Anomalien zu erkennen. Dafür wird ein weiteres ML-Modell verwendet, welches aus dem Klassifizierungsverhalten des ML-Modells zur Standortbestimmung schließt, ob eine Anomalie vorliegt. Dies motiviert die Erweiterung, um eine weitere Phase zur Feature-Extrahierung aus den zuletzt erkannten Standorten, sowie einer Phase zur Evaluierung des ML-Modells zur Anomalieerkennung aus der resultierenden Feature-Menge.

5 MACHINE LEARNING MODELLE

Die Anomalieerkennung interpretiert somit das Standortbestimmungsverhalten des vorangestellten ML-Modells zur Standortbestimmung, weshalb sowohl der Standort als auch die Einschätzung der Anomalie als Ergebnis zurückgegeben werden.

In dieser Arbeit werden Entscheidungsbaum basierte Klassifizierer mit FFNNs verglichen, insbesondere den von Mian verwendeten Ansatz des FBNNs. Entscheidungsbäume sind deutlich effizienter in der Ausführungszeit als FFNNs [Dym21], allerdings sind sie in ihrer Generalisierungsfähigkeit durch die berechneten Features begrenzt, wohingegen FFNNs komplexe Features selbst erlernen können [SLCY11].

5.1 Standortkodierung

Als Standort wird ein einzigartiger diskreter Ort im Indoor-Szenario bezeichnet. Bei der Klassifizierung können Standorte auf verschiedene Arten im ML-Modell kodiert werden. Mian kodierte die Pfade zwischen Punkten, die von Interesse sind, als Standorte, d. h. das Klassifizierungsergebnis ist der Pfad auf dem sich der Mikrocontroller befindet [Mia21].

In dieser Arbeit wird neben der Erkennung von Pfaden auch die Erkennung von Knoten, sowie die Erkennung von Pfaden und Knoten untersucht. Pfade und Knoten liegen auf Routen, die als zyklischen Graphen betrachtet werden können, wie in Abbildung 5.2 illustriert. Der Ansatz von Mian versucht die Kanten dieses Graphen zu klassifizieren und definiert diese als Standorte [Mia21]. Daneben können auch nur die Knoten als Standorte kodiert werden und alle restlichen Datensätze als *unbekannten Standort*. Zuletzt können sowohl die Knoten und Kanten als Standorte definiert werden. Die Knoten werden durch alle Datensätze dargestellt, die innerhalb eines Umkreises von einem Punkt sind, der von Interesse ist. Folglich befinden sich alle restlichen Datensätze auf Kanten zwischen zwei Knoten oder gelten als *unbekannt*. In dieser Arbeit wird der Kodierungsansatz, der nur Kanten kodiert, nicht untersucht, da Mian diesen Ansatz bereits untersucht hatte.

Daraus wird die Komplexität und Genauigkeit dieser Ansätze deutlich. Der Kantenansatz ist ein Kompromiss zwischen Genauigkeit und Komplexität. Dabei bestimmt die Anzahl der zu klassifizierenden Standorte die Komplexität. Zum einen ist gerade bei langen Pfaden eine geringe Auflösung im Vergleich zur Realposition der Sensorbox zu erwarten, d. h. es ist unklar, ob sich die Sensorbox am Anfang, Ende oder in dazwischen befindet. Zum anderen werden in einem zyklischen Graphen mindestens so viele Standorte, wie beim Knotenansatz verwendet. Der Knotenansatz benötigt am wenigsten Standorte zur Kodierung ist aber außerhalb der Standorte sehr ungenau.

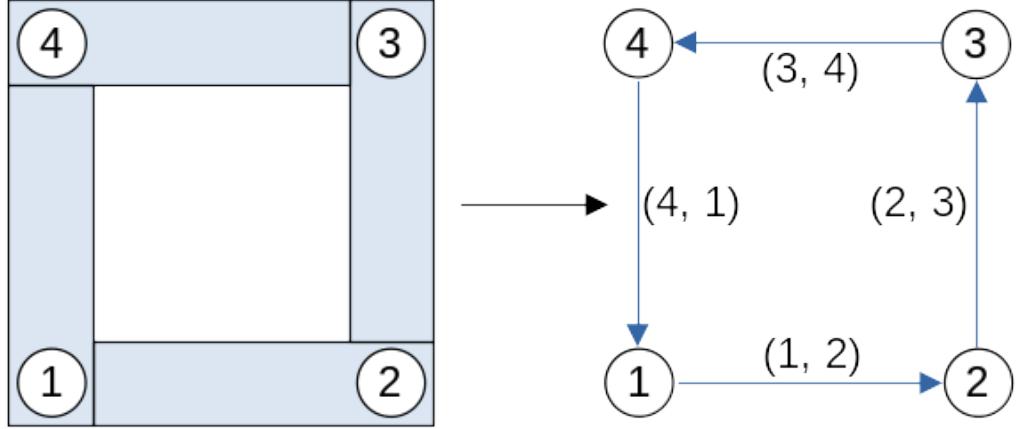


Abbildung 5.2: Standortkodierung der Knoten und Pfade.

Aus einer Historie von vorherigen Standorten kann aber ein möglicher Pfad inferiert werden, auf dem sich die Sensorbox befindet. Allerdings können auch mehrere Pfade in Frage kommen, z. B. bei einer Gabelung. Der kombinierte Ansatz kodiert so viele Standorte, wie beide Ansätze zusammen, wodurch dieser Ansatz am komplexesten ist und am schlechtesten für große Routen skaliert. Dafür ist die Auflösung des kombinierten Ansatzes so gut, wie eine diskrete Kodierung es zulässt.

Ist in den aufgenommenen Trainingsdaten die Position der Sensorbox zum Zeitpunkt der Aufnahme der Sensorwerte bekannt, so können die Standorte nach dem gewählten Kodierungsansatz beliebig genau beschriftet werden. Dies kann in einem Weiterverarbeitungsschritt nach der Aufnahme der Daten mit einer Karte von Punkten, die von Interesse sind, geschehen.

5.2 Entscheidungswald

Entscheidungsbaum basierte Klassifizierer sind sehr effizient und können trotzdem hohe Klassifizierungsgenauigkeiten bei hohen Fehlertoleranzen erreichen [Dym21]. Entscheidungswälder erhöhen die Klassifizierungsgenauigkeit während die Varianz reduziert wird, dafür wird aber der Speicherbedarf mit jedem Baum linear erhöht. Der Klassifizierer soll zukünftig auf einem Mikrocontroller ausgeführt werden, d. h. die Größe des Entscheidungswaldes ist durch den Programmspeicher des Mikrocontrollers limitiert. Zum Zeitpunkt, zu der diese Arbeit verfasst wird, sind die Limitierungen des Mikrocontrollers noch nicht bekannt. Für gewöhnlich ist der Programmspeicher aber auf wenige Kilobyte beschränkt [Dym21].

5 MACHINE LEARNING MODELLE

Als Ensemble-Methode wird der *RandomForest* benutzt, da dieser Entscheidungsbäume auf Basis von zufälligen Teilmengen der Feature-Menge konstruiert. Dadurch ist eine erhöhte Toleranz gegenüber Fehlern, wie fehlerhafte Sensorwerte oder anderen Features zu erwarten.

Um den Einfluss von verschiedenen Wald- und Baumgrößen auf die Klassifizierungsgenauigkeit hin zu untersuchen, werden verschiedene Größen trainiert und auf den Testmengen evaluiert. Trotzdem wurden Dimensionen in einem Bereich gewählt, die für einen Mikrocontroller realistisch sind. Es wurden jeweils Bäume und Wälder der Größe 8, 16, 32, und 64 untersucht.

5.3 Feed Forward neuronales Netzwerk

Für das KNN wird ein Feed Forward neuronales Netzwerk verwendet. Das FFNN besteht aus drei bis sechs Schichten. Alle Schichten, außer der letzten, verwenden ReLU als Aktivierungsfunktion. Die letzte Schicht verwendet SoftMax.

Die Größe der Eingabeschicht ist abhängig von der Anzahl der verwendeten Features. Die Features werden in einem Vorverarbeitungsschritt im Gegensatz zum Entscheidungswald normalisiert. Die Größe der Ausgabeschicht ist die Anzahl der verschiedenen diskreten Standorte, die unterschieden werden. Je nach Konfiguration gibt es eins, zwei oder vier verdeckte Schichten, die jeweils 16, 32, 64 oder 128 Neuronen haben.

Die Standorte sind kategorische Daten, d. h. ihr Werte haben keine Aussage über die Beziehung der Standorte zueinander. Aus diesem Grund werden sie kategorisch kodiert, d. h. aus einem Wert i aus N möglichen Werten wird eine Liste der Größe N generiert, die überall 0 ist außer an der Stelle i , die 1 ist. Folglich wird als Kostenfunktion *kategoriale Crossentropy* verwendet. Als Lernalgorithmus wird Adam verwendet mit einer Batch-Größe von 50. Trainiert wird über 75 Epochen.


5.4 Training der ML-Modelle

Typischerweise haben weder Entscheidungsbaum basierte Klassifizierer noch FFNNs Rückwärtspfeile. Neuronale Netze mit Rückwärtspfeilen werden als *rekurrente Netze* (RNN) bezeichnet. Abbildung 5.1 zeigt, dass die Rückwärtspfeile genutzt werden, um das Klassifizierungsergebnis, also den vorherigen Standort, bei der Feature-Extrahierung zu nutzen. Das Klassifizierungsergebnis ist aber nicht immer korrekt, wodurch fehlerhafte Features im Zusam-

5.4 TRAINING DER ML-MODELLE

menhang mit dem Klassifizierungsergebnis als Eingabe in das ML-Modell verwendet werden können. Damit das ML-Modell lernt mit diesem Fehler umzugehen, ist es notwendig, dass das ML-Modell Trainingsbeispiele mit Features auf Basis eigener Klassifizierungsbeispiele zur Verfügung hat.

Abbildung 5.3 illustriert den Trainingsablauf. Die simulierten Daten der aufgenommenen Routen sind unterteilt in Partitionen basierend auf deren Zyklusbewertung, damit in jeder Partition alle Standorte vorhanden sind. Der Zyklus ist ein Umlauf einer Route, bevor sie wiederholt wird. Insgesamt besteht die Datenmenge aus 20 Zyklen. Die ersten fünf Zyklen werden zum „Aufwärmen“ verwendet, d. h. das ML-Modell wird mit korrekt beschrifteten Daten trainiert, welche es nicht selbst beschriftet hat. In den folgenden zehn Zyklen werden weitere Partitionen zur Trainingsmenge hinzugefügt, die mit quadratisch steigendem Anteil vom ML-Modell selbst beschriftet sind. Zunächst werden 50% der Partition i vom ML-Modell beschriftet, bis beim 13. Zyklus schließlich 100% beschriftet wird. Die Elemente aus der Partition, die beschriftet werden sollen, sind zufällig, damit der Klassifizierungsfehler auf allen Teilstücken der Route gelernt werden kann.



■ Abbildung 5.3: Der Trainingsablauf des verfolgten Ansatzes.

5 MACHINE LEARNING MODELLE

Die erste Trainingsphase ist abgeschlossen, nachdem das ML-Modell mit einer Trainingsmenge von 15 Zyklen trainiert wurde. Anschließend wird einmalig eine Feature-Auswahl betrieben, in der insignifikante Features aus der Feature-Menge entfernt werden. Features sind insignifikant, die eine geringe Wichtigkeit aufweisen (Kapitel 7.4). Dies ermöglicht kleinere ML-Modelle zu verwenden und verringert die Dimensionen des Suchraumes, wodurch das Trainieren erleichtert wird. Außerdem müssen Modelle individuell für verschiedene Einsatzgebiete trainiert werden, bei denen möglicherweise einige Sensoren bzw. Features nicht genutzt werden. In Abbildung 5.3 ist die Feature-Auswahl nur einmalig vorgesehen. Denkbar wäre aber auch eine iterative Eliminierung der Features oder Optimierung durch ein evolutionären Algorithmus. Anschließend wird das ML-Modell erneut auf den Partitionen trainiert, bis es validiert und evaluiert werden kann.

Die ML-Modelle ohne Rückwärtskante sind deutlich simpler. Diese müssen nicht in Zyklen trainiert werden, sondern können direkt mit der vollständigen Trainingsmenge trainiert werden, wodurch das Training deutlich effizienter ist.

5.5 Anomalieerkennung

Als Anomalieerkennung wird in dieser Arbeit das Problem bezeichnet, zu erkennen, dass die Sensorbox sich an einem unbekannten Standort oder auf einem unbekannten Pfad befindet. Abbildung 5.1 zeigt, dass die Anomalieerkennung ein eigener Schritt bei der Evaluierung der Sensordaten ist. Die Eingabe sind Features, die auf historischen Daten und dem momentanen Standort basieren.

Es wird ein zweites ML-Modell trainiert, anstatt dem ML-Modell zur Standortbestimmung einen *Anomaliestandort* lernen zu lassen. Dies ist begründet auf der Schwierigkeit Trainingsdaten für Anomalien basierend auf den Sensordaten zu entwickeln, da es unendlich viele Szenarien geben könnte, die als Anomalie zu bezeichnen sind. Stattdessen werden Features genutzt, die eine Abweichung von der Normalität ausdrücken, d. h. das ML-Modell lernt nicht explizite Anomaliepfade, sondern das Verhalten des Standortklassifizierungsmodells einzuordnen.

Dafür werden analog zu Kapitel 5.2 und 5.3 Entscheidungswälder und FFNNs trainiert. Allerdings bedarf dieses Modell keine Rückwärtskante und das FFNN kann für binäre Klassifizierung vereinfacht werden. Die letzte Schicht des FFNNs hat nur ein Neuron und nutzt die Sigmoid-Funktion, anstatt der SoftMax-Funktion. Außerdem wird für die Kostenfunktion *binäre Crossentropy* verwendet, anstatt kategorische Crossentropy. Binäre Crossentropy bedarf keine kategorische Kodierung im Gegensatz zur kategorischen Crossentropy.

Die ML-Modelle zur Anomalieerkennung können separat von den ML-Modellen zur Standortbestimmung trainiert werden. Sie werden im Gegensatz zu den ML-Modellen zur Standortbestimmung nur einmalig trainiert mit vorbereiteten Trainingsdaten. Die Trainingsdaten werden aus den Anomaliedatenmengen und Datenmengen für die verschieden Routen generiert. Dafür werden die Klassifizierungsergebnisse auf diesen Datenmengen von den zuvor trainierten ML-Modellen zur Standortbestimmung genutzt. Daraus werden beschriftete Features extrahiert, die in Kapitel 6.6 detailliert erläutert werden.

Alternativ können nicht ML-Modelle als Vergleichsmodelle genutzt werden. Die trivialen Modelle sind das *Coin-Toss*-, *immer Falsch*- und *immer Wahr*-Modell. Ein komplexeres Modell nutzt die Topologie des Systems aus, um eine Anomalie zu indizieren, wenn die Sensorbox nicht dem Pfad folgt. In einer lockeren Variante könnte nur erwartet werden, dass einem Pfad kontinuierlich gefolgt wird, sodass übersprungene Standorte nicht dauerhaft eine Anomalie indizieren. Abbildung 5.1 skizziert dieses Modell. Wenn der Standort und der vorherige Standort nicht der unbekannte Standort ist und der vorherige Standort ungleich dem erwarteten Standort ist, dann wird ein Alarm ausgelöst. Dieser Alarm indiziert für eine konstante Dauer, dass eine Anomalie vorliegt. Dies ist motiviert aus dem Zusammenhang, dass wenn eine Anomalie vorliegt, es wahrscheinlich ist, dass sie kurz danach immer noch vorliegt.

```

if standort > 0 and vorheriger_standort > 0 and ↴
    topologie[standort].vorheriger_standort != vorheriger_standort:
        alarm_zaehtler = 0

if alarm_dauer > alarm_zaehtler:
    alarm_zaehtler++
    return true
return false

```

Listing 5.1: Skizze des Modells zur Anomalieerkennung auf Basis der Topologie.

5 MACHINE LEARNING MODELLE

Trainings- und Testdaten

Zum Zeitpunkt, als diese Arbeit verfasst wurde, existierte noch keine Möglichkeit Echtdaten in einem realistischen Szenario mit einem Mikrocontroller aufzunehmen, der über alle nötigen Sensoren verfügt. Aus diesem Grund wurden Trainings- und Testdaten simulativ erfasst.

Zur Datenerfassung wurde der Simulator CoppeliaSim verwendet, der zur Simulation von Robotik in Fabrikumgebungen entwickelt wurde [RSF13]. Mit diesem Simulator wurden verschiedene Routen aus Fließbändern simuliert und dabei verschiedene Sensorwerte erfasst. Diese wurden in einem Vorverarbeitungsschritt gefiltert und mit Sensordaten ergänzt, die in CoppeliaSim nicht verfügbar sind. Zuletzt wurden Features extrahiert und die resultierende Datenmenge in Trainings-, Validations- und Testdaten unterteilt.


6.1 Sensordaten aus Simulator CoppeliaSim

Insgesamt wurden vier Routen über 20 Zyklen jeweils zweimal erfasst. Das geschah einmal für Trainingsdaten und einmal für Testdaten, wobei die letzten fünf Zyklen der Trainingsdaten als Validationsmenge genutzt werden. Dabei wurden alle 50ms die xyz-Koordinaten, Accelerometerdaten und Gyroskopdaten erfasst, sowie Lichtintensität und Metadaten. Zu den Metadaten gehören Zeitstempel, Beschriftung des Routenabschnitts und Beschriftung des derzeitigen Zykluses. Ein Zyklus ist der vollständige Umlauf einer Route.

Abbildung 6.1 zeigt eine der vier Routen „simple_square“. Jede Route ist mit Markierungen für Zyklen und Standorte ausgestattet. Die Zyklusmarkierung wird genutzt, um die Datensätze mit dem derzeitigen Zyklus zu beschriften. Jedes Mal, wenn die Sensorbox diese Markierung überschreitet, wird der Zähler für den Zyklus inkrementiert.

6 TRAININGS- UND TESTDATEN

Die Standortmarkierung wird genutzt, um die Datensätze mit dem derzeitigen Routenabschnitt zu beschriften. Jedes Mal, wenn die Sensorbox diese Markierung überschreitet, wird der derzeitige Wert für den Routenabschnitt auf den Wert der Markierung gesetzt. Dabei werden alle aufgenommenen Datensätze immer mit dem derzeitigen Wert für den Routenabschnitt annotiert.



■ Abbildung 6.1: Modell der Route „simple_square“ in CoppeliaSim mit Beschriftungen.

Neben „simple_square“ gibt es noch drei weitere Routen (siehe Abbildungen B.1, B.3 und B.5). Die Route „long_rectangle“ weist lange Pfade mit wenig Änderungen auf. Die Route „rectangle_with_ramp“ besitzt zusätzlich zwei Rampen, wodurch Höhenunterschiede simuliert werden. Die Route „many_corners“ ist sehr komplex und hat viele verschiedene Standorte. Die Förderbänder können verschiedene Geschwindigkeiten haben mit sowohl abrupten Übergängen als auch fließenden Übergängen zueinander.

Je nach Kodierungsart (siehe Kapitel 5.1) müssen die Knoten und Kanten des zyklischen Graphen als Standorte kodiert werden. Mian hatte in seiner Arbeit die Kanten während der Simulation markiert [Mia21]. In dieser Arbeit wurde der Programm-Code seiner Arbeit für die Simulation übernommen, weswegen die aufgenommen Daten initial genau so beschriftet sind.

6.2 MIT EIGENEN MODELLEN ERGÄNZTE SENSORDATEN

Aus diesem Grund müssen die aufgenommenen Datensätze transformiert werden, sodass nicht die Kanten, sondern entweder Knoten oder Knoten und Kanten kodiert werden. Zu einem Knoten gehören die Datensätze, die sich in einem Umkreis vom ersten Datensatz befindet, der eine einzigartige Beschriftung in der Simulation erhalten hatte. Bei dem Kodierungsansatz, der nur die Knoten kodiert, werden die restlichen Datensätze als *unbekannt* beschriftet. Bei dem Kodierungsansatz, der Knoten und Kanten kodiert, werden die restlichen Datensätze mit einer neuen einzigartigen Beschriftung markiert, die abhängig von der topologischen Position der zuvor bestimmten Knoten ist.

6.2 Mit eigenen Modellen ergänzte Sensordaten

Im Projekt ist die Sensorbox mit einem Accelerometer, Gyroskop, Licht-, Magnetfeld-, Temperatur- und Geräuschsensor ausgestattet, sowie einen Empfänger zur Erfassung von WLAN-Zugangspunkten. Mit Coppeliasim ist es allerdings nur möglich Sensorwerte des Accelerometers, Gyroskops und Lichtsensors zu erfassen. Aus diesem Grund werden die fehlenden Sensoren durch das Ausnutzen vereinfachter Modelle ergänzt.

Abbildung 6.2 zeigt die Route „simple_square“ mit eingezeichneten Objekten, die Einfluss auf die modellierten Sensoren nehmen können. Die Routen befinden sich im gleichen Koordinatensystem, weswegen alle Routen diese Verteilung teilen. Abbildungen B.2, B.4 und B.6 zeigen eine analoge Karte für die restlichen Routen.

6.2.1 Magnetfeldsensor

Der Magnetfeldsensor ermöglicht die Ausrichtung des Sensors zum Erdmagnetfeld zu messen, welches durch magnetische Objekte beeinflusst werden kann. Diese Anomalien werden ausgenutzt, um Standortspezifische Daten zu erhalten. Magnetfeldsensoren messen das Magnetfeld auf Basis von Effekten die dadurch impliziert werden, z. B. die Lorentzkraft oder der Hall-Effekt [TH09]. Eine Anwendung dieses Sensors ist ein Kompass. Dieser richtet sich nach dem Magnetfeld der Erde aus und wird daher traditionell zur Navigation verwendet.

Das in dieser Arbeit verwendete Modell des simulierten Magnetfeldsensors fungiert als Kompass. Die Ausgabe ist der relative Richtungsunterschied von der Sensorbox zum magnetischen Nordpol. Dabei können starke magnetische Objekte in der Umgebung Einfluss auf den Sensor haben, sodass sich der magnetische Nordpol für den simulierten Sensor ändern kann. Die Ausgabewerte sind zwischen 0° und 359° , d. h. 0° ist Norden, 90° Osten, 180° Süden und 270° Westen.

6 TRAININGS- UND TESTDATEN




Abbildung 6.2: Karte der Route „simple_square“ mit eingezeichneten Einflussbereichen der Objekte, die Einfluss auf modellierte Sensoren haben. *Magnetic Source* (Gelb), *Noise Source* (Lila), *Access Point* (Grau), *Heat Source* (Rot) und Standorte (Grün).

Es wird angenommen, dass der magnetische Nordpol der Erde weit genug weg ist, sodass sich im Fabrikszenario die Richtung nur ändern kann, wenn die Ausrichtung der Sensorbox geändert wird oder, wenn ein magnetisches Objekt in der Umgebung Einfluss ausübt. Außerdem wird angenommen, dass sich die Ausrichtung des Objektes in einem Zyklus nicht ändert, da Fließbandsysteme für gewöhnlich nicht rund sind, sondern Kante auf Kante aufeinander übergehen. Allerdings wird für jeden Zyklus eine neue zufällige Ausrichtung zwischen 0° und 359° gewählt, da das Objekt mit verschiedenen Ausrichtungen auf das Fließband gelegt werden könnte. Zudem wird keine Interferenz der magnetischen Objekte zueinander angenommen. Sollten sie sich überschneiden wird das magnetische Objekt mit dem meisten Einfluss gewählt.

Starke magnetische Objekte sind strategisch in der Umgebung des Fließbandsystems platziert. Ihre Stärke wird dabei durch die Einflussreichweite definiert, wobei der Einfluss quadratisch mit der Distanz abnimmt. Ist der Einfluss bei 100%, so wird für den magnetischen Nordpol die Position des magnetischen Objekts angenommen. Wenn der Einfluss geringer ist, dann wird ein magnetischer Nordpol zwischen dem magnetischen Nordpol der Erde und des magnetischen Objektes Anteilweise gewählt. Die magnetischen Objekte können unterschiedliche Einflussreichweiten haben.

6.2 MIT EIGENEN MODELLEN ERGÄNZTE SENSORDATEN

Abbildung 6.3 illustriert diese Situation. Um die Ausrichtung der Sensorbox relativ zum magnetischen Nordpol der Erde bei 0 und dem Einfluss des magnetischen Objekts zu berechnen, ist es nötig die Winkel zwischen dem magnetischen Nordpol der Erde und dem magnetischen Objekt, sowie den Winkel zur Sensorbox zu wissen. Der Winkel β vom magnetischen Nordpol der Erde zur Sensorbox p_o ist bekannt. Der Winkel γ vom magnetischen Nordpol der Erde zum magnetischen Objekt p_m wird aus dem Winkel α innerhalb des eigenen Quadranten und der Anzahl der Quadranten, zum Quadranten in dem sich p_m befindet, berechnet. Dabei werden die Quadranten im Uhrzeigersinn gezählt. Je nach Quadrant können




Abbildung 6.3: Ausrichtung der Sensorbox relativ zum magnetischen Objekt und magnetischen Nordpol der Erde.

für a und b die x - bzw. y -Koordinate von p_m gewählt werden. Da der Einfluss des magnetischen Objekts p_m abhängig von der Position der Sensorbox p_o ist, müssen a und b mit p_o als Ursprung transformiert werden. Die Berechnung von α folgt dann (6.1).

$$\alpha = \arcsin\left(\frac{|p_{o_a} - p_{m_a}|}{\sqrt{(p_{o_a} - p_{m_a})^2 + (p_{o_b} - p_{m_b})^2}}\right) \quad (6.1)$$

Mit den Winkeln β und γ kann dann das Koordinatensystem zum magnetischen Objekt hin rotiert werden, sodass die Ausrichtung von p_o zum beeinflussten magnetischen Nordpol aus (6.2) berechnet werden kann.

$$\gamma' = (\gamma + (360 - \beta)) \mod 360 \quad (6.2)$$

6 TRAININGS- UND TESTDATEN

Der Einfluss eines magnetischen Objekts wird mit η beschrieben. Es ist abhängig von der Distanz von p_m zu p_o . In (6.3) wird der Einfluss als quadratisch abfallende Funktion mit zunehmender Distanz d und maximaler Einflussdistanz d_{\max} modelliert, wobei der maximale Einfluss 1 ist und der minimale Einfluss 0 ist.

$$\eta(d) = \min(0, 1 - \frac{d^2}{d_{\max}^2}) \quad (6.3)$$

Der Einfluss wirkt sich proportional auf den Winkel von p_m zum magnetischen Nordpol der Erde aus. Dabei ist aber die Ausrichtung von p_m zum magnetischen Nordpol der Erde zu beachten, denn bei den Polen des Magnetfeldes ändert sich die Richtung des Magnetfeldes. Formel 6.4 zeigt die Berechnung von γ' abhängig von der Ausrichtung von p_m zum magnetischen Nordpol der Erde, wobei $d = \sqrt{(p_{o_a} - p_{m_a})^2 + (p_{o_b} - p_{m_b})^2}$.

$$\begin{aligned}\gamma'_L &= (\gamma + (360(1 + \eta(d)) - \beta(1 - \eta(d)))) \mod 360 \\ \gamma'_R &= (\gamma + (360 - \beta(1 - \eta(d)))) \mod 360\end{aligned}\quad (6.4)$$

6.2.2 Temperatursensor

Der Temperatursensor wird ausgenutzt, um Abweichungen zu der Umgebungstemperatur zu erkennen. Diese könnte je nach Einsatzszenario von verschiedenen Faktoren beeinflusst sein, z. B. eine offene Tür, ein Schmelzofen oder eine Kühlkammer.

Das Modell für den Temperatursensor geht von einer konstanten Umgebungstemperatur aus. Im Raum sind Kälte- und Wärmequellen strategisch verteilt, die eine Temperatur unter- und oberhalb der Umgebungstemperatur haben können. Je näher sich die Sensorbox an einer der Quellen befindet, desto mehr nähert sich die gemessene Temperatur der Temperatur der Quelle T_{\max} an.

Jede Kälte- und Wärmequelle hat einen Einflussbereich, in der sie sich auf die Umgebungstemperatur T_U auswirken kann. Sollten sich zwei Wärmequellen überschneiden wird die Temperatur ausgewählt, die den größten Unterschied zur Umgebungstemperatur verursacht. In (6.5) wird die Berechnung der resultierenden Temperatur T' abhängig von der Distanz d der Quelle zur Sensorbox und der maximalen Einflussdistanz d_{\max} gezeigt.

$$T' = \begin{cases} T_U & , \text{ wenn } d > d_{\max} \\ \frac{(T_{\max} - T_U)d^2}{d_{\max}} + T_U & , \text{ ansonsten} \end{cases} \quad (6.5)$$

6.2.3 Geräuschsensor

In den verschiedenen Einsatzszenarien können Standorte von der Art und Intensität von Geräuschquellen unterschieden werden. Beispielsweise können wiederholende Geräuschemuster, wie Hämmern, oder mechanische Geräusche von Robotern, oder konstante Geräusche, wie eine Kreissäge, einen Standort einzigartig machen.

Es gibt verschiedene Arten von Geräuschsensoren, z. B. Geräuschrichtungssensoren [TDS⁺14] oder spezifische Anwendungen, wie Herzgeräuschsensoren [ZLGZ16]. Das in dieser Arbeit verwendete Modell ist einem Akustiksensor [Ses91] oder einem Mikrofon am ähnlichsten, das die Lautstärke in einem Frequenzbereich misst.

In diesem Modell werden Frequenzbereiche vernachlässigt. Es gibt ein Hintergrundrauschen V_H , auf das für jeden Datensatz ein zufälliges Rauschen addiert wird. Daneben gibt es Lautstärkequellen, die entweder periodisch oder konstant sind und strategisch im Raum verteilt sind. Die Interferenz von verschiedenen Lautstärkequellen wird vernachlässigt. Sollten sich zwei Lautstärkequellen überschneiden, so wird die maximale Lautstärke ausgewählt.

Die Lautstärke V_{\max} die von einer Quelle ausgeht nimmt quadratisch mit der Distanz d ab. Dabei wird der Einflussbereich von der maximalen Einflussdistanz d_{\max} bestimmt. In (6.6) wird die Berechnung für die resultierende Lautstärke durch eine konstante Lautstärkequelle gezeigt.

$$V' = \begin{cases} V_H & , \text{ wenn } d > d_{\max} \\ \frac{(V_{\max}-V_H)d^2}{d_{\max}} + V_H & , \text{ ansonsten} \end{cases} \quad (6.6)$$

Periodische Lautstärkequellen emittieren ein Geräusch in regelmäßigen Abständen. Dies wird modelliert durch eine quadratisch verringerte Lautstärke über 500ms, wenn die Lautstärke gemessen wird nachdem das Geräusch stattgefunden hat, d. h. nach 500ms, ist das Geräusch nicht mehr wahrzunehmen. In (6.7) wird dieser Zusammenhang beschrieben, wobei t der momentane Zeitpunkt ist und t_n das Intervall des periodischen Geräusches ist.

$$V' = \begin{cases} V_H & , \text{ wenn } d > d_{\max} \vee t \bmod t_n \leq 0,5 \\ \max(V_H, (\frac{(V_{\max}-V_H)d^2}{d_{\max}} + V_H)(1 - 4(t \bmod t_n)^2)) & , \text{ ansonsten} \end{cases} \quad (6.7)$$

6 TRAININGS- UND TESTDATEN

6.2.4 WLAN-Zugangspunkte

In vielen Einsatzszenarien sind WLAN-Zugangspunkte bereits vorhanden und im Raum strategisch verteilt. Diese werden entweder von den Mitarbeitern genutzt, oder sind nötig zur Kommunikation von den Geräten. Jeder WLAN-Zugangspunkt deckt einen bestimmten Bereich ab und impliziert somit nur bestimmte Standorte.

Die Detektierung von WLAN-Zugangspunkten wird durch die Messung von RSSI-Werten bzw. MAC-Adressen von WLAN-Zugangspunkten modelliert. Das Modell vereinfacht dies, indem es lediglich aussagt, ob ein WLAN-Zugangspunkt in Reichweite ist oder nicht.

Im Raum sind strategisch WLAN-Zugangspunkte verteilt. Diese können innerhalb einer maximalen Reichweite empfangen werden. Ist die Distanz der Sensorbox zum WLAN-Zugangspunkt innerhalb der Reichweite, gilt der WLAN-Zugangspunkt als empfangen. Interferenzen und Reflexionen werden vernachlässigt.

6.3 Simulation von Interrupts

Die Simulationsdaten, die mit CoppeliaSim aufgenommen wurden, enthalten alle 50ms Einträge für die aufgenommenen Sensoren. Unter realen Bedingungen wäre so eine Abtastrate aber nicht mit den Limitierungen der Batterielaufzeit zu vereinbaren. Aus diesem Grund sollten Sensoren *Interrupts* auslösen, wenn eine signifikante Änderung festgestellt oder ein Schwellenwert überschritten wurde. Interrupts sind Benachrichtigungen an die CPU, dass der Sensor ausgelesen werden sollte, wodurch die CPU in der Zwischenzeit schlafen und somit Energie gespart werden kann.

Um dieses Verhalten nachzustellen werden diese Interrupts simuliert, wodurch die Datenmenge gefiltert wird. In dieser Arbeit wird die Änderung zum letzten Interrupt eines Sensors modelliert, d. h. jeder Sensor merkt sich seinen Sensorwert, wenn er einen Interrupt auslöst und führt das nächste Mal nur einen Interrupt aus, wenn sich der Sensorwert um einen bestimmten Prozentsatz zum gemerkten Sensorwert unterscheidet.

Dadurch wird einerseits ein realistischeres Szenario dargestellt, denn von einer Sensorbox, die still steht, würde auch keine Aktivität erwartet werden. Andererseits verringert sich die Datenmenge, wodurch die Trainingszeit verringert wird.

6.4 FEATURE-EXTRAHIERUNG

Unterschieden werden drei Ansätze, um Interrupts zu erzeugen. Der erste Ansatz vergleicht den Betrag der Differenz mit einem festen Schwellenwert. Der zweite Ansatz erfordert, dass die Änderung einen Prozentsatz des vorherigen Wertes ausmacht. Der dritte Ansatz erfordert nur eine Änderung.

Die verwendeten Ansätze und Schwellenwerte sind Tabelle 6.1 zu entnehmen. Für Sensorwerte des Accelerometers und Gyroskops, sowie des Magnetfeldsensors wurde der erste Ansatz verwendet, da signifikante Änderungswerte nicht relativ zum vorherigen Sensorwert sind, sondern lediglich eine absolute Änderung erzeugen. Für Sensorwerte des Temperatur-, Licht- und Geräuschsensors wurde der zweite Ansatz verwendet, da diese ein allgegenwärtiges Rauschen aufnehmen, das je nach Umgebung variiieren kann. Für die WLAN-Zugangspunkte wird der dritte Ansatz verwendet, da die Sensorwerte binär sind. Die Schwellenwerte wurden so gewählt, dass jeder Standort Interrupts auslöst und nicht mehr als 50% der ursprünglichen Daten genutzt werden. Je nach Route werden zwischen 15% und 50% dieser Daten verwendet.

Sensordaten	Fester Schwellenwert	Variabler Schwellenwert	Änderung
Accelerometer	0.1	-	-
Gyroskop	0.1	-	-
Magnetfeld	8	-	-
Temperatur	-	0.12	-
Licht	-	0.12	-
Geräusch	-	0.16	-
WLAN-Zugangspunkte	-	-	1

■ **Tabelle 6.1:** Schwellenwerte der simulierten Interrupts.

6.4 Feature-Extrahierung

Die Feature-Extrahierung ist der Prozess, in dem Features aus den Rohdaten der Datenmenge extrahiert werden. In dieser Arbeit findet dieser Schritt nach der Filterung durch künstliche Interrupts statt. Features sind berechnete Attribute und Eigenschaften von einem oder mehreren Sensorwerten der Rohdaten.

6 TRAININGS- UND TESTDATEN

Durch die Feature-Extrahierung müssen die ML-Modelle die Features nicht selbständig lernen, sondern lediglich darauf abstrahieren. Dies erleichtert das Training, kann aber gerade für tiefe NN die Generalisierungsfähigkeit einschränken [SLCY11]. Einerseits benötigten entscheidungsbaumbasierte Klassifizierer einen solchen Prozess, da Features das Rauschen der Rohdaten verringern und dadurch eine Partitionierung vereinfachen. Andererseits kann das FFNN durch die Limitierungen der Hardware möglicherweise nicht groß genug sein, um diese Features selbstständig zu erlernen.

Mian hat in seiner Arbeit ein Datenfenster verwendet, um die Sensorwerte zu glätten [Mia21]. Als Datenfenster werden die letzten N Einträge der Sensordaten bezeichnet, wobei N die Fenstergröße ist. Mian hat eine hohe Abtastrate verwendet, wodurch die Unterschiede zu hintereinander liegenden Datensätzen gering ist und Rauschen eine große Auswirkung hat. Durch die künstlichen Interrupts werden nur Datensätze verwendet, die signifikante Änderungen enthalten, wodurch große Datenfenster in dieser Arbeit nicht benötigt werden. Es wird dennoch ein Datenfenster verwendet, da dadurch mehr Features konstruiert werden können, die eine bessere Generalisierung ermöglichen. Das Datenfenster ist aber signifikant kleiner, da durch die künstlichen Interrupts eine im Mittel geringe Abtastrate zu erwarten ist.

Tabelle 6.2 listet alle verwendeten Features auf. Zunächst werden aus jedem Sensor, sofern der Sensor dies erlaubt, die gleiche Menge von Features extrahiert. Aus den Datenfenstern der Sensordaten werden Standardabweichung, Minimum, Maximum und Durchschnitt für jeden Sensor berechnet. Zusätzlich wird der momentane Wert jedes Sensors als Feature verwendet. Da die Werte des Accelerometers und Gyroskops abhängig von der Ausrichtung der Sensorbox ist, wird von diesen nur der Betrag der Summe der x-, y- und z-Komponenten verwendet. Für die Detektionsdaten der WLAN-Zugangspunkte erschien die Standardabweichung, Minimum, Maximum und Durchschnitt nicht sinnvoll, da die Daten nur binäre Werte annehmen. Mian hat die Änderung der Sensordaten als Features verwendet [Mia21]. Statt dessen wird in dieser Arbeit die Standardabweichung verwendet, die eine Änderung im Datenfenster impliziert.

Daneben wurden noch drei weitere Features aus den Metadaten extrahiert. Das erste Feature ist der zuletzt vom ML-Modell bestimmte Standort. Das zweite Feature ist der zuletzt bestimmte Standort, der nicht als unbekannter Standort gilt und nicht der aktuelle Standort ist. Mian hat ein Feature für jeden zu klassifizierenden Standort als Eingabe verwendet, dass auf eins gesetzt wird, wenn es erkannt wurde und ansonsten exponentiell abfällt [Mia21]. In dieser Arbeit wurde der Standort als Wert nur eines Features repräsentiert, da dies schlecht mit der steigenden Anzahl von zu klassifizierenden Standorten skaliert und eine Abhängigkeit zum zuletzt bestimmten Standort für die Robustheit vermieden werden sollte.

Sensordaten	Standardabweichung	Minimum	Maximum	Durchschnitt	Wert
Accelerometer	X	X	X	X	X
Gyroskop	X	X	X	X	X
Magnetfeld	X	X	X	X	X
Temperatur	X	X	X	X	X
Licht	X	X	X	X	X
Geräusch	X	X	X	X	X
WLAN-Zugangspunkte	-	-	-	-	X
Letzter Standort	-	-	-	-	X
Letzter unterschiedlicher Standort	-	-	-	-	X
Zeit	X	-	-	-	-

■ **Tabelle 6.2:** Extrahierte Features aus verfügbaren Sensordaten.

Das dritte Feature ist die Standardabweichung über die Zeit zwischen Interrupts des Datenfensters. Alle anderen Features sind zeitunabhängig, da sie sich auf zeitunabhängige Sensorwerte im Datenfenster beziehen.

Die Signifikanz der einzelnen Features ist abhängig von der Einsatzumgebung, weshalb in Kapitel 5.4 ein Feature-Auswahlschritt im Trainingsprozess vorgeschlagen wurde, um die Anzahl der Features zu verringern. Dabei wird die Wichtigkeit, über die Permutationswichtigkeit bestimmt (Kapitel 7.4). Aus diesem Grund muss individuell für jedes Einsatzgebiet abgewogen werden, welche Sensoren und Features im Vergleich zu deren Kosten und Energieverbrauch am meisten Nutzen bringen.

6.5 Synthetische Daten

Es kann passieren, dass Sensoren über die Zeit kaputt gehen oder vorübergehend gestört werden. Ist die Abhängigkeit des ML-Modells zu diesen Sensoren zu groß, wird die Klassifizierungsfähigkeit des ML-Modells stark eingeschränkt, wenn dieser Fall eintritt. Um die ML-Modelle robust gegenüber diesen Szenarien zu machen, werden synthetische Daten auf Basis existierenden Daten erzeugt, die zusätzlich im Training benutzt werden. In den Daten werden Sensorausfälle simuliert, indem die Sensorwerte verändert werden.

6 TRAININGS- UND TESTDATEN

Mögliche Fehler der Sensoren sind ein temporärer oder permanenter Ausfall oder eine leichte Abweichungen zum korrekten Sensorwert. Zudem könnten Standorte nicht erfasst werden, weil kein Interrupt ausgelöst wurde als die Sensorbox sich an diesem Standort befand oder die Sensorbox hat auf einem unbekannten Weg einen Standorte übersprungen.

Fehlerhafte Sensoren werden durch die Duplizierung von Routen dargestellt, in denen die Sensoren genutzt werden bzw. ein zufälliges Rauschen addiert wird. Verpasste Standorte werden zum einen als Routen mit permutierten Standorten dargestellt. Zum anderen werden sie durch duplizierte Routen dargestellt, in denen der zuletzt besuchte nicht unbekannte Standort übersprungen wurde. Um keinen Bias zu erzeugen, werden 10% synthetische Routen von jedem Standort zur Trainingsmenge hinzugefügt.

6.6 Anomaliedaten

Um Trainings- und Testdaten für Routen mit Anomalien zu erzeugen, in denen die Sensorbox auf anderen als den üblichen Wegen transportiert wurde, wurden die bekannten Routen modifiziert, indem Umleitungen eingebaut werden, die teilweise Standorte überspringen und nicht in den Trainingsdaten vorhanden sind. Dadurch wird ein Szenario simuliert, in der das Klassifizierungsverhalten vom ML-Modell zur Standortbestimmung auf unbekannten Wegen beobachtet werden kann. Aus den Klassifizierungsergebnissen des ML-Modells zur Standortbestimmung werden schließlich Features extrahiert, die vom separaten ML-Modell zur Anomalieerkennung verwendet werden.




Abbildung 6.4: Ausschnitt der Anomalietestmenge mit den Standortänderungen in einem Datenfenster von 25.

Wenn eine Anomalie vorliegt, wird erwartet, dass das ML-Modell unsicherer wird und stärker fluktuiert, wodurch drei Features motiviert sind. Das erste Feature beschreibt die Abweichung von der üblichen Standortänderungshäufigkeit. Dazu wird der Durchschnitt der aktuellen Häufigkeit der Standortänderungen in einem Datenfenster gemessen und von der durchschnittlichen Häufigkeit ohne Anomalien abgezogen. Das Feature ist der Betrag dieser Differenz. Abbildung 6.4 zeigt die akkumulierten Standortänderungen in einem Datenfenster von 25. Bei den Pfadeinträgen bei ca. 250, 1000 und 1600 sind Extrema zu erkennen, die mit der Anomalie in dieser Testmenge übereinstimmen, d. h. wenn eine Anomalie vorliegt, wird häufiger der Standort geändert.

Das zweite Feature ist analog zum ersten Feature konstruiert. Dieses nutzt anstatt der Anzahl der Standortänderungen die summierte Wahrscheinlichkeit der erkannten Standorte. Das ML-Modell zur Standortbestimmung hat keine diskrete Ausgabe, sondern gibt einen Vektor von Wahrscheinlichkeiten aus, der für jeden Standort die Klassifizierungswahrscheinlichkeit angibt. Dabei gilt der klassifizierte Standort als der Eintrag im Vektor mit der höchsten Wahrscheinlichkeit. Diese Wahrscheinlichkeit wird dann analog zu den Standortänderungen akkumuliert. Das dritte Feature ist die Standardabweichung der ersten fünf Einträge dieses Vektors, der absteigend sortiert ist. Abbildung 6.5 zeigt die akkumulierte Standortwahrscheinlichkeit in einem Datenfenster von 25. Bei den Pfadeinträgen bei ca. 250, 1000 und 1600 ist die akkumulierte Standortwahrscheinlichkeit deutlich geringer, d. h. wenn eine Anomalie vorliegt, ist die Sicherheit für einen Standort geringer.

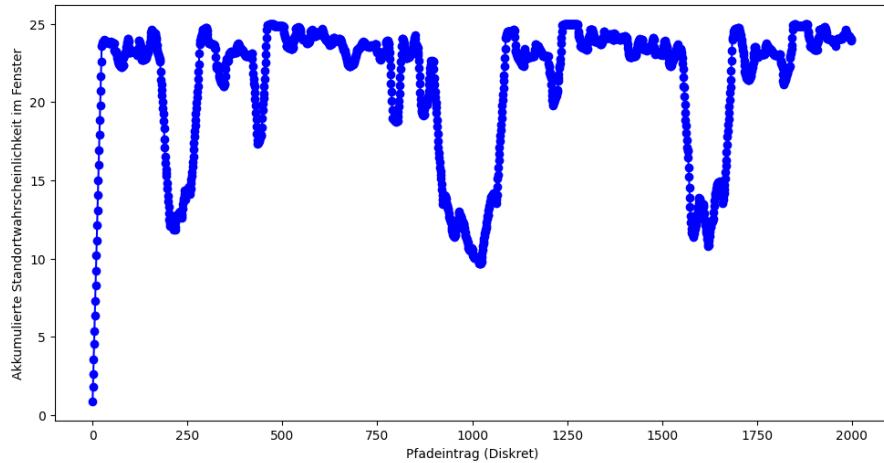


Abbildung 6.5: Ausschnitt der Anomalietestmenge mit der akkumulierten Standortwahrscheinlichkeit in einem Datenfenster von 25.

6 TRAININGS- UND TESTDATEN

Als viertes Feature wird betrachtet, ob die Folge erkannter Standorte einem bekannten Weg entspricht (Listing 5.1). Ist das nicht der Fall, muss das ML-Modell zur Standortbestimmung ein Fehler gemacht haben oder tatsächlich eine Anomalie vorliegen, da die Topologie verletzt wurde.

Daneben wurde ebenfalls eine Rückwärtskante von dem ML-Modell zur Anomalieerkennung zur vorherigen Feature-Extrahierung in Betracht gezogen, da es wahrscheinlich ist, dass wenn zuvor eine Anomalie vorlag, danach immer noch eine Anomalie vorliegt. Im Training wurden damit zwar sehr gute Ergebnisse erreicht, in der Praxis war das Modell aber äquivalent zum *Immer-Falsch*-Modell.

Evaluation

Zur Evaluation der ML-Modelle werden drei Aspekte betrachtet: Klassifizierungsgenauigkeit, Robustheit und Ressourcennutzung. Bei der Klassifizierungsgenauigkeit wird einerseits die Standortbestimmung und andererseits die Anomalieerkennung evaluiert. Dabei wird sowohl auf verschiedene Größen von FFNNs und Entscheidungswälder eingegangen, als auch auf die Anzahl zu unterscheidender Standorte. Für die Robustheit wird der Fehler des besten FFNNs und Entscheidungswaldes bei verschiedenen Fehlerszenarien untersucht. Diese bestehen aus fehlerhaften Sensordaten durch Rauschen oder ausgefallenen Sensoren und Routen mit permutierten Teilstücken. Bei der Ressourcennutzung wird auf die Programmgröße und die Ausführungszeit der besten ML-Modelle eingegangen. Außerdem wird der Energieverbrauch für verschiedene Szenarien eingeschätzt.

Unterschieden werden zwei Varianten von Testmengen. Diese unterscheiden sich in der Art, wie die Features für den vorherigen Standort bestimmt werden. In der ersten Variante sind alle vorherigen Standorte korrekt. In der zweiten Variante ist der erste vorherige Standort als *unbekannt* beschriftet und alle folgenden vorherigen Standorte werden iterativ durch das ML-Modell bestimmt, d. h. in dieser Variante wird der propagierte Fehler durch die Rückwärtsskante des ML-Modells betrachtet. Nachfolgend beschriebene Metriken, die auf die zweite Variante der Testmenge angewendet werden sind mit `cont` markiert.

Die ML-Modelle wurden mit Trainingsdaten von den vier aufgenommenen Routen trainiert (Kapitel 6.1). Sie teilen ein Koordinatensystem, in dem die künstlichen Interferenzquellen für die ergänzten Sensoren liegen. Daher kann das Training mit mehreren Routen kann als eine sehr komplexe Route mit überlappenden Pfaden betrachtet werden, da diese Pfade übereinander liegen.

7.1 Metriken

In dieser Arbeit werden drei Metriken zur Bewertung der Klassifizierungsgenauigkeit verwendet. Die erste Metrik, die die Klassifizierungsgenauigkeit als die Anzahl der korrekt klassifizierten Standorte mit der Gesamtanzahl vergleicht (7.1). Diese Metrik wird auch von Mian verwendet und ist für den direkten Vergleich mit seinen FFNNs erforderlich.

$$P(A) := \frac{\text{Anzahl korrekter Klassifizierungen}}{\text{Gesamtzahl}} \quad (7.1)$$

Die zweite Metrik (7.2) betrachtet die Klassifizierungsgenauigkeit unter Tolerierung, dass ein Standort zu früh oder zu spät verlassen wurde, d. h. Fehlklassifizierungen werden vernachlässigt, wenn der letzte korrekte Standort bzw. der nächste korrekte Standort klassifiziert wird mit einer Gesamttoleranz von ϵ Klassifizierungen. Diese Metrik ist besonders gut für den Vergleich von ML-Modellen geeignet, da entgegen der Beschriftung in der Testmenge, harte Übergänge zwischen zwei benachbarten Standorten nicht der Wirklichkeit entsprechen. Im Übergang können Sensorwerte mehrdeutig sein und dies sollte bei der Standortbestimmung, solange sie konsequent ist, beachtet werden. Dadurch wird, im Vergleich zu $P(A)$, das Rauschen in der Klassifizierungsgenauigkeit reduziert, da diese Mehrdeutigkeit im Übergang toleriert wird, wodurch die ML-Modelle besser vergleichbar sind.

$L :=$ Menge der vom ML-Modell klassifizierten Standorten.

$K :=$ Menge von den wirklichen Standorten.

$\Phi(i) :=$ Index vom nächsten Standort.

$\Psi(i) :=$ Index vom vorherigen Standort.

$$\Omega(i) := \Phi(i) - i \leq \epsilon \wedge \bigwedge_{i \leq q \leq \min(\#K, \Phi(i))} L_q = K_{\Phi(i)}$$

$$\Theta(i) := i - \Psi(i) \leq \epsilon \wedge \bigwedge_{\max(0, \Psi(i)) \leq q \leq i} L_q = K_{\Psi(i)}$$

$$P(B \leq \epsilon) := \frac{\#\{L_i | L_i = K_i \vee \Omega(i) \vee \Theta(i) \text{ für } i \in \{0, 1, \dots, \#L - 1\}\}}{\#K} \quad (7.2)$$

Als dritte Metrik wird betrachtet, welche Klassifizierungsgenauigkeit nach (7.1) erreicht werden kann, wenn der vorherige Standort inkorrekt war (7.3). Diese Metrik ist besonders relevant bei der Beurteilung der Robustheit der ML-Modelle.

$$P(C) := \frac{\text{Anzahl korrekter Klassifizierungen, wenn vorheriger Standort inkorrekt war}}{\text{Alle Klassifizierungen, wenn vorheriger Standort inkorrekt war}} \quad (7.3)$$

7.2 Klassifizierungsgenauigkeit der Standorte

Die Klassifizierungsgenauigkeit der ML-Modelle zur Standortbestimmung wurde mit verschiedenen Konfigurationen über komplexer werdende Datenmengen evaluiert. In Kapitel 5.2 und Kapitel 5.3 wurden die einzelnen Konfigurationen der ML-Modelle beschrieben. Die Standortkomplexität einer Testmenge ist die Anzahl der Standorte, die davon erkannt werden können. Um die Standortkomplexität zu erhöhen, wurden die Datenmengen um weitere Routen erweitert. Dies impliziert aber, dass die Testmengen unter den verschiedenen Standortkomplexitäten nicht direkt miteinander vergleichbar sind, da mit jeder Route die Testmenge erweitert wird. Die berechneten Klassifizierungswahrscheinlichkeiten sind jeweils der Durchschnitt der Klassifizierungswahrscheinlichkeiten aller Routen in der Testmenge.

Außerdem unterscheiden sich die Kodierungsansätze, je nach Standortkomplexität. Für die Standortkomplexitäten 9, 17, 25 und 52 wurde der Kodierungsansatz verwendet, bei denen nur die Knoten und ein zusätzlicher unbekannter Standort betrachtet wird. Für die Standortkomplexitäten 16, 32, 48 und 102 wurde der Kodierungsansatz verwendet, bei denen Knoten und Kanten betrachtet werden.

7.2.1 Vergleich mit Mians Ergebnissen

Mian hat die Klassifizierungsgenauigkeit $P(A)_{\text{cont}}$ betrachtet. Er konnte mit einem WFBNN bei einer Route mit drei Pfaden und 14 Standorten eine Klassifizierungsgenauigkeit von 93,26% erreichen [Mia21]. Mit einem WFFNN konnte Mian eine Klassifizierungsgenauigkeit von 94,51% erreichen. Abbildung 7.1 vergleicht die besten Klassifizierungsergebnisse der Entscheidungswälder und FFNNs mit und ohne Rückwärtskante und den Klassifizierungsergebnissen von Mian. Dabei ist $P(A)$ des ML-Modells ohne Rückwärtskante mit $P(A)_{\text{cont}}$ des ML-Modells mit Rückwärtskante vergleichbar, da bei dem ML-Modell ohne Rückwärtskante kein Fehler propagiert werden kann.

Mian kodierte in seinem Ansatz die Kanten als Standorte, was sich von den beiden in dieser Arbeit benutzten Ansätzen unterscheidet. Die in dieser Arbeit evaluierten Standortkomplexitäten, die Mians Evaluation am nächsten kommen, sind 16, mit dem Kodierungsansatz, der Kanten und Knoten kodiert, und 17, mit dem Kodierungsansatz, der nur Knoten kodiert.

7 EVALUATION




Abbildung 7.1: Die besten Klassifizierungsgenauigkeiten der ML-Modelle mit und ohne Rückwärtskante und Mians Modelle über Standortkomplexitäten.

Aus Tabelle C.2 können die Klassifizierungsergebnisse $P(A)_{\text{cont}}$ für die ML-Modelle mit Rückwärtskante entnommen werden und aus Tabelle C.5 die Klassifizierungsergebnisse $P(A)$ für die ML-Modelle ohne Rückwärtskante. Der beste Entscheidungswald mit Rückwärtskante bei einer Standortkomplexität von 16 Orten hat eine Klassifizierungsgenauigkeit $P(A)_{\text{cont}}$ von 83,52% erzielt. Das ist 9,74 Prozentpunkte schlechter als Mians WFBNN. Das beste FFNN ist 29,32 Prozentpunkte schlechter. Von der Modellstruktur her ist das FBNN von Mian der in dieser Arbeit verwendeten Struktur am ähnlichsten. Im Vergleich mit diesem Modell ist der Entscheidungswald 49,95 Prozentpunkte besser und das FFNN 30,37 Prozentpunkte besser.

Der beste Entscheidungswald mit Rückwärtskante bei einer Standortkomplexität von 17 Orten ist 1,15 Prozentpunkte besser als Mians WFBNN. Das beste FFNN ist 6,04 Prozentpunkte schlechter. Im Vergleich mit Mians FBNN ist der Entscheidungswald 60,84 Prozentpunkte besser und das FFNN 53,65 Prozentpunkte besser.

Der beste Entscheidungswald ohne Rückwärtskante bei einer Standortkomplexität von 16 Orten ist 0,22 Prozentpunkte schlechter als Mians WFFNN. Das beste FFNN ist 5,59 Prozentpunkte schlechter. Bei einer Standortkomplexität von 17 Orten ist der beste Entscheidungswald 1,98 Prozentpunkte besser und das beste FFNN ist 1,05 Prozentpunkte schlechter. Anzumerken ist, dass die Standortkomplexität in Vergleich zu Mian höher ist. Außerdem wird kein sensorisches Gedächtnis verwendet, wodurch die ML-Modelle deutlich weniger Features nutzen und kleiner sind.

7.2.2 Einfluss der Standortkomplexität

ML-Modelle sind besser vergleichbar, wenn toleriert wird, dass das ML-Modell den Standort etwas zu früh betritt oder etwas zu spät verlässt, solange es kontinuierlich den selben Standort angibt, da bei den Übergängen zwischen Standorten nicht immer eindeutig ein Standort bestimmt werden kann. Tabellen C.3 und C.6 geben diese Klassifizierungsgenauigkeit an, wobei bis zu fünf fehlerhafte Klassifizierungen toleriert werden.

Abbildung 7.2 vergleicht die ML-Modelle mit und ohne Rückwärtskante mit der Metrik $P(B \leq 5)$. Die Entscheidungswälder klassifizieren mit steigender Standortkomplexität genauer als die FFNNs. Bei einer linearen Regression über diese Klassifizierungsergebnisse, verringert sich die Klassifizierungsgenauigkeit mit jedem zusätzlichen Standort bei den Entscheidungswäldern mit Rückwärtskante um 0,13 Prozentpunkte, bei Entscheidungswäldern ohne Rückwärtskante um 0,1 Prozentpunkte, bei FFNNs mit Rückwärtskante um 0,47 Prozentpunkte und bei FFNNs ohne Rückwärtskante um 0,24 Prozentpunkte.




Abbildung 7.2: Die besten Klassifizierungsgenauigkeiten $P(B \leq 5)$ der ML-Modelle mit und ohne Rückwärtskante über Standortkomplexitäten.

Die Klassifizierungsgenauigkeit ist besser, wenn nur Knoten statt Knoten und Kanten erkannt wurden. Das gilt sowohl für Entscheidungswälder als auch FFNNs. Insbesondere zwischen den Standortkomplexitäten 16 und 17, sowie 32, 48 und 52 ist diese Diskrepanz zu erkennen. Aus diesem Grund ist zu schließen, dass der Kodierungsansatz, der nur Knoten kodiert, bessere Klassifizierungsergebnisse erzielt als der Kodierungsansatz, der Kanten und Knoten kodiert.

7 EVALUATION

7.2.3 Einfluss der Hyperparameter

Als beste maximale Baumhöhe hat sich 16 herausgestellt, wobei 32 und 64 marginal schlechtere Ergebnisse erzielen. Eine maximale Baumhöhe von 8 war nicht ausreichend, da es für hohe Standortkomplexitäten schlechtere Ergebnisse erzielt hatte. Bei gleicher Waldgröße haben die maximalen Baumhöhen von 32 und 64 für Entscheidungswälder mit Rückwärtsskante äquivalente Ergebnisse erzielt (Vgl. Abbildung B.7, Abbildung B.11). Dies schließt aber nicht aus, dass andere Szenarien nicht von größeren maximalen Baumhöhen profitieren könnten.

Eine Waldgröße von 8 hat nur marginal schlechtere Ergebnisse bei 102 Standorten erzielt, als die Waldgrößen 16, 32 und 64. Aus diesem Grund ist eine Waldgröße von 8 ausreichend (Vgl. Abbildung B.8, Abbildung B.12). Eine kleine Waldgröße wäre auch vorstellbar, wurde aber in dieser Arbeit nicht untersucht.

Die FFNNs mit Rückwärtsskante verhalten sich sehr volatil, weswegen keine Aussage über die Skalierung mit der Anzahl der verdeckten Schichten oder der Anzahl der Neuronen pro verdeckte Schicht getroffen werden kann. Die FFNNs ohne Rückwärtsskante erzielen konsistenter Ergebnisse (Vgl. Abbildung B.9, Abbildung B.10). Die Klassifizierungsergebnisse für verschiedene Anzahlen von verdeckten Schichten unterscheiden sich nicht stark voneinander. Zwei verdeckte Schichten haben sich insgesamt marginal besser erwiesen als eine, vier und acht verdeckte Schichten, aber die zusätzliche Klassifizierungsgenauigkeit müsste mit der zusätzlichen Größe des FFNNs abgewogen werden (Vgl. Abbildung B.13). Die Klassifizierungsgenauigkeit wächst mit steigender Anzahl von Neuronen in der verdeckten Schicht (Vgl. Abbildung B.14). Auch hier müsste die gewonnene Klassifizierungsgenauigkeit mit der zusätzlichen Größe des FFNNs abgewogen werden.

7.3 Klassifizierungsgenauigkeit der Anomalien

Bei der Anomalieerkennung werden Entscheidungswälder und FFNNs mit den besten ML-Modellen zur Standortbestimmung trainiert und mit den drei Baseline-Modellen verglichen. Tabelle 7.1 zeigt die Klassifizierungsgenauigkeiten über die verschiedenen Standortkomplexitäten, wobei die Klassifizierungsgenauigkeit $P(A)$ nochmal genauer in den Anteil der korrekten Klassifizierungen aufgeschlüsselt ist, wenn eine bzw. keine Anomalie vorlag. Die trainierten FFNNs geben stets aus, dass keine Anomalie vorliegt. Es ist unklar, warum die FFNNs sich so verhalten.

7.3 Klassifizierungsgenauigkeit der Anomalien

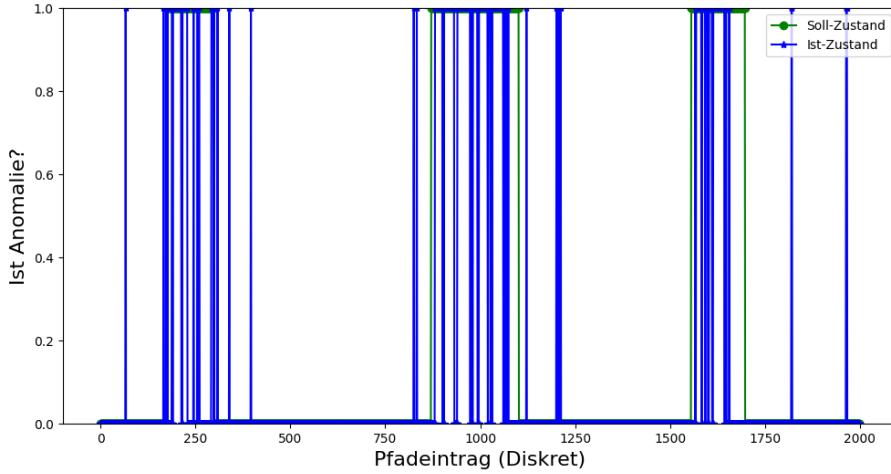
Standorte	9	16	17	25	32	48	52	102
$P(A)$								
Entscheidungswald	82,59%	81,19%	87,14%	84,91%	79,06%	83,47%	81,93%	76,00%
FFNN	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%	77,88%
Topologie (DT)	84,77%	30,57%	83,51%	79,76%	28,63%	24,97%	80,55%	29,47%
Topologie (KNN)	86,10%	52,17%	77,72%	79,30%	45,06%	41,92%	74,77%	43,55%
Anteil korrekt klassifiziert, indem Anomalie vorlag								
Entscheidungswald	34,86%	35,52%	52,58%	50,92%	32,21%	50,64%	23,21%	1,92%
FFNN	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%	0,00%
Anteil korrekt klassifiziert, indem keine Anomalie vorlag								
Entscheidungswald	96,14%	94,41%	97,05%	95,83%	92,48%	93,13%	98,96%	97,18%
FFNN	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%

■ **Tabelle 7.1:** $P(A)$ über Standorte und Modelle zur Anomalieerkennung.

Die Entscheidungswälder hingegen eignen sich besser zur Anomalieerkennung. Es werden zwischen 1,92% und 52,58% der Anomalien erkannt und zwischen 1,04% und 7,52% falsch als Anomalien erkannt. Die Klassifizierungsgenauigkeit des Entscheidungswaldes zur Anomalieerkennung ist abhängig von der Klassifizierungsgenauigkeit zur Standortbestimmung und von der Standortkomplexität. Je besser das Standortbestimmungsmodell und je höher die Standortkomplexität, desto höher ist die Anomalieerkennungsrate. Aus diesem Grund ist die Klassifizierungsgenauigkeit bei den Standortkomplexitäten, die mit dem Kodierungsansatz, der Kanten und Knoten kodiert, zusammenhängen, geringer als bei dem Kodierungsansatz, der nur die Knoten kodiert.

Abbildung 7.3 zeigt einen Ausschnitt der Anomalietestmenge, worauf der Entscheidungswald der Standortkomplexität 17 angewendet wurde. Die Anomalie wird nicht kontinuierlich erkannt und es werden auch fälschlicherweise Standorte als Anomalien klassifiziert. Allerdings treten falsch-positive Ergebnisse nur vereinzelt auf, wohingegen bei einer Anomalie, sehr häufig eine Anomalie erkannt wird. Die falsch-positiven Ergebnisse können somit durch Ausnutzen dieser Fluktuationen vermieden werden, indem beispielweise ein Schwellenwert an Ausschlägen in einer bestimmten Zeit eingeführt wird.

7 EVALUATION



■ Abbildung 7.3: Ausschnitt der Klassifizierungsergebnisse auf der Anomalietestmenge mit dem Entscheidungswald der Standortkomplexität 17.

7.4 Wichtigkeit der Features


Die Wichtigkeit, oder Signifikanz, der Features wird in dieser Arbeit definiert als der Fehler, der durch die Modifizierung eines Features in der Testmenge im Vergleich zur ursprünglichen Testmenge entsteht. Die Permutationswichtigkeit ist der Fehler, der durch das permutieren eines Features in der Testmenge entsteht, im Vergleich zu der ursprünglichen Testmenge. Je größer der Fehler, desto wichtiger das Feature [Bre01].

Scikit-Learn bietet für den verwendeten *RandomForest* ein Attribut `feature_importances_` an, dass die Feature-Wichtigkeit ausgeben soll. Dieses beschreibt die akkumulierte *Impurity*-Verringerung, das ein Feature im Entscheidungswald beiträgt [lea21]. Dabei gibt *Purity* an, wie durchmischt die Klassen in den Blättern der Entscheidungsbäume sind, d. h. Features die früh in der Konstruktion verwendet werden, haben laut dieser Metrik einen großen Einfluss. Zur besseren Vergleichbarkeit mit den FFNNs wurde diese Metrik aber nicht verwendet.

Abbildung 7.4 zeigt die Permutationswichtigkeiten der ML-Modelle mit Rückwärtskante zur Standortbestimmung. Die Features sind abgekürzt in der Grafik: *acc* steht für die Features aus den Accelerometer, *light* für den Lichtsensor, *ap* für den WLAN-Zugangspunkt, *temperature* für den Temperatursensor, *heading* für den Magnetfeldsensor, *volume* für den Geräuschsensor, *ang* für das Gyroskop.

7.4 WICHTIGKEIT DER FEATURES

Auffallend ist, dass die Features der vorherigen Standorte keine Wichtigkeit haben. Dies ist durch das iterative Evaluierungsverfahren der Testmenge begründet, d. h. eine Permutation hat keinen Effekt, da diese Features während der Evaluierung vom Modell selbstständig bestimmt werden.



■ Abbildung 7.4: Permutationswichtigkeit der Features der ML-Modelle mit Rückwärtskante.

Insgesamt ist der Entscheidungswald sehr robust gegenüber der Permutation eines einzelnen Features. Der größte Fehler wird durch die Permutation des Minimums der Lichtintensität induziert. Das FFNN hingegen ist deutlich anfälliger gegenüber der Permutation eines einzelnen Features. Der größte Fehler ist 15,1 Prozentpunkte gegenüber 5,0 Prozentpunkten des Entscheidungswaldes.

Die wichtigsten Features für den Entscheidungswald sind das Minimum der Lichtintensität, die WLAN-Zugangspunkte, die Standardabweichung zu der Ausrichtung zum Magnetfeld, das Maximum der Lautstärke und der Durchschnitt der Drehbeschleunigung. Damit nutzt der Entscheidungswald mindestens ein Feature aus jeder Feature-Art. Je nach Sensorart sind einige Feature-Arten nicht so aussagekräftig, wie andere Feature-Arten.

Auffallend ist, dass dort wo der Durchschnitt nicht aussagekräftig ist, das Minimum oder das Maximum stattdessen Aussagekraft besitzt. Insbesondere trifft dies auf die Beschleunigung des Accelerometers, der Lichtintensität und der Lautstärke zu. Diese haben gemeinsam, dass der Großteil ihrer Sensorwerte sehr ähnlich sind, d. h. eine gleichbleibende Beschleunigung, Lichtintensität oder Lautstärke. Extrema weisen auf besondere Standorte hin, bei denen sich die Sensorwerte ruckartig ändern. Damit diese in der Permutationswichtigkeit relevant sind, müssen diese relativ häufig vorkommen.

7 EVALUATION

Unerwartet ist, dass das Minimum der Lichtintensität, im Gegensatz zum Maximum, eine hohe Aussagekraft besitzt, da die platzierten Lichtquellen die Lichtintensität nur erhöhen. Vermutlich wird das Minimum verwendet, um sich von den üblichen Lichtintensitäten zu unterscheiden, anstatt mit dem Maximum nach speziellen Standorten zu suchen.

Bei den Features zu der Ausrichtung zum Magnetfeld und der Beschleunigung wird zudem die Standardabweichung benutzt. Diese drückt signifikante Änderungen im Datenfenster aus. Besonders bei der Ausrichtung zum Magnetfeld ist eine Unterscheidung basierend auf Extrema nicht sinnvoll, da die Ausrichtung zum Magnetfeld abhängig von der Orientierung der Sensorbox ist, die sich im Laufe der Route ändern kann.

Besonders relevant sind zudem die Detektierung der WLAN-Zugangspunkte und alle Features basierend auf den Sensorwerten des Gyroskops. Die WLAN-Zugangspunkte sind binär. Eine Detektierung schließt bestimmte Standorte direkt aus, weswegen die Wichtigkeit nachvollziehbar ist. In der Simulation dreht sich die Sensorbox an vielen Ecken, weswegen die Sensorwerte für diese Standorte sehr Aussagekräftig sind. Eine durchschnittliche Drehbeschleunigung weißt auf diese Standorte konsistent hin.

Das FFNN weißt den gleichen Features ebenfalls eine hohe Wichtigkeit zu, nur ist der verursachte Fehler durch die Permutation bis zu drei-mal größer. Im Gegensatz zum Entscheidungswald, ist die Wichtigkeit der Standardabweichung und des Maximums der Lichtintensität größer und das Minimum dafür geringer. Dies ist nachvollziehbar, wenn man betrachtet, dass bei Standorten in der Umgebung von Lichtquellen die Lichtintensität kontinuierlich steigt. Zudem ist die Wichtigkeit der Features des Temperatursensors deutlich höher. Die Temperatur verhält sich ähnlich zur Lichtintensität. In der Nähe von Wärme- und Kältequellen verändert sich die Temperatur kontinuierlich, bis ein Maximum oder Minimum erreicht wird. Unerwartet ist die Wichtigkeit, die dem Maximum der Ausrichtung zum Magnetfeld zugewiesen wird. Wie zuvor diskutiert, ist dieses Feature fachlich nicht sinnvoll.

Abbildung 7.5 zeigt die Permutationswichtigkeit der ML-Modelle ohne Rückwärtsskante zur Standortbestimmung. Die Wichtigkeit der Features für den Entscheidungswald sind weitestgehend unverändert, wobei die verursachten Fehler durch die Permutation größer sind, im Vergleich zum Entscheidungswald mit Rückwärtsskante. Ähnlich verhält sich auch das FFNN im Vergleich zum FFNN mit Rückwärtsskante. Die Wichtigkeit der Standardabweichung, sowie der Wert der Temperatur ist geringer.

7.4 WICHTIGKEIT DER FEATURES

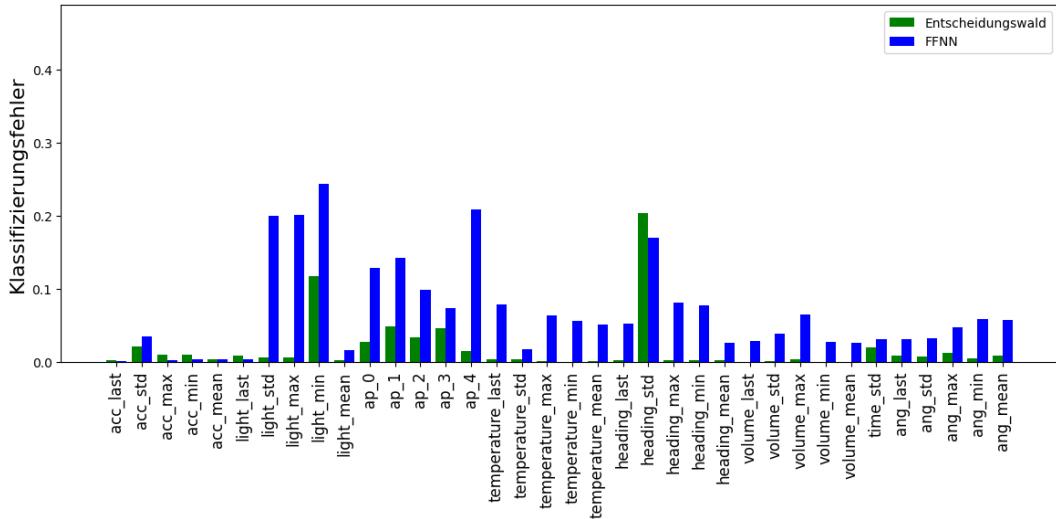


Abbildung 7.5: Permutationswichtigkeit der Features der ML-Modelle ohne Rückwärtsskante.

Abbildung 7.6 zeigt die Permutationswichtigkeit von einem Entscheidungswald zur Anomalieerkennung. Am wichtigsten sind die Features, welche die Wahrscheinlichkeitsverteilung des Klassifizierungsergebnisses vom ML-Modell zur Standortbestimmung ausnutzen. Die Abweichung zu den durchschnittlichen Standortänderungen hat kaum Einfluss. Dies deutet darauf hin, dass die ML-Modelle zur Standortbestimmung nicht so instabil in Anomalien sind. Aus demselben Grund hat das Feature der Topologieverletzung auch wenig Einfluss, da es bei Anomalien wenig ausschlägt. Dem FFNN wird für jedes Feature die gleiche Wichtigkeit zugewiesen (Abbildung B.15).

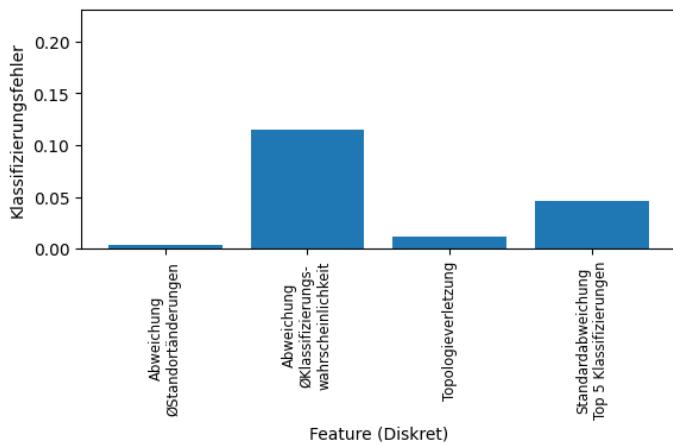


Abbildung 7.6: Permutationswichtigkeit der Features eines Entscheidungswaldes zur Anomalieerkennung.

7 EVALUATION

Die Wichtigkeit der Features variiert mit dem Szenario, indem die ML-Modelle eingesetzt werden, und unter den einzelnen ML-Modellen. Aus diesem Grund sollte die Analyse der Wichtigkeit der Features individuell für jedes Einsatzszenario und ML-Modell durchgeführt werden, womit durch eine sorgfältige Feature-Selektion die Klassifizierungsgenauigkeit maximiert und der Ressourcenverbrauch minimiert werden kann.

7.5 Fehlertoleranz

Bei der Fehlertoleranz wird die Fähigkeit der ML-Modelle untersucht, trotz fehlerhafter Sensordaten Standorte zu erkennen. Dafür wurden für jeden Sensor modifizierte Testmengen erstellt. Die erste Testmenge fügt ein Rauschen von 5% hinzu und die zweite Testmenge simuliert den Ausfall des Sensors, indem alle Sensorwerte genullt werden. Zudem wurde untersucht, was passiert wenn die Sensorbox nicht dem trainierten Pfad folgt, indem die Testmenge permutiert wurde. Damit Entscheidungswald und FFNN fair verglichen werden können, werden die besten ML-Modelle der Standortkomplexität 9 Orten verwendet.

Tabelle 7.2 zeigt die Differenz der Klassifizierungsgenauigkeiten $P(A)_{\text{cont}}$ und $P(A)$ von den modifizierten Testmengen zur originalen Testmenge. Die Testmengen mit einem Rauschen von 5% wurde ausgelassen, da es keine Auswirkung auf die Klassifizierungsgenauigkeit hatte. Vermutlich ist 5% Rauschen zu wenig, um einen Einfluss auszuüben.

Testmenge	Entscheidungswald	FFNN	Entscheidungswald	FNNN
	mit Rückwärtskante		ohne Rückwärtskante	
Licht	4.46%-Pkt.	4.65%-Pkt.	5.28%-Pkt.	6.93%-Pkt
Geräusch	3.20%-Pkt.	5.00%-Pkt.	1.63%-Pkt.	5.11%-Pkt.
Temperatur	15.15%-Pkt.	6.60%-Pkt.	8.10%-Pkt.	13.50%-Pkt.
Ausrichtung zum Magnetfeld	3.32%-Pkt.	19.94%-Pkt.	2.51%-Pkt.	2.78%-Pkt.
WLAN-Zugangspunkte	2.60%-Pkt.	22.65%-Pkt.	3.74%-Pkt.	14.13%-Pkt.
Accelerometer	1.41%-Pkt.	9.52%-Pkt.	0.62%-Pkt.	1.33%-Pkt.
Gyroskop	8.52%-Pkt.	4.58%-Pkt.	0.91%-Pkt.	3.30%-Pkt.
Permutierte Testmenge	2.27%-Pkt.	-0.13%-Pkt.	0.47%-Pkt.	0.93%-Pkt.
Durchschnitt	5,8%-Pkt.	9,1%-Pkt.	2,91%-Pkt.	6,00%-Pkt.

■ **Tabelle 7.2:** Fehler der modifizierten Testmengen zur originalen Testmenge.

Die ML-Modelle mit und ohne Rückwärtskante sind robust gegenüber der Nullung der Features und gegenüber der permutierten Testmenge. Aus der Menge stechen die Fehler durch die Nullung der Features des Temperatur- und Magnetfeldsensors sowie der WLAN-Zugangspunkte heraus. Außerdem ist der Fehler durch die Nullung der Features des Accelerometers und Gyroskops bei den ML-Modellen mit Rückwärtskanten deutlich größer als bei den ML-Modellen ohne Rückwärtskante.

Die Permutationswichtigkeit hat den Features des Temperatursensors eine geringere Wichtigkeit zugeordnet, als die Nullung es tut. Dies ist dadurch begründet, dass die Sensordaten des Temperatursensors mit wenigen Ausnahmen sehr homogen sind. Für den Temperatursensor wird eine Umgebungstemperatur simuliert, die sich nur verändert, wenn die Sensorbox einer Kälte- oder Wärmequelle näher kommt. Für den größten Teil der Daten misst der Temperatursensor die Umgebungstemperatur, weswegen eine permutation keinen großen Fehler verursacht. Die Nullung dieser Sensordaten hingegen deutet auf eine Kältequelle hin, die die Umgebungstemperatur verringert. Dieses Ereignis ist im Vergleich zu einer Erhöhung der Umgebungstemperatur selten, weswegen die Nullung einen großen Fehler verursacht. Würde dieses Ereignis häufiger vorkommen, wäre der Fehler vermutlich geringer.

Das FFNN mit Rückwärtskante hat im Vergleich zu den anderen ML-Modellen einen deutlich größeren Fehler, wenn die Features des Magnetfeldsensors genullt werden. Diese Anomalie ist entgegen den Erwartungen der Permutationswichtigkeit, insbesondere da die anderen ML-Modelle höhere Permutationswichtigkeiten für die Features des Magnetfeldsensors erzeugt haben. Es ist unklar, warum das FFNN, im Vergleich zu den anderen ML-Modellen, dem so anfällig gegenüber ist.

Die FFNNs erzeugen einen großen Fehler, wenn die WLAN-Zugangspunkte genullt werden. Dies stimmt mit den Ergebnissen der Permutationswichtigkeit überein. Insgesamt bilden die Features der WLAN-Zugangspunkte 14,7% aller Features, wobei die Werte bei der Eingabeschicht binär sind. Vermutlich ist aus diesem Grund der Einfluss dieser Features beim FFNN im Vergleich zu den Entscheidungswäldern so groß.

Die Permutation der Testmenge hat nur einen geringen Fehler verursacht. Dies war bei allen ML-Modellen zu erwarten, da das interne Datenfenster mit drei Einträgen sehr klein ist und die Features der vorherigen Standorte bereits nach wenigen Klassifizierungen korrigiert werden. Dementsprechend ist der Fehler bei den ML-Modellen ohne Rückwärtskante auch deutlich kleiner als bei den ML-Modellen mit Rückwärtskante.

7 EVALUATION

Im Durchschnitt sind die ML-Modelle ohne Rückwärtskante robuster als die ML-Modelle mit Rückwärtskante. Die Entscheidungswälder sind robuster als die FFNNs. Der beobachtete Fehler korreliert aber mit der Klassifizierungsgenauigkeit der ML-Modelle (Abbildung 7.1). Der Entscheidungswald mit Rückwärtskante, der marginal bessere Klassifizierungsgenauigkeiten erzielt hat, als das FFNN ohne Rückwärtskante, hat einen marginal geringeren Fehler im Test erzielt.

Tabellen C.4 und C.7 geben die Klassifizierungsgenauigkeit $P(C)_{\text{cont}}$ bzw. $P(C)$ an. Diese geben die Wahrscheinlichkeit an, dass ein Standort korrekt klassifiziert wird, wenn der Standort zuvor falsch klassifiziert wurde. Wie zu erwarten ist die Wahrscheinlichkeit bei den ML-Modellen ohne Rückwärtskante deutlich größer. Bei einer Standortkomplexität von 9 Orten benötigt ein Entscheidungswald mit Rückwärtskante ca. 5,3 Klassifizierungen, ein FFNN mit Rückwärtskante ca. 5,8 Klassifizierungen, ein Entscheidungswald ohne Rückwärtskante ca. 1,9 Klassifizierungen und ein FFNN ohne Rückwärtskante ca. 2,2 Klassifizierungen. Bei einer Standortkomplexität von 102 Orten werden 8,1-, 25-, 3,4- und 4,4 Klassifizierungen benötigt. Dies bestätigt, dass die ML-Modelle ohne Rückwärtskante deutlich robuster sind als die mit Rückwärtskante.

Von Entscheidungswäldern ist zu erwarten, dass sie mit steigender Waldgröße robuster werden, da sich die Feature-Mengen der einzelnen Entscheidungsbäume unterscheiden. Dies wird von den Klassifizierungsergebnissen teilweise gestützt, allerdings ist unklar, ob dies nicht nur mit der damit steigenden Klassifizierungsgenauigkeit zusammenhängt.

Im Vergleich zu Mian sind die ML-Modelle dieser Arbeit deutlich robuster. Der Ausfall des Lichtsensors bei Mians Ansätzen hat einen Fehler von 88,15 Prozentpunkten verursacht [Mia21], wohingegen der Fehler des schlechtesten ML-Modells in dieser Arbeit gegenüber dem Ausfall des Lichtsensors nur 6,93 Prozentpunkten ist.

In dieser Arbeit haben sich Entscheidungswälder als robuster gegenüber Fehler herausgestellt als FFNNs. Allerdings erzielen die Entscheidungswälder in dieser Arbeit auch insgesamt bessere Klassifizierungsergebnisse, weswegen dies zu erwarten ist. Der durchschnittliche Fehler beider ML-Modelle ist vergleichbar, bei vergleichbarer Klassifizierungsgenauigkeit. Zusätzlich hat sich die Untersuchung von modifizierten Testmengen mit gezielten Veränderungen als Ergänzung zur Permutationswichtigkeit bewiesen, um die Wichtigkeit von einzelnen Features einzuschätzen.

7.6 Benötigte Trainingsdaten

Mit wachsender Standortkomplexität werden mehr Trainingsdaten benötigt. Abbildung 7.7 zeigt die benötigten Trainingszyklen für Entscheidungswälder und FFNNs mit Rückwärtskante bis auf der Testmenge eine Klassifizierungsgenauigkeit $P(A)$ von 97% erreicht wurde. Es wurde 97% als Grenze gewählt, da 97,26% die höchste Klassifizierungsgenauigkeit des FFNNs bei einer Standortkomplexität von 102 ist. Die Trainingszyklen korrelieren mit der Anzahl der Trainingsdaten, da mit jedem Zyklus die Trainingsdaten ergänzt werden.

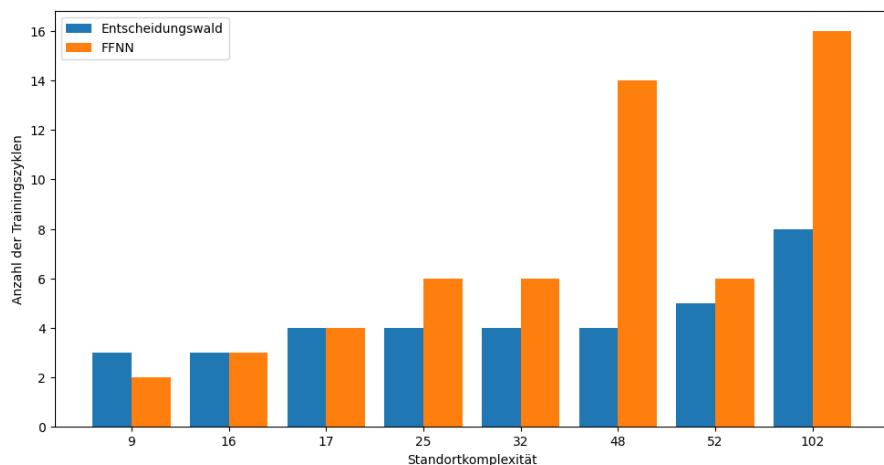


Abbildung 7.7: Anzahl der benötigten Trainingszyklen bis $P(A) = 97\%$ auf der Testmenge erreicht wurde.

Die Entscheidungswälder benötigen weniger Trainingszyklen als FFNNs, um den Schwellenwert zu erreichen. Je größer die Standortkomplexität, desto größer wird die Differenz der benötigten Trainingsdaten. Die ML-Modelle ohne Rückwärtskante wurden nicht in Zyklen trainiert, weswegen keine Aussage über die benötigten Trainingsdaten getroffen wird.

7.7 Programmspeicher

Der Großteil des Programmspeichers wird für das ML-Modell benötigt. Aus diesem Grund wird der Anteil des Programmspeichers in der Evaluation vernachlässigt, der für die restlichen Funktionen und für die Feature-Extrahierung benötigt wird. Zudem ist der benötigte Programmspeicher dieses Anteils konstant und skaliert nicht mit der Größe, wie die ML-Modelle.

7 EVALUATION

Zur Einschätzung des Programmspeichers der Entscheidungsbäume wird der hybride Ansatz mit einer Toleranz von $\epsilon = 0$ angenommen, d. h. es werden für eindeutige Ergebnisse diskrete Rückgaben zurückgegeben, anstatt der Wahrscheinlichkeitsverteilung. Als Datentyp für die Vergleiche und allen Features wird angenommen, dass ein vier Byte Datentyp verwendet wird. Für einen Vergleich werden fünf Instruktionen benötigt [Dym21]. Für eine Rückgabe werden zwischen zwei und $2(N + 1)$ Instruktionen und zwischen 0 und $2N$ Parameter benötigt, wobei N die Anzahl der möglichen Standorte ist. Die Größe einer Instruktion ist vier Byte, da eine 32-Bit CPU angenommen wird. Die Größe des Algorithmus des zusammenfassenden Klassifizierers wird vernachlässigt.

Für die FFNNs wird ebenfalls ein vier Byte Datentyp für die Biase und die Gewichte angenommen. Die Größe des Algorithmus zur Ausführung des FFNNs ist unbekannt und wird als konstanter Wert angenommen, liegt aber, den Zahlen in Giese's Arbeit nach zu urteilen, zwischen 6 KB und 7 KB [Gie20]. Diese Messungen beziehen sich aber auf einen 8-Bit Mikrocontroller, weshalb dieser Anteil für ein 32-Bit Mikrocontroller möglicherweise größer ist.

Tabelle 7.3 zeigt Einschätzungen des benötigten Programmspeichers der verschiedenen Konfigurationen der ML-Modelle, wobei die konstanten Anteile vernachlässigt werden. Potenzielle Optimierungen der Entscheidungswälder, z. B. durch den Compiler, sowie potenzielle Optimierungen des FFNNs, wie Giese in [Gie20] vorgeschlagen hat, wurden dabei nicht betrachtet. Giese hat mit dem CSC-MA-Bit Format die Programmgröße um 39% reduzieren können. Kompilierung mit der Optimierungsstufe *O2* konnte experimentell generierten C-Code eines Entscheidungswaldes um bis zu 21,3% reduzieren.

Der benötigte Programmspeicher beider ML-Modelle skaliert mit der Standortkomplexität, der Anzahl der verdeckten Schichten bzw. der Waldgröße und der Anzahl der Neuronen pro verdeckte Schicht bzw. der maximalen Baumhöhe. Für Entscheidungswälder werden maximal ca. 4,7 MB benötigt. Der beste Entscheidungswald bei einer Standortkomplexität von 102 benötigt aber nur ca. 1,1 MB. Die FFNNs hingegen benötigen deutlich weniger Programmspeicher. Für beide ML-Modelle gibt es Mikrocontroller, die ausreichend Programmspeicher anbieten. Im Vergleich zum WFFNN und WFBNN von Mian sind die FFNNs dieser Arbeit zwischen 54% und 97,6% kleiner bei ähnlicher Standortkomplexität. Die Entscheidungswälder können bis zu 47% kleiner sein, aber auch bis zu 720% größer sein.

7.8 RAM

Programmgröße in KB über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	72.2	71.2	119.8	157.5	132.8	184.3	237.9
16	16	158.2	114.5	264.9	465.0	297.0	573.7	724.7
16	32	158.8	132.5	277.8	472.2	293.4	625.9	771.2
16	64	158.8	132.5	277.8	472.2	293.4	625.9	771.2
8	32	72.2	68.4	135.4	242.1	144.4	317.2	415.2
32	32	325.9	250.7	550.8	951.2	576.1	1151.9	1676.2
64	32	669.2	522.8	1107.6	1906.5	1141.4	2440.0	3244.9
32	64	325.9	250.7	550.8	951.2	576.1	1151.9	1676.2
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	2.8	3.2	3.3	3.8	4.2	5.2	5.5
1	32	5.5	6.4	6.5	7.6	8.4	10.5	11.0
1	64	11.0	12.8	13.1	15.1	16.9	21.0	22.0
1	128	22.0	25.6	26.1	30.2	33.8	42.0	44.0
2	32	9.6	10.5	10.6	11.6	12.5	14.6	15.1
4	32	17.8	18.7	18.8	19.8	20.7	22.8	23.3
8	32	34.2	35.1	35.2	36.2	37.1	39.2	39.7
4	64	60.2	62.0	62.2	64.3	66.0	70.1	71.2

■ **Tabelle 7.3:** Programmgröße in KB über Standorte und Konfigurationen der ML-Modelle.

7.8 RAM

Für den benötigten RAM muss neben dem Anteil der ML-Modelle, die Historie der Sensorwerte und die berechneten Features betrachtet werden. Wichtig ist dabei der meiste RAM, der zu einem Zeitpunkt benötigt werden kann.

Für jeden Sensorwert, bis auf der Detektion von WLAN-Zugangspunkten, wird ein vier Byte Datentyp angenommen. Für die Detektion der Zugangspunkte wird ein ein Byte Datentyp angenommen. Insgesamt beträgt der benötigte RAM für einen Vektor von Sensorwerten damit 61 Byte.

7 EVALUATION

Dies setzt sich zusammen aus dem Zeitstempel, der xyz-Komponente vom Accelerometer und Gyroskop, dem Lichtsensor, dem Temperatursensor, dem Magnetfeldsensor, dem Geräuschsensor und fünf möglichen WLAN-Zugangspunkten. Bei einem Datenfenster von drei Einträgen wird damit 183 Byte für Sensorwerte benötigt.

Der Anteil der Features ist abhängig von den Features, die für ein bestimmtes Szenario eingesetzt werden. Insgesamt werden 38 Features verwendet, die vereinfacht alle als vier Byte Datentyp angenommen werden. Zur Evaluierung des ML-Modells wird nur die aktuelle Feature-Menge benötigt. Damit wird für die Feature-Menge insgesamt 152 Byte benötigt, wenn alle Features verwendet werden.

Zur Ausführung eines Entscheidungswaldes wird für die Rückgabe der Wahrscheinlichkeitsverteilung für jeden Standort vier Byte benötigt. Je nach Implementierung würde dieser Vektor mehrmals benötigt werden, z. B. bei der parallelen Evaluierung der Entscheidungsbäume skaliert dies mit der Anzahl der Prozessoren. In diesem Fall wird keine Nebenläufigkeit angenommen. In dieser Arbeit wurden zwischen 9 Standorte und 102 Standorte untersucht, d. h. es wurden zwischen 36 Byte und 408 Byte benötigt. Die Standortkomplexität ist jedoch abhängig vom Einsatzszenario. Die anschließende Evaluierung eines Entscheidungswaldes zur Anomalieerkennung kann vernachlässigt werden, da dieser ein diskretes Ergebnis zurückgeben kann und die benötigte Feature-Menge deutlich kleiner ist. Damit wird für N Standorte und K Features mit einem Entscheidungswald als ML-Modell zu einem Zeitpunkt ca. $183 + 4(N + K)$ Byte benötigt, d. h. bei 102 Standorten und 38 Features ca. 743 Byte.

Zur Ausführung eines FFNNs werden nur wenige Byte benötigt, um die nötigen Multiplikationen eines Neurons durchzuführen. Dies würde die Ausführungszeit, und den Energiebedarf, aber signifikant erhöhen, da die benötigten Gewichte ständig aus dem Programmspeicher geladen werden müssten. Das heißt, es müssen mindestens die Zwischenergebnisse einer Schicht im RAM gehalten werden, sowie ein Gewicht und ein Bias.

Damit benötigt ein FFNN, dessen größte Schicht M Neuronen hat, mindestens $4(M + 2)$ Byte. Maximal wird $4M$ Byte, zuzüglich der Größe aller Gewichte und Biase benötigt. Der maximale RAM, der zu einem Zeitpunkt, mit einem FFNN, benötigt wird, beträgt damit mindestens $183 + 4(M + K)$ Byte.

7.9 Ausführungszeit und benötigte Energie

Es ist problematisch eine sinnvolle Einschätzung für die benötigte Ausführungszeit und Energie anzugeben, da die Ausführungszeit und die benötigte Energie abhängig vom verwendeten Mikrocontroller ist. Vergleichbare 32-Bit Mikrocontroller mit FPU (Floating Point Unit), zu den Mikrocontrollern die Dymel verwendet hat [Dym21], sind aus der AVR C-Serie [Atm12]. Die Datenblätter enthalten keine Information über die Ausführungszeit von Gleitkommazahl-instruktionen und kein Energiemodell. Es ist aber anzunehmen, dass deutlich weniger Zyklen für hardwareunterstützte Gleitkommazahloperationen benötigt werden als Software basierte Alternativen. Aus diesem Grund wird die Ausführungszeit in Gleitkommazahl-Vergleichen, -Multiplikationen, -Division, -Additionen und Wurzeln angegeben, da diese die integralen Bestandteile der Feature-Extrahierung und Evaluation der ML-Modelle sind.

Die in dieser Arbeit vorgeschlagene Architektur (5.1) hat fünf Bestandteile, die jeweils zur Gesamtausführungszeit beitragen. Die Aufnahme der Sensorwerte wird als konstanter Energieverbrauch angenommen und in dieser Evaluation vernachlässigt. In der ersten Feature-Extrahierung werden 38 Features aus dem Datenfenster extrahiert. Tabelle 7.4 zeigt die geschätzte Anzahl der Operationen, die pro Art des Features benötigt wird.

Art des Features	Vergleich	Multiplikation	Division	Addition	Wurzel
Standardabweichung (7)	0	3	2	7	1
Minimum (6) / Maximum (6)	2	0	0	0	0
Durchschnitt (6)	0	0	1	2	0
Wert (13)	0	0	0	0	0

■ **Tabelle 7.4:** Geschätzte Anzahl der Operationen pro Art des Features bei einer Datenfenstergröße von 3. Fettgedruckte Zahl zeigt die Verwendungsanzahl in der Feature-Menge an.

Zur Evaluierung eines Entscheidungswaldes werden höchstens $\text{Waldgröße} \cdot \text{Max. Baumhöhe}$ Vergleiche benötigt, sowie $\text{Waldgröße} \cdot \# \text{Standorte}$ Additionen und $\# \text{Standorte}$ zusätzliche Vergleiche, um die einzelnen Entscheidungsbäume zusammenzufassen [Dym21]. Für einen Entscheidungswald mit 8 Bäumen mit einer maximalen Höhe von 16 und 102 Standorten werden damit 230 Vergleiche und 816 Additionen benötigt.

7 EVALUATION

Für die Evaluierung eines FFNNs mit der in Kapitel 5.3 beschriebenen Struktur setzen sich die benötigten Operationen folgendermaßen zusammen: Die Größe der ersten Schicht des FFNNs ist $n_1 := \#\text{Features}$. Die Größe der letzten Schicht ist $n_m := \#\text{Standorte}$. Dazwischen liegen $m - 2$ Schichten, die jeweils K Neuronen haben. Bei jeder Schicht i werden für jedes Neuron in n_{i+1} , n_i Multiplikationen und n_i Additionen, sowie ein Vergleich für die Aktivierungsfunktion ReLU verwendet. Für die SoftMax-Funktion in der letzten Schicht müssen n_m Divisionen durchgeführt werden, n_m Additionen, sowie n_m Mal die exp-Funktion ausgeführt werden. Insgesamt werden für die Ausführung eines FFNNs mit einer verdeckten Schicht mit 32 Neuronen, bei 102 Standorten, 4352 Multiplikationen, 4454 Additionen, 134 Vergleiche, 102 Divisionen und 102 exp-Funktionen benötigt.

Bei der Feature-Extrahierung für das ML-Modell zur Anomalieerkennung werden nur vier Features extrahiert. Tabelle 7.5 zeigt die geschätzte Anzahl der Operationen, die für die einzelnen Features benötigt werden. Der Entscheidungswald zur Anomalieerkennung besteht aus 4 Entscheidungsbäumen mit einer maximalen Baumhöhe von 8. Das FFNN zur Anomalieerkennung hat eine verdeckte Schicht mit 16 Neuronen und die Ausgabeschicht hat nur ein Neuron. Der Entscheidungswald benötigt damit 34 Vergleiche und 8 Additionen. Das FFNN benötigt 80 Multiplikationen, 81 Additionen, 17 Vergleiche, eine Division und eine exp-Funktion.

Feature	Vergleich	Multiplikation	Division	Addition	Wurzel
Abweichung zum ØStandortänderungen	4	0	2	5	0
Abweichung zum ØKlassifizierungswahrscheinlichkeit	4	0	2	5	0
Topologieverletzung	5	1	0	1	0
Standardabweichung Top 5 Klassifizierungen	0	5	2	13	1

■ **Tabelle 7.5:** Geschätzte Anzahl der Operationen pro Feature der Anomalieerkennung.

7.9 AUSFÜHRUNGSZEIT UND BENÖTIGTE ENERGIE

Tabelle 7.6 fasst die Anzahl der Operationen für eine Konfiguration mit ausschließlich Entscheidungswäldern und FFNNs zusammen. Es ist zu erwarten, dass die Entscheidungswälder weniger Ausführungszeit benötigen als die FFNNs, da deutlich weniger Operationen benötigt werden, wodurch sich ein Entscheidungsbaum basierter Klassifizierer in Hinsicht auf die benötigte Energie besser eignet. Bei konstanter Bewegung wurde in den Testszenarien der Mikrocontroller alle 166 ms aufgeweckt. Dies ist aber unrealistisch, da die Sensorbox auch für lange Zeit an einem Ort verbleiben kann, was sich positiv auf den Energiebedarf auswirkt.

Operation	Entscheidungswald	FFNN
Vergleich	289	176
Multiplikation	27	4459
Division	26	129
Addition	909	5444
Wurzel	8	8
exp-Funktion	0	103

■ **Tabelle 7.6:** Geschätzte Anzahl der Operationen für die gesamte Ausführung mit den im Beispiel genannten Größen für Entscheidungswald und FFNN.

7 EVALUATION

Diskussion

Ein Großteil dieser Arbeit ist die Generierung von Sensordaten. Dazu wurde der Ansatz von Mian aufgegriffen, wodurch verschiedene Routen in CoppeliaSim simuliert wurden. Der Nachteil dieses Ansatzes ist die schlechte Skalierbarkeit, wenn es um die Untersuchung von Pfaden und Standorten geht. Um weitere Pfade und Standorte zu untersuchen, mussten entweder komplexere Routen in CoppeliaSim erstellt werden, Routen synthetisch kombiniert werden oder Routen unabhängig von einander trainiert werden.

Der erste Ansatz ist sehr aufwändig und der zweite Ansatz unterscheidet sich nicht stark vom dritten Ansatz, da die Routen nur an einem Punkt kombiniert werden. Ein besserer Ansatz wäre es gewesen, wenn man lediglich abgeschlossene Teilstücke simuliert hätte, z. B. eine Kurve oder eine Gerade nach links laufend. Jedes dieser Teilstücke hätte eine feste Länge und könnte transformiert werden in sowohl der Länge, als auch den aufgenommenen Sensordaten. Durch geschickte Kombination, könnten dann beliebig komplexe Routen mit beliebig vielen Pfaden und Standorten generiert werden, was die Untersuchung erheblich erleichtert hätte. Zudem könnten genauere Aussagen über die Skalierung der Klassifizierungsgenauigkeit mit der Standortkomplexität getroffen werden können, da die Standortkomplexität systematisch erhöht werden könnte.

Die Entscheidungswälder könnten gezielter trainiert werden, um die Klassifizierungsgenauigkeit zu erhöhen und die Robustheit zu verbessern. Zuerst wird ein Entscheidungswald mit allen Features trainiert. Aus diesem Entscheidungswald wird die Wichtigkeit der einzelnen Features geschlossen. Auf Basis dessen werden gezielt Teilmengen aus der Feature-Menge extrahiert, womit orthogonale Entscheidungsbäume trainiert werden. Anschließend werden diese Entscheidungsbäume zu einem Entscheidungswald kombiniert.

8 DISKUSSION

Für das FFNN wurden für die vorherigen Standorte zwei Features verwendet, die alle Standorte zwischen 0 und 1 kodiert haben. Dies hat dazu geführt, dass FFNNs mit steigender Standortkomplexität schlechtere Klassifizierungsergebnisse erzielt haben als Entscheidungswälder. Besser hätten die vorherigen Standorte kategorisch kodiert werden sollen. Dadurch würde die Eingabeschicht des FFNNs zwar stark wachsen, aber das Problem möglicherweise eliminiert werden.

Um die Robustheit gegenüber ausgefallenen Sensoren zu erhöhen wurde synthetisch die Trainingsmenge mit Datensätzen ergänzt, die ausgefallen Sensoren simulieren. KNN bieten die Methode *DropConnect* an, welche die Gewichte einzelner Kanten zu einer bestimmten Wahrscheinlichkeit nullt. Ein FFNN mit DropConnect nach der Eingabeschicht hätte effizienter trainiert werden können unter gleichen Anforderungen zur Robustheit, da die synthetischen Trainingsdaten nicht benötigt werden würden.

Beim Training der ML-Modelle ist eine Aufwärmphase vorgesehen, damit die ML-Modelle eine Chance haben die nachfolgenden Partitionen der Trainingsmenge zu einer hohen Wahrscheinlichkeit zu bestimmen. Möglicherweise wurden in dieser Arbeit zu viele Aufwärmzyklen verwendet, wodurch eine hohe Abhängigkeit zum vorherigen Standort im Vergleich zu anderen Features beobachtet werden konnte.

Bei der Feature-Extrahierung wurde der Betrag von den Komponenten der Sensorwerte von dem Accelerometer und Gyroskop falsch berechnet. Anstatt den Betrag des Vektors zu berechnen, wurde der Betrag der Summe berechnet. Aus diesem Grund ist die Wichtigkeit der Features des Accelerometers und Gyroskops möglicherweise nicht so wichtig, wie es hätte sein können.

Schlussfolgerungen

Diese Arbeit hat gezeigt, dass sich Klassifizierer mit Entscheidungsbäumen besser als FFNNs zur Standortbestimmung eignen. Es können mit kleinen Entscheidungswäldern, Klassifizierungsgenauigkeiten von 98,62% bei einer geringen Standortkomplexität von 9 Orten und 87,35% bei einer hohen Standortkomplexität von 102 Orten erzielt werden. Anomalien von üblichen Wegen konnten nur bis zu 52,58% bei einer Fehlerrate von 2,95% korrekt klassifiziert werden.

Die untersuchten ML-Modelle sind klein genug, um diese auf Mikrocontrollern auszuführen. Es wurde gezeigt, dass ein Datenfenster von drei Einträgen ausreicht, um die Sensorwerte zu glätten und Features zu extrahieren. Entscheidungswälder benötigen zwar mehr Programm-speicher, dafür aber weniger RAM und deutlich weniger Operationen als FFNNs, wodurch ein geringerer Energiebedarf zu erwarten ist.

Der Kodierungsansatz, der nur Knoten kodiert, skaliert besser als der Kodierungsansatz, der Kanten und Knoten kodiert. Resultierende ML-Modelle haben damit bessere Klassifizierungsergebnisse erzielt. Entscheidungswälder skalieren mit steigender Standortkomplexität besser als FFNNs. Mit jedem zusätzlichen Standort nimmt die Klassifizierungsgenauigkeit für Entscheidungswälder um 0,1 Prozentpunkte ab, wohingegen sie für FFNNs um 0,24 Prozentpunkte abnimmt.

Die Wichtigkeit der Features ist vom Einsatzszenario abhängig. Zur Einschätzung der Wichtigkeit haben sich die Permutationswichtigkeit [Bre01] und ähnliche Modifizierungen der Testmengen erwiesen, die die Wichtigkeit durch den Klassifizierungsfehler im Vergleich zur originalen Testmenge bestimmen, z. B. die Nullung einzelner Features.

9 SCHLUSSFOLGERUNGEN

Die ML-Modelle wurden mit fehlerhaften Daten trainiert, um die Fehlertoleranz zu erhöhen. Es hat sich gezeigt, dass dadurch sowohl Entscheidungswälder als auch FFNNs robust gegenüber Abweichungen der Sensorwerte, Ausfall von einzelnen Sensoren und Permutation der Routen sind. Der durchschnittliche Fehler in diesen Szenarien beträgt 2,91 Prozentpunkte für Entscheidungswälder und 6 Prozentpunkte für FFNNs. Im Schnitt benötigt ein Entscheidungswald 1,9- bis 3,4 Klassifizierungen, um den korrekten Standort wieder zu bestimmen, nachdem es einen falschen Standort bestimmt hat. Ein FFNN benötigt im Schnitt 2,2- bis 4,4 Klassifizierungen.

Das Training mit einer Rückwärtskante, die erkannte Standorte für die nachfolgende Klassifizierung als Feature verfügbar macht, ist sehr aufwändig und rechenintensiv. Ohne die Rückwärtskante konnten bessere Klassifizierungsergebnisse erzielt werden als mit Rückwärtskante. Dabei ist das resultierende ML-Modell kleiner und unkomplizierter. FFNNs konnten ohne Rückwärtskante deutlich bessere Klassifizierungsergebnisse erzielen.

Zukünftige Arbeiten sollten die untersuchten Ansätze mit Echtdaten untersuchen und ein Modell zur Abschätzung des Energiebedarfs erstellen. Um die ML-Modelle mit Echtdaten zu untersuchen, muss ein Prototyp der Sensorbox konstruiert werden. Möglicherweise könnte ein Arduino Board mit handelsüblichen, vergleichbaren Sensoren, oder ein Smartphone ausreichen. In einem geeigneten Szenario müssen dann ausreichend Daten aufgenommen werden.

Das Energiemodell soll für verschiedene ML-Modelle, Batteriegrößen und Mikrocontroller erstellt werden. Mit den resultierenden oberen Schranken für die Größen verschiedener ML-Modelle, können dann gezielter ML-Ansätze untersucht werden.

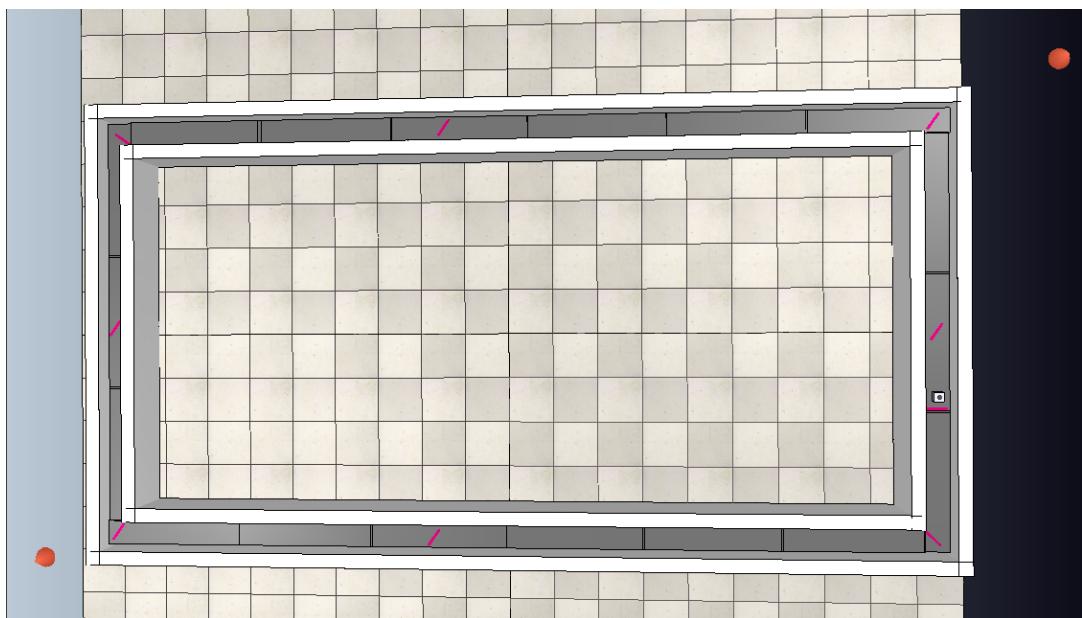
Inhalt des USB-Sticks

- PDF und Quelldateien für diese Arbeit (/thesis/thesis.pdf)
- PDF und Quelldateien für den Antritts- und Abschlussvortrag (/antrittsvortrag, /abschlussvortrag)
- Quelldateien für die Szenen zur Generierung der Sensordaten in CoppeliaSim (/scenes)
- ZIP mit den simulierten Sensordaten aus CoppeliaSim (/bin_data.zip)
- Ergebnisse der Evaluation von verschiedenen ML-Modellen in Rohform (/bin)
- Quelldateien zur Verarbeitung der Sensordaten und Generierung der Modelle (/sources)

Weitere Informationen können der Datei README.md entnommen werden.

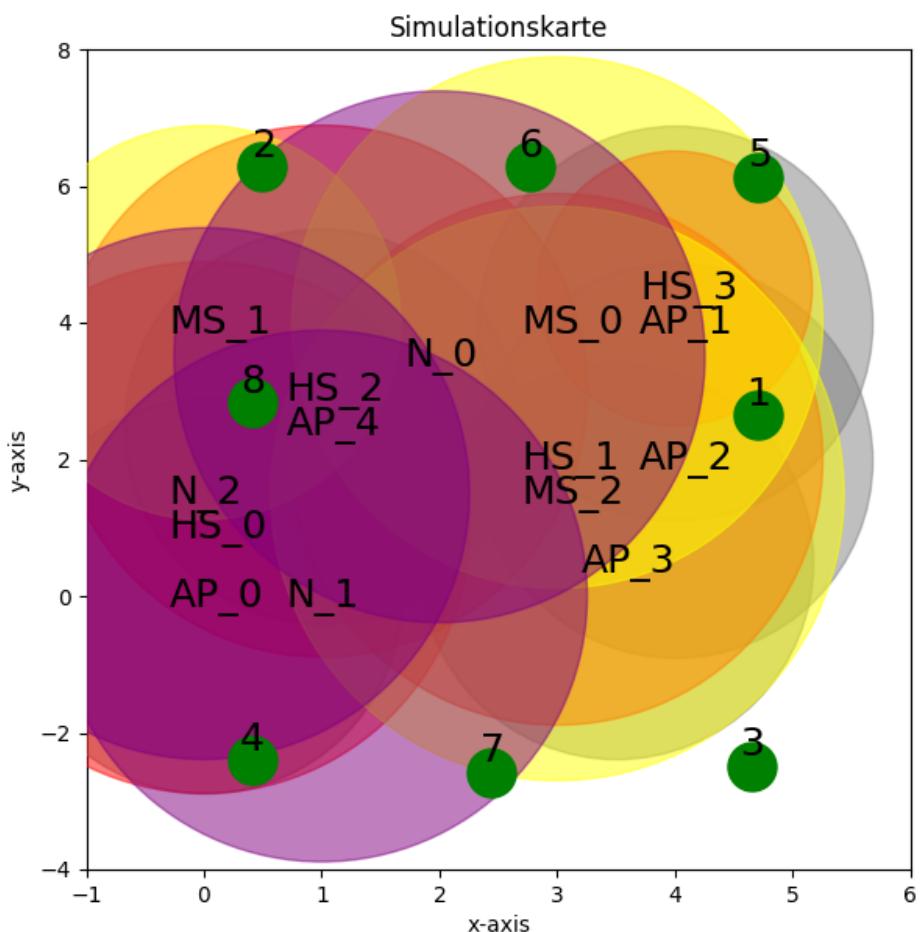
A INHALT DES USB-STICKS

Bildanhänge



■ Abbildung B.1: Modell der Route „long_rectangle“ in CoppeliaSim.

B BILDANHÄNGE



■ **Abbildung B.2:** Karte der Route „long_rectangle“ mit eingezeichneten Einflussbereichen der Objekte, die Einfluss auf modellierte Sensoren haben. **Magnetic Source** (Gelb), **Noise Source** (Lila), **Access Point** (Grau), **Heat Source** (Rot) und Standorte (Grün).

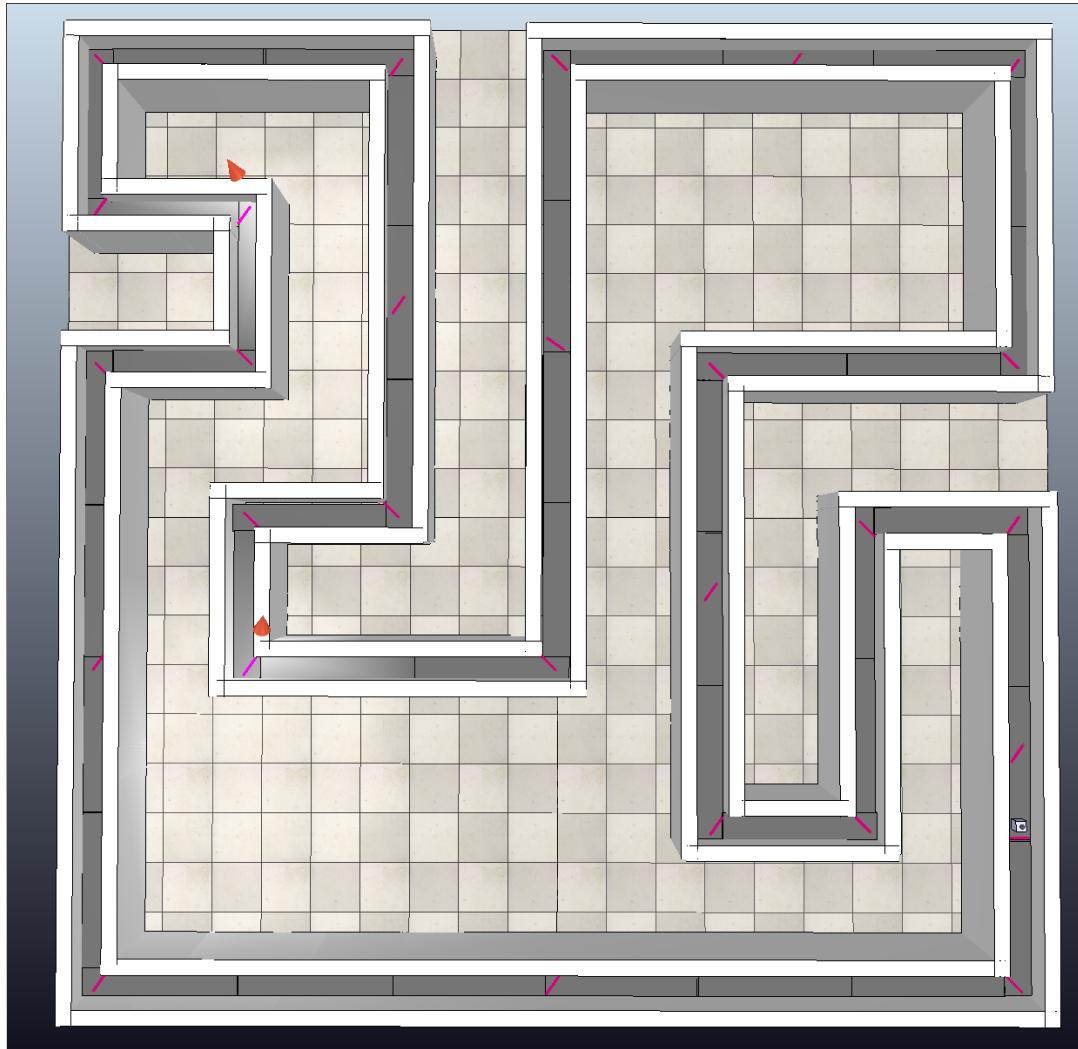


■ Abbildung B.3: Modell der Route „rectangle_with_ramp“ in CoppeliaSim.

B BILDANHÄNGE

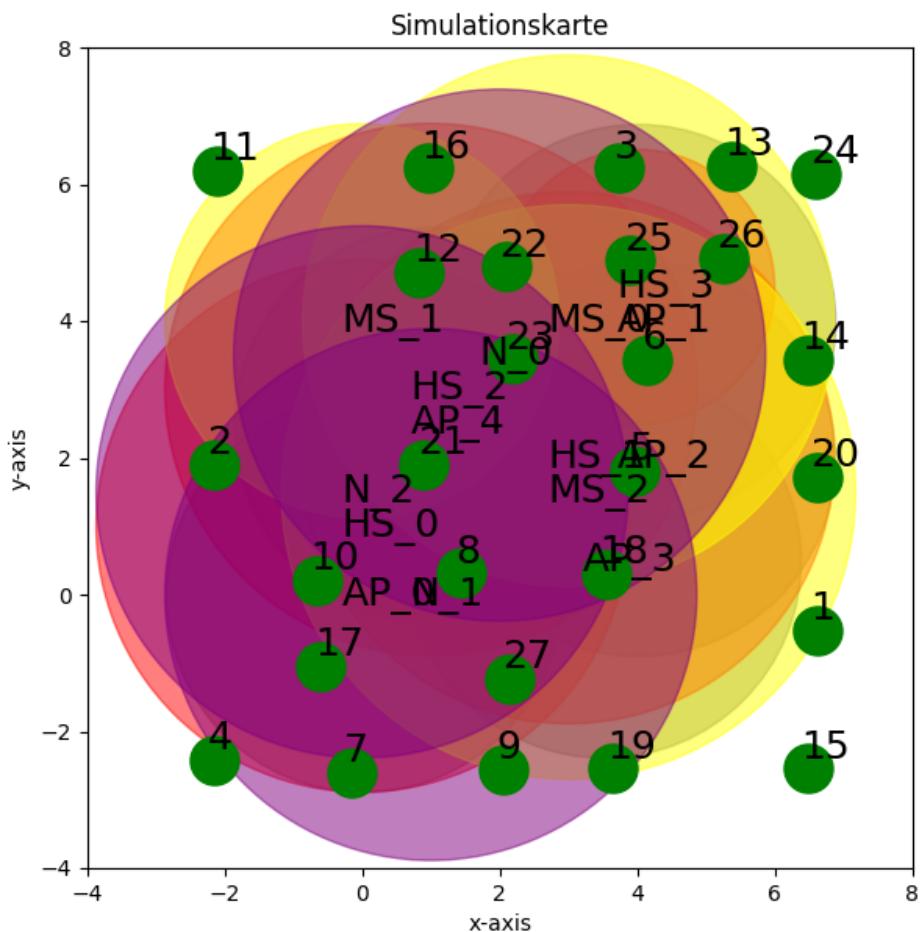


■ Abbildung B.4: Karte der Route „rectangle_with_ramp“ mit eingezeichneten Einflussbereichen der Objekte, die Einfluss auf modellierte Sensoren haben. *Magnetic Source* (Gelb), *Noise Source* (Lila), *Access Point* (Grau), *Heat Source* (Rot) und Standorte (Grün).

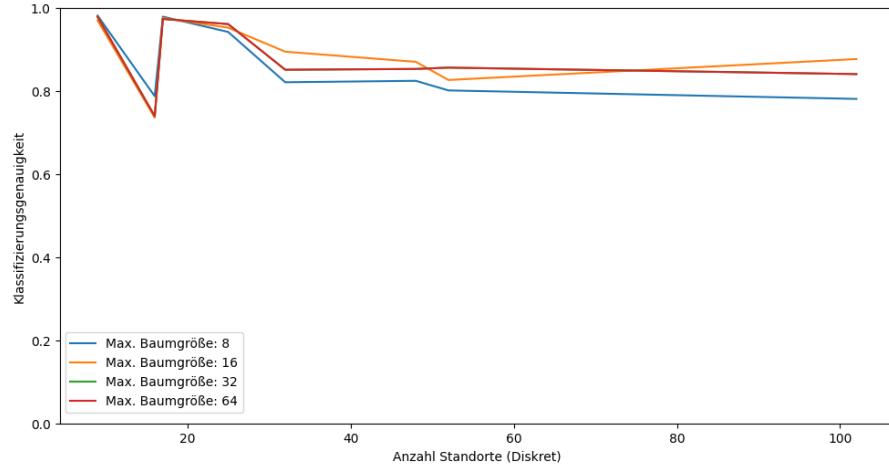


■ Abbildung B.5: Modell der Route „many_corners“ in CoppeliaSim.

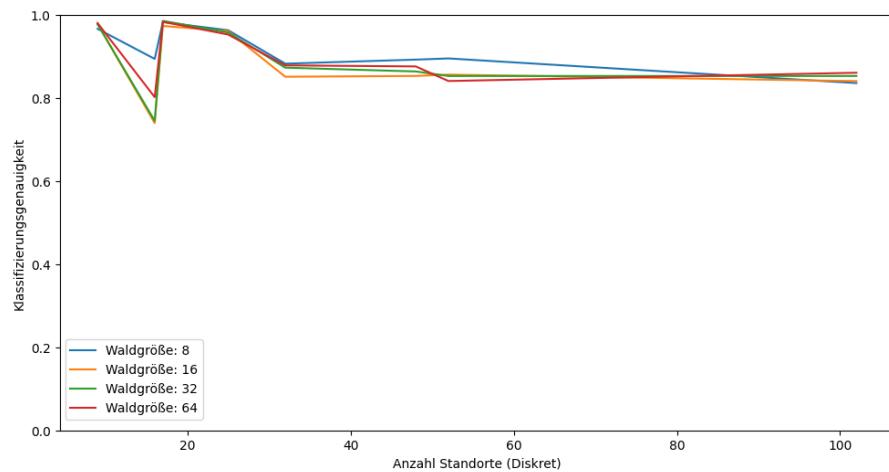
B BILDANHÄNGE



■ **Abbildung B.6:** Karte der Route „many_corners“ mit eingezeichneten Einflussbereichen der Objekte, die Einfluss auf modellierte Sensoren haben. **Magnetic Source** (Gelb), **Noise Source** (Lila), **Access Point** (Grau), **Heat Source** (Rot) und Standorte (Grün).



■ **Abbildung B.7:** Klassifizierungsgenauigkeiten $P(B \leq 5)_{\text{cont}}$ von Entscheidungswäldern mit einer Waldgröße von 16 über Standortkomplexitäten.



■ **Abbildung B.8:** Klassifizierungsgenauigkeiten $P(B \leq 5)_{\text{cont}}$ von Entscheidungswäldern mit einer maximalen Baumhöhe von 32 über Standortkomplexitäten.

B BILDANHÄNGE

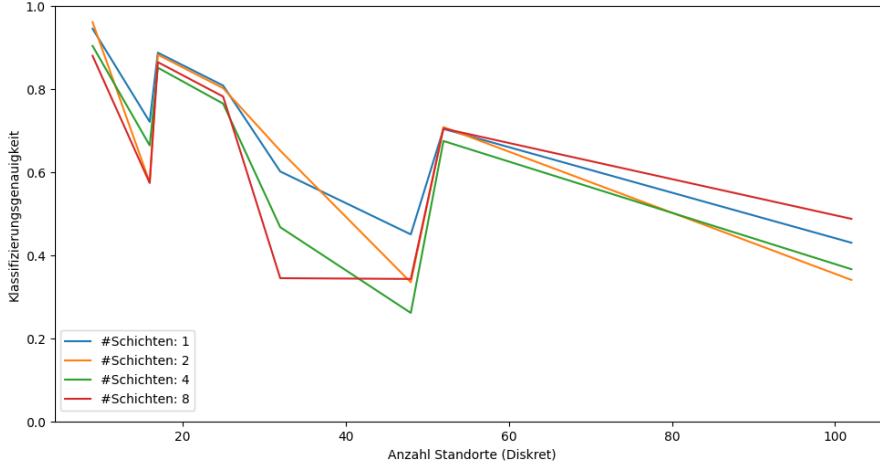


Abbildung B.9: Klassifizierungsgenauigkeiten $P(B \leq 5)_{\text{cont}}$ von FFNNs mit 32 Neuronen pro verdeckte Schicht über Standortkomplexitäten.

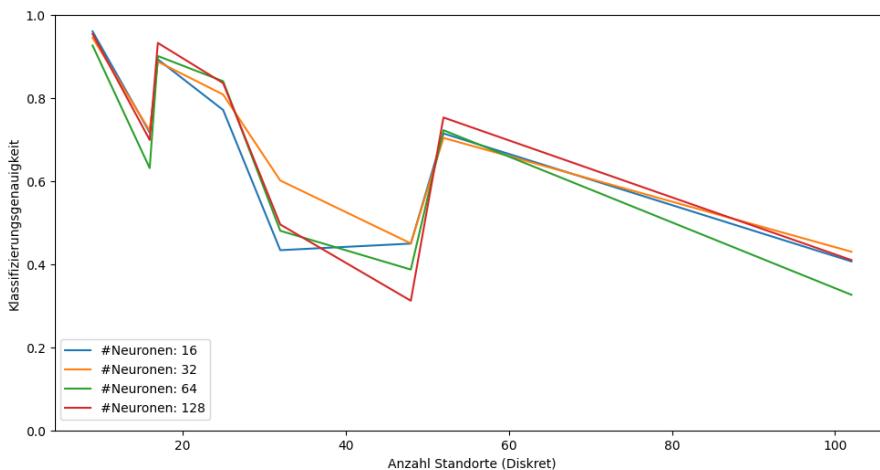
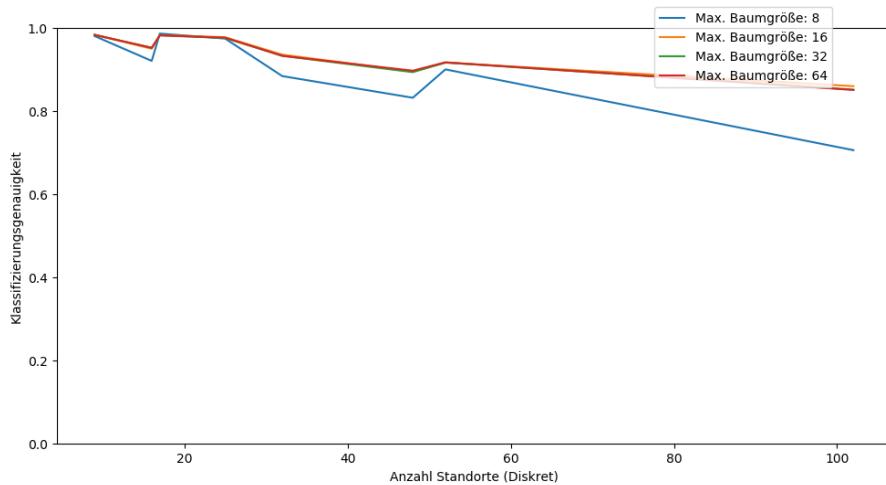
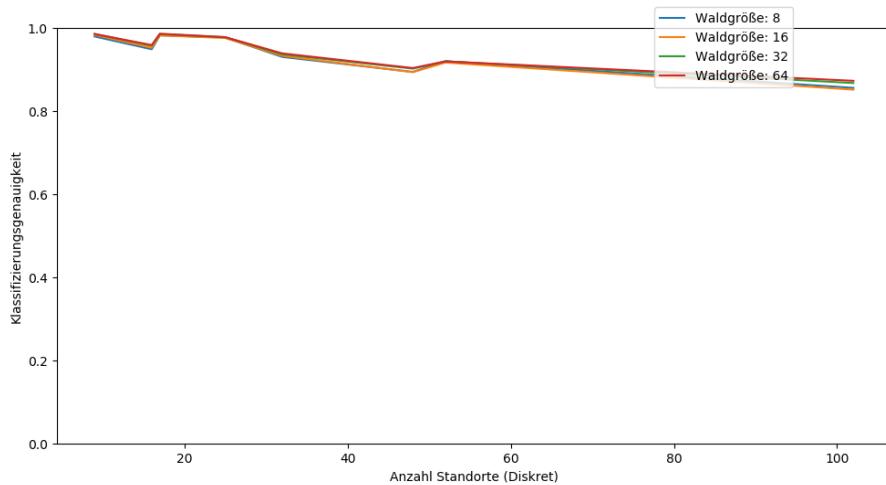


Abbildung B.10: Klassifizierungsgenauigkeiten $P(B \leq 5)_{\text{cont}}$ von FFNNs mit einer verdeckte Schicht über Standortkomplexitäten.



■ **Abbildung B.11:** Klassifizierungsgenauigkeiten $P(B \leq 5)$ von Entscheidungswäldern ohne Rückwärtskante mit einer Waldgröße von 16 über Standortkomplexitäten.



■ **Abbildung B.12:** Klassifizierungsgenauigkeiten $P(B \leq 5)$ von Entscheidungswäldern ohne Rückwärtskante mit einer maximalen Baumhöhe von 32 über Standortkomplexitäten.

B BILDANHÄNGE

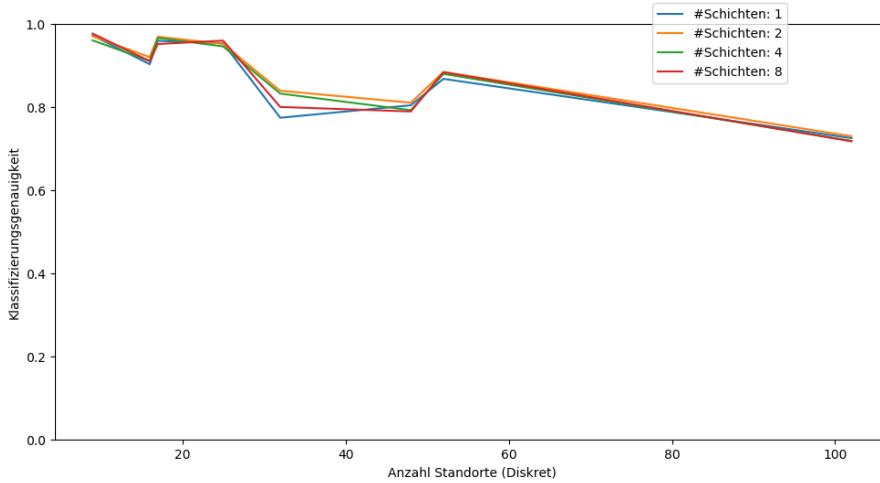


Abbildung B.13: Klassifizierungsgenauigkeiten $P(B \leq 5)$ von FFNNs ohne Rückwärtskanne mit 32 Neuronen pro verdeckte Schicht über Standortkomplexitäten.


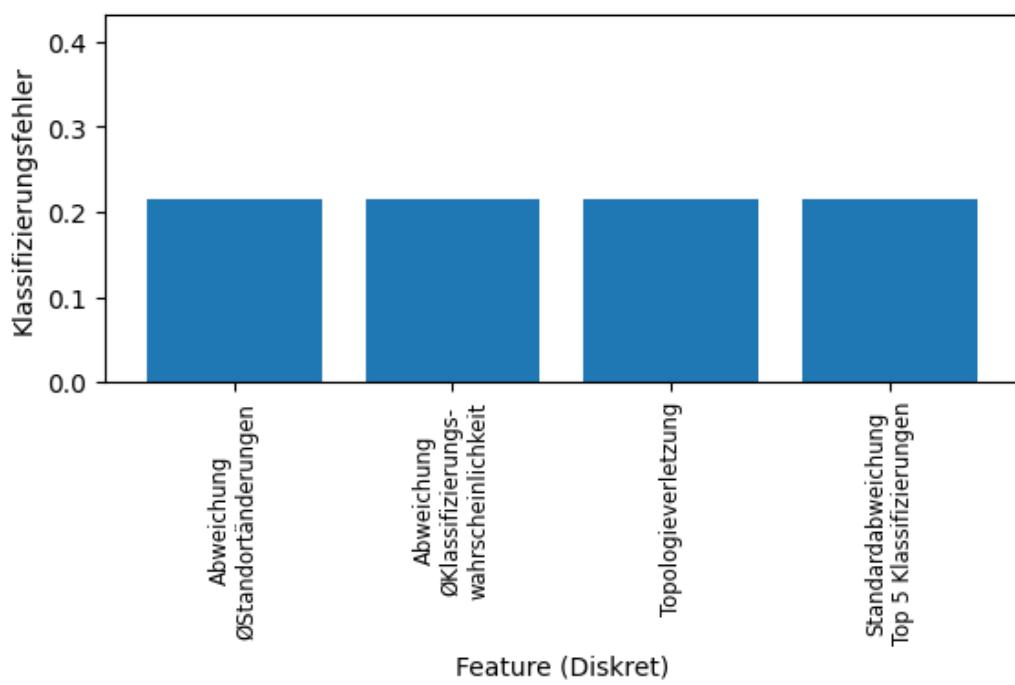


Abbildung B.14: Klassifizierungsgenauigkeiten $P(B \leq 5)$ von FFNNs ohne Rückwärtskanne mit einer verdeckte Schicht über Standortkomplexitäten.



■ Abbildung B.15: Permutationswichtigkeit eines FFNNs zur Anomalieerkennung.

B BILDANHÄNGE

Tabellenanhänge

C TABELLENANHÄNGE

$P(A)$ über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	98.86%	99.16%	98.47%	97.57%	96.47%	94.09%	95.73%
16	16	99.08%	99.81%	98.81%	98.77%	98.87%	99.10%	98.67%
16	32	99.13%	99.90%	98.92%	98.70%	98.74%	98.74%	98.68%
16	64	99.13%	99.90%	98.92%	98.70%	98.74%	98.74%	98.68%
8	32	98.97%	99.65%	98.75%	98.52%	98.62%	98.45%	98.50%
32	32	99.10%	99.85%	98.98%	98.77%	98.90%	99.06%	98.63%
64	32	99.12%	99.85%	98.86%	98.84%	98.73%	99.27%	98.66%
32	64	99.10%	99.85%	98.98%	98.77%	98.90%	99.06%	98.63%
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	98.63%	98.90%	98.47%	97.32%	96.94%	92.44%	97.60%
1	32	98.69%	99.75%	98.52%	97.79%	97.18%	96.61%	97.89%
1	64	98.98%	99.79%	98.60%	98.27%	98.38%	97.87%	98.19%
1	128	98.95%	99.67%	98.83%	98.62%	98.50%	98.23%	98.06%
2	32	98.63%	99.68%	98.45%	98.36%	98.43%	97.99%	98.00%
4	32	98.49%	99.75%	98.43%	98.78%	98.44%	95.87%	98.50%
8	32	98.89%	99.52%	98.55%	98.71%	98.24%	98.45%	97.34%
4	64	98.72%	99.87%	98.42%	97.99%	98.73%	98.55%	98.49%
97.26%								

■ **Tabelle C.1:** $P(A)$ über Standorte und Konfigurationen der ML-Modelle.

$P(A)_{\text{cont}}$ über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	92.59%	73.56%	92.55%	88.13%	79.88%	79.50%	70.87%
16	16	92.24%	68.49%	93.35%	91.06%	85.56%	83.47%	77.33%
16	32	93.25%	69.36%	93.16%	92.00%	81.69%	82.19%	80.42%
16	64	93.25%	69.36%	93.16%	92.00%	81.69%	82.19%	80.42%
8	32	90.85%	83.52%	94.10%	92.42%	83.76%	86.04%	84.97%
32	32	93.18%	68.85%	94.41%	91.56%	83.79%	82.96%	80.19%
64	32	93.76%	73.89%	94.15%	90.80%	83.75%	84.13%	79.04%
32	64	93.18%	68.85%	94.41%	91.56%	83.79%	82.96%	80.19%
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	88.30%	63.61%	81.55%	71.24%	39.00%	42.22%	64.83%
1	32	86.66%	63.94%	81.41%	75.11%	54.72%	41.84%	64.07%
1	64	86.83%	55.45%	83.92%	79.05%	43.84%	35.96%	66.37%
1	128	89.77%	61.82%	87.22%	78.17%	45.12%	29.59%	68.98%
2	32	88.55%	48.69%	82.13%	74.06%	59.44%	31.71%	65.12%
4	32	81.98%	58.53%	76.97%	70.02%	42.38%	25.04%	60.74%
8	32	79.08%	50.21%	78.61%	71.57%	31.70%	32.28%	63.93%
4	64	82.65%	54.46%	79.81%	74.91%	46.46%	21.03%	64.14%

■ **Tabelle C.2:** $P(A)_{\text{cont}}$ über Standorte und Konfigurationen der ML-Modelle.

C TABELLENANHÄNGE

$P(B \leq 5)_{\text{cont}}$ über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	98.24%	78.83%	97.98%	94.30%	82.18%	82.53%	80.22%
16	16	97.07%	73.68%	97.66%	95.32%	89.54%	87.10%	82.73%
16	32	97.91%	74.03%	97.42%	96.19%	85.19%	85.39%	85.70%
16	64	97.91%	74.03%	97.42%	96.19%	85.19%	85.39%	85.70%
8	32	96.73%	89.49%	98.35%	96.39%	88.34%	89.32%	89.60%
32	32	97.84%	74.58%	98.64%	95.85%	87.38%	86.47%	85.37%
64	32	98.11%	80.29%	98.42%	95.35%	87.93%	87.68%	84.17%
32	64	97.84%	74.58%	98.64%	95.85%	87.38%	86.47%	85.37%
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	96.11%	71.77%	89.37%	77.19%	43.45%	45.03%	71.55%
1	32	94.59%	72.18%	88.82%	80.91%	60.22%	45.08%	70.47%
1	64	92.71%	63.21%	90.18%	84.11%	48.12%	38.78%	72.33%
1	128	95.50%	69.99%	93.33%	83.66%	49.63%	31.27%	75.39%
2	32	96.17%	57.58%	88.34%	80.28%	65.24%	33.54%	70.91%
4	32	90.45%	66.50%	85.20%	76.55%	46.81%	26.17%	67.56%
8	32	88.06%	57.44%	86.54%	78.26%	34.54%	34.35%	70.57%
4	64	90.98%	62.21%	86.66%	81.08%	51.40%	22.54%	70.94%
45.54%								

■ **Tabelle C.3:** $P(B \leq 5)_{\text{cont}}$ über Standorte und Konfigurationen der ML-Modelle.

$P(C)_{\text{cont}}$ über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	16.21%	5.94%	19.29%	15.67%	12.34%	9.49%	6.12%
16	16	16.16%	5.04%	18.13%	14.66%	12.65%	10.30%	8.46%
16	32	17.01%	5.27%	19.71%	17.24%	13.66%	11.01%	9.49%
16	64	17.01%	5.27%	19.71%	17.24%	13.66%	11.01%	9.49%
8	32	14.86%	11.67%	19.75%	18.77%	13.29%	13.00%	12.62%
32	32	17.87%	5.04%	23.01%	16.63%	12.01%	10.14%	10.31%
64	32	18.96%	7.27%	20.02%	15.58%	14.35%	11.62%	10.31%
32	64	17.87%	5.04%	23.01%	16.63%	12.01%	10.14%	10.31%
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	16.87%	5.66%	9.86%	6.97%	4.73%	2.07%	6.24%
1	32	14.36%	6.50%	10.11%	9.62%	5.71%	2.61%	5.72%
1	64	13.45%	5.20%	12.92%	11.51%	3.57%	1.84%	7.55%
1	128	17.15%	5.82%	13.58%	10.51%	3.28%	1.34%	7.15%
2	32	15.93%	4.50%	9.79%	6.41%	5.37%	1.67%	8.75%
4	32	11.73%	5.76%	8.29%	6.38%	3.17%	1.27%	5.09%
8	32	6.88%	3.72%	8.08%	6.91%	2.67%	1.15%	5.86%
4	64	10.67%	5.11%	8.70%	7.38%	3.51%	0.81%	5.01%

■ **Tabelle C.4:** $P(C)_{\text{cont}}$ über Standorte und Konfigurationen der ML-Modelle.

C TABELLENANHÄNGE

$P(A)$ über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	93.73%	90.41%	94.46%	92.75%	86.79%	81.65%	84.48%
16	16	96.10%	93.45%	96.01%	94.98%	92.20%	88.22%	88.56%
16	32	96.37%	93.71%	96.25%	94.94%	92.01%	88.07%	88.90%
16	64	96.37%	93.71%	96.25%	95.05%	92.01%	88.46%	88.91%
8	32	95.74%	93.34%	96.01%	95.20%	91.60%	88.18%	89.27%
16	32	96.37%	93.71%	96.25%	94.94%	92.01%	88.07%	88.90%
32	32	96.42%	94.18%	96.48%	95.16%	92.18%	88.89%	89.05%
64	32	96.50%	94.29%	96.47%	95.12%	92.48%	89.05%	88.97%
32	64	96.42%	94.18%	96.49%	95.09%	92.18%	88.93%	89.12%
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	93.22%	84.16%	90.86%	90.77%	72.62%	74.87%	81.57%
1	32	93.06%	87.93%	91.53%	91.34%	75.69%	78.86%	82.61%
1	64	92.72%	88.50%	93.32%	91.78%	78.55%	79.05%	85.16%
1	128	93.53%	88.92%	93.46%	92.36%	81.81%	81.53%	84.87%
2	32	93.46%	88.81%	92.87%	91.55%	82.10%	79.53%	84.86%
4	32	92.21%	88.70%	92.65%	90.64%	81.34%	77.67%	84.39%
8	32	94.16%	88.48%	91.03%	91.93%	77.98%	77.17%	84.42%
4	64	93.01%	88.29%	93.35%	92.44%	82.54%	79.95%	84.82%

■ **Tabelle C.5:** $P(A)$ über Standorte und Konfigurationen der ML-Modelle ohne Rückwärtskante.

$P(B \leq 5)$ über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	98.12%	92.14%	98.71%	97.51%	88.48%	83.27%	90.09%
16	16	98.43%	95.07%	98.35%	97.83%	93.64%	89.57%	91.72%
16	32	98.41%	95.29%	98.29%	97.65%	93.36%	89.43%	91.74%
16	64	98.41%	95.29%	98.29%	97.74%	93.36%	89.78%	91.80%
8	32	98.02%	94.94%	98.28%	97.78%	93.10%	89.49%	92.07%
16	32	98.41%	95.29%	98.29%	97.65%	93.36%	89.43%	91.74%
32	32	98.62%	95.79%	98.61%	97.83%	93.70%	90.28%	92.03%
64	32	98.62%	95.96%	98.68%	97.87%	93.95%	90.42%	92.01%
32	64	98.54%	95.79%	98.62%	97.86%	93.70%	90.27%	92.08%
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	97.09%	86.56%	95.84%	95.43%	74.32%	76.80%	86.01%
1	32	97.29%	90.38%	96.01%	95.40%	77.49%	80.49%	86.85%
1	64	96.90%	91.30%	97.12%	95.49%	80.18%	80.73%	88.76%
1	128	97.07%	91.34%	97.24%	95.63%	83.44%	83.18%	88.24%
2	32	97.11%	92.08%	97.01%	95.26%	83.99%	81.11%	88.51%
4	32	96.12%	91.19%	96.69%	94.66%	83.31%	79.31%	88.04%
8	32	97.76%	91.12%	95.23%	96.05%	80.09%	79.00%	88.47%
4	64	96.50%	90.64%	97.09%	95.90%	84.51%	81.96%	88.29%

■ **Tabelle C.6:** Metrik $P(B \leq 5)$ über Standorte und verschiedenen Konfigurationen der ML-Modelle ohne Rückwärtskante.

C TABELLENANHÄNGE

$P(C)$ über Standorte	9	16	17	25	32	48	52	102
Entscheidungswälder								
Waldgröße	Max. Baumgröße							
16	8	28.93%	26.47%	32.61%	25.10%	24.45%	17.36%	18.72%
16	16	46.46%	38.90%	39.60%	33.97%	36.96%	28.34%	26.25%
16	32	53.33%	42.86%	45.03%	36.42%	37.64%	29.14%	28.01%
16	64	53.33%	42.86%	45.03%	38.82%	37.64%	30.54%	27.59%
8	32	50.10%	44.44%	47.14%	40.44%	38.75%	32.93%	30.78%
16	32	53.33%	42.86%	45.03%	36.42%	37.64%	29.14%	28.01%
32	32	48.92%	38.28%	40.92%	36.52%	35.57%	29.82%	27.02%
64	32	48.28%	41.20%	42.26%	34.78%	34.57%	28.87%	24.48%
32	64	52.29%	38.28%	40.91%	35.54%	35.57%	30.22%	27.63%
Feed Forward neuronale Netzwerke								
#Schichten	#Neuronen							
1	16	39.82%	30.53%	30.31%	28.22%	23.26%	18.95%	23.76%
1	32	37.23%	41.47%	34.54%	30.98%	24.40%	21.64%	25.47%
1	64	37.60%	37.85%	37.39%	30.65%	28.46%	21.58%	30.42%
1	128	40.13%	38.03%	37.61%	34.54%	28.01%	24.21%	28.94%
2	32	39.97%	36.06%	36.01%	32.62%	30.96%	22.44%	27.86%
4	32	40.35%	38.46%	40.72%	25.24%	27.53%	21.71%	29.50%
8	32	45.64%	40.32%	31.27%	28.24%	26.14%	21.35%	25.37%
4	64	44.32%	35.89%	37.49%	35.43%	32.75%	27.37%	31.01%

Tabelle C.7: Metrik $P(C)$ über Standorte und verschiedenen Konfigurationen der ML-Modelle ohne Rückwärtskante.

Literaturverzeichnis

- [ABC⁺16] ABADI, Martín ; BARHAM, Paul ; CHEN, Jianmin ; CHEN, Zhifeng ; DAVIS, Andy ; DEAN, Jeffrey ; DEVIN, Matthieu ; GHEMAWAT, Sanjay ; IRVING, Geoffrey ; ISARD, Michael ; KUDLUR, Manjunath ; LEVENBERG, Josh ; MONGA, Rajat ; MOORE, Sherry ; MURRAY, Derek G. ; STEINER, Benoit ; TUCKER, Paul ; VASUDEVAN, Vijay ; WARDEN, Pete ; WICKE, Martin ; YU, Yuan ; ZHENG, Xiaoqiang: TensorFlow: A System for Large-Scale Machine Learning. In: *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 16)*. Savannah, GA : USENIX Association, November 2016. – ISBN 978-1-931971-33-1, 265–283
- [ABLM14] AKESSON, Susanne ; BOSTRÖM, Jannika ; LIEDVOGEL, Miriam ; MUHEIM, Rachel: Animal Navigation. In: *Animal movement across scales* Vol. 21 (2014), 08, 151-178. <http://dx.doi.org/10.1093/acprof:oso/9780199677184.003.0009>. – DOI 10.1093/acprof:oso/9780199677184.003.0009. ISBN 9780199677191
- [ADIP21] APICELLA, Andrea ; DONNARUMMA, Francesco ; ISGRÒ, Francesco ; PREVETE, Roberto: A survey on modern trainable activation functions. In: *Neural Networks* (2021). <http://dx.doi.org/10.1016/j.neunet.2021.01.026>. – DOI 10.1016/j.neunet.2021.01.026. – Elsevier
- [Alc18] ALCAIDE, Eric: *E-swish: Adjusting Activations to Different Network Depths*. 2018
- [Atm12] ATMEL CORPORATION: *AT32UC3C datasheet*. <https://ww1.microchip.com/downloads/en/DeviceDoc/doc32117.pdf>. Version: 2012. – Atmel Corporation
- [BFSO84] BREIMAN, Leo ; FRIEDMAN, Jerome ; STONE, Charles J. ; OLSHEN, Richard A.: *Classification and regression trees*. CRC press, 1984. <http://dx.doi.org/10.1201/9781315139470> <http://dx.doi.org/10.1201/9781315139470>
- [BGC17] BENGIO, Yoshua ; GOODFELLOW, Ian ; COURVILLE, Aaron: *Deep learning*. Bd. Vol. 1. MIT press Massachusetts, USA, 2017
- [BHE00] BULUSU, Nirupama ; HEIDEMANN, John ; ESTRIN, Deborah: GPS-less low-cost outdoor localization for very small devices. In: *IEEE personal communications* Vol. 7 (2000), Nr. 5, 28–34. <http://dx.doi.org/10.1109/98.878533>. – DOI 10.1109/98.878533. – IEEE
- [Bre96] BREIMAN, Leo: Bagging predictors. In: *Machine learning* Vol. 24 (1996), Nr. 2, 123–140. <http://dx.doi.org/10.1007/bf00058655>. – DOI 10.1007/bf00058655. – Springer
- [Bre01] BREIMAN, Leo: Random forests. In: *Machine learning* Vol. 45 (2001), Nr. 1, 5–32. <http://dx.doi.org/10.1023/A:1010933404324>. – DOI 10.1023/A:1010933404324. – Springer

LITERATURVERZEICHNIS

- [CGSS14] CORRAL, Luis ; GEORGIEV, Anton B. ; SILLITTI, Alberto ; SUCCI, Giancarlo: Can execution time describe accurately the energy consumption of mobile apps? an experiment in android. In: *Proceedings of the 3rd International Workshop on Green and Sustainable Software*, 2014, 31–37
- [CPC⁺11] CUNHA, Joao ; PEDROSA, Eurico ; CRUZ, Cristóvao ; NEVES, António JR ; LAU, Nuno: Using a depth camera for indoor robot localization and navigation. In: *DETI/IEETA-University of Aveiro, Portugal* (2011), S. 6
- [CUH16] CLEVERT, Djork-Arné ; UNTERTHINER, Thomas ; HOCHREITER, Sepp: *Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)*. 2016
- [D⁺02] DIETTERICH, Thomas G. u. a.: Ensemble learning. In: *The handbook of brain theory and neural networks* Vol. 2 (2002), S. 110–125. – MIT press Cambridge, Massachusetts
- [DBB⁺01] DUGAS, Charles ; BENGIO, Yoshua ; BÉLISLE, François ; NADEAU, Claude ; GARCIA, René: Incorporating second-order functional knowledge for better option pricing. In: *Advances in neural information processing systems* Vol. 14 (2001), S. 472–478. – MIT
- [DHS11] DUCHI, John ; HAZAN, Elad ; SINGER, Yoram: Adaptive subgradient methods for online learning and stochastic optimization. In: *Journal of Machine Learning Research* Vol. 12 (2011), Juli, Nr. 7, S. 2121–2159. – ISSN 1532–4435. – Microtome Publishing
- [Dym21] DYMEL, Tom: *Handgestenerkennung mit Entscheidungsbäumen*. Februar 2021. – Forschungsprojekt und Seminar - Technische Universität Hamburg
- [Efr92] EFRON, Bradley: Bootstrap methods: another look at the jackknife. Version: 1992. http://dx.doi.org/10.1007/978-1-4612-4380-9_41. In: *Breakthroughs in statistics*. 1992. – DOI 10.1007/978-1-4612-4380-9_41, 569–593. – Springer
- [Eng18] ENGELHARDT, Sebastian: *Optische Gestenerkennung mit künstlichen neuronalen Netzen für kleine eingebettete Systeme*. Oktober 2018. – Bachelorarbeit, Technische Universität Hamburg
- [EUD18] ELFWING, Stefan ; UCHIBE, Eiji ; DOYA, Kenji: Sigmoid-weighted linear units for neural network function approximation in reinforcement learning. In: *Neural Networks* Vol. 107 (2018), 3–11. <http://dx.doi.org/10.1016/j.neunet.2017.12.012>. – DOI 10.1016/j.neunet.2017.12.012. – Elsevier
- [FS97] FREUND, Yoav ; SCHAPIRE, Robert E.: A decision-theoretic generalization of on-line learning and an application to boosting. In: *Journal of computer and system sciences* Vol. 55 (1997), Nr. 1, 119–139. <http://dx.doi.org/10.1006/jcss.1997.1504>. – DOI 10.1006/jcss.1997.1504. – Elsevier
- [GBB11] GLOROT, Xavier ; BORDES, Antoine ; BENGIO, Yoshua: Deep Sparse Rectifier Neural Networks. In: GORDON, Geoffrey (Hrsg.) ; DUNSON, David (Hrsg.) ; DUDÍK, Miroslav (Hrsg.): *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics* Bd. Vol. 15. Fort Lauderdale, FL, USA : PMLR, 11–13 Apr 2011 (Proceedings of Machine Learning Research), 315–323
- [GEW06] GEURTS, Pierre ; ERNST, Damien ; WEHENKEL, Louis: Extremely randomized trees. In: *Machine learning* Vol. 63 (2006), Nr. 1, 3–42. <http://dx.doi.org/10.1007/s10994-006-6226-1>. – DOI 10.1007/s10994-006-6226-1. – Springer
- [Gie20] GIESE, Anton: *Compression of Artificial Neural Networks for Hand Gesture Recognition*. Oktober 2020. – Bachelorarbeit, Technische Universität Hamburg

- [GL09] GHOSH, Joydeep ; LIU, Alexander: K-Means. In: *The top ten algorithms in data mining* Vol. 9 (2009), 21-22. <http://dx.doi.org/10.1201/9781420089653-9>. – DOI 10.1201/9781420089653-9. – CRC Press New York, NY
- [HH19] HIGHAM, Catherine F. ; HIGHAM, Desmond J.: Deep learning: An introduction for applied mathematicians. In: *SIAM Review* Vol. 61 (2019), Nr. 4, 860–891. <http://dx.doi.org/10.1137/18m1165748>. – DOI 10.1137/18m1165748. – SIAM
- [HSS12] HINTON, Geoffrey ; SRIVASTAVA, Nitish ; SWERSKY, Kevin: Neural networks for machine learning lecture 6a overview of mini-batch gradient descent. In: *Cited on* Vol. 14 (2012), Nr. 8
- [JCC⁺13] JURDAK, Raja ; CORKE, Peter ; COTILLON, Alban ; DHARMAN, Dhinesh ; CROSSMAN, Chris ; SALAGNAC, Guillaume: Energy-efficient localization: GPS duty cycling with radio ranging. In: *ACM Transactions on Sensor Networks (TOSN)* Vol. 9 (2013), Nr. 2, 1–33. <http://dx.doi.org/10.1145/2422966.2422980>. – DOI 10.1145/2422966.2422980. – ACM New York, NY, USA
- [Jia17] JIADONG, Yao: *Performance of Artificial Neural Networks on an AVR Microcontroller*. 2017. – Forschungsprojekt und Seminar, Technische Universität Hamburg
- [JLP06] JIN, Guang-yao ; LU, Xiao-yi ; PARK, Myong-Soo: An indoor localization mechanism using active RFID tag. In: *IEEE International Conference on Sensor Networks, Ubiquitous, and Trustworthy Computing (SUTC'06)* Bd. Vol. 1 IEEE, 2006, 4–pp
- [KB17] KINGMA, Diederik P. ; BA, Jimmy: *Adam: A Method for Stochastic Optimization*. 2017
- [KBP⁺19] KIM, Chelhwon ; BHATT, Chidansh ; PATEL, Mitesh ; KIMBER, Don ; TJAHIJADI, Yulius: InFo: indoor localization using fusion of visual information from static and dynamic cameras. In: *2019 International Conference on Indoor Positioning and Indoor Navigation (IPIN)* IEEE, 2019, 1–8
- [ker21] *Keras Dokumentation*. <https://keras.io/about/>. Version: 2021
- [KH05] KAPLAN, Elliott ; HEGARTY, Christopher: *Understanding GPS: principles and applications*. Artech house, 2005
- [KH10] KEMPER, Jürgen ; HAUSCHILD, Daniel: Passive infrared localization with a probability hypothesis density filter. In: *2010 7th Workshop on Positioning, Navigation and Communication* IEEE, 2010, 68–76
- [KMK15] KONDA, Kishore ; MEMISEVIC, Roland ; KRUEGER, David: *Zero-bias autoencoders and the benefits of co-adapting features*. 2015
- [KSA17] KRUKAR, Jakub ; SCHWERING, Angela ; ANACTA, Vanessa J.: Landmark-based navigation in cognitive systems. In: *KI - Künstliche Intelligenz* Vol. 31 (2017), März, Nr. 2, 121–124. <http://dx.doi.org/10.1007/s13218-017-0487-7>. – DOI 10.1007/s13218-017-0487-7. – Springer
- [Kub19] KUBIK, Philipp: *Zuverlässige Handgestenerkennung mit künstlichen neuronalen Netzen*. April 2019. – Bachelorarbeit, Technische Universität Hamburg
- [lea20a] LEARN scikit: *1.10.6. Tree algorithms: ID3, C4.5, C5.0 and CART*. <https://scikit-learn.org/stable/modules/tree.html#tree-algorithms>. Version: 2020
- [lea20b] LEARN scikit: *1.11. Ensemble methods*. <https://scikit-learn.org/stable/modules/ensemble.html#ensemble>. Version: 2020

LITERATURVERZEICHNIS

- [lea21] LEARN scikit: *Feature importances with a forest of trees*. https://scikit-learn.org/stable/auto_examples/ensemble/plot_forest_importances.html. Version: 2021
- [LF19] LYDIA, Agnes ; FRANCIS, Sagayaraj: Adagrad—An optimizer for stochastic gradient descent. In: *Int. J. Inf. Comput. Sci.* Vol. 6 (2019), Nr. 5
- [LM99] LEUPERS, R. ; MARWEDEL, P.: Function inlining under code size constraints for embedded processors. In: *1999 IEEE/ACM International Conference on Computer-Aided Design. Digest of Technical Papers (Cat. No.99CH37051)*, 1999, 253-256
- [LR76] LAURENT, Hyafil ; RIVEST, Ronald L.: Constructing optimal binary decision trees is NP-complete. In: *Information processing letters* Vol. 5 (1976), Nr. 1, 15–17. [http://dx.doi.org/10.1016/0020-0190\(76\)90095-8](http://dx.doi.org/10.1016/0020-0190(76)90095-8). – DOI 10.1016/0020-0190(76)90095-8
- [MGC⁺96] MENZEL, Randolph ; GEIGER, Karl ; CHITTKA, Lars ; JOERGES, Jasdan ; KUNZE, Jan ; MÜLLER, Uli: The knowledge base of bee navigation. In: *Journal of Experimental Biology* Vol. 199 (1996), Nr. 1, 141–146. <http://dx.doi.org/10.1242/jeb.199.1.141>. – DOI 10.1242/jeb.199.1.141. – The Company of Biologists Ltd
- [MHN13] MAAS, Andrew L. ; HANNUN, Awni Y. ; NG, Andrew Y.: Rectifier nonlinearities improve neural network acoustic models. In: *Proc. icml* Bd. Vol. 30 Citeseer, 2013, S. 3
- [Mia21] MIAN, Naveed A.: *Sensor based Location Awareness with Artificial Neural Networks*. 2021. – Master-Arbeit, Technische Universität Hamburg
- [MP43] MCCULLOCH, Warren S. ; PITTS, Walter: A logical calculus of the ideas immanent in nervous activity. In: *The bulletin of mathematical biophysics* Vol. 5 (1943), Nr. 4, 115–133. <http://dx.doi.org/10.1007/BF02478259>. – DOI 10.1007/BF02478259. – Springer
- [Nie15] NIELSEN, Michael A.: *Neural networks and deep learning*. Bd. Vol. 25. Determination press San Francisco, CA, 2015 <http://neuralnetworksanddeeplearning.com>
- [NIGM18] NWANKPA, Chigozie ; IJOMAH, Winifred ; GACHAGAN, Anthony ; MARSHALL, Stephen: *Activation Functions: Comparison of trends in Practice and Research for Deep Learning*. 2018
- [PE96] PARKINSON, Bradford W. ; ENGE, Per K.: Differential gps. In: *Global Positioning System: Theory and applications*. Vol. 2 (1996), 3–50. <http://dx.doi.org/10.2514/4.866395>. – DOI 10.2514/4.866395
- [PGP98] PEI, M ; GOODMAN, ED ; PUNCH, WF: Feature extraction using genetic algorithms. In: *Proceedings of the 1st International Symposium on Intelligent Data Engineering and Learning, IDEAL* Bd. Vol. 98, 1998, S. 371–384
- [PH19] POULOSE, Alwin ; HAN, Dong S.: Hybrid indoor localization using IMU sensors and smartphone camera. In: *Sensors* Vol. 19 (2019), Nr. 23, 5084. <http://dx.doi.org/10.3390/s19235084>. – DOI 10.3390/s19235084. – Multidisciplinary Digital Publishing Institute
- [PVG⁺11] PEDREGOSA, Fabian ; VAROQUAUX, Gaël ; GRAMFORT, Alexandre ; MICHEL, Vincent ; THIRION, Bertrand ; GRISEL, Olivier ; BLONDEL, Mathieu ; PRETTENHOFER, Peter ; WEISS, Ron ; DUBOURG, Vincent u. a.: Scikit-learn: Machine Learning in Python. In: *Journal of Machine Learning Research* Vol. 12 (2011), S. 2825–2830. – JMLR. org

- [PZYH08] PAN, Sinno J. ; ZHENG, Vincent W. ; YANG, Qiang ; HU, Derek H.: Transfer learning for wifi-based indoor localization. In: *Association for the advancement of artificial intelligence (AAAI) workshop* Bd. Vol. 6 The Association for the Advancement of Artificial Intelligence Palo Alto, 2008
- [Qui86] QUINLAN, J. R.: Induction of decision trees. In: *Machine learning* Vol. 1 (1986), Nr. 1, 81–106. <http://dx.doi.org/10.1007/BF00116251>. – DOI 10.1007/BF00116251. – Springer
- [Qui90] QUINLAN, J R.: Decision trees and decision-making. In: *IEEE Transactions on Systems, Man, and Cybernetics* Vol. 20 (1990), Nr. 2, 339–346. <http://dx.doi.org/10.1109/21.52545>. – DOI 10.1109/21.52545. – IEEE
- [Qui92] QUINLAN, JR.: *C4. 5: programs for machine learning*. Morgan Kaufmann, 1992. – ISBN 9780080500584
- [QWZ⁺18] QIAN, Kun ; WU, Chenshu ; ZHANG, Yi ; ZHANG, Guidong ; YANG, Zheng ; LIU, Yunhao: Widar2.0: Passive Human Tracking with a Single Wi-Fi Link. In: *Proceedings of the 16th Annual International Conference on Mobile Systems, Applications, and Services*. New York, NY, USA : Association for Computing Machinery, 2018 (MobiSys '18). – ISBN 9781450357203, 350–361
- [RLF18] ROTH, Mikko ; LUPOLD, Arno ; FALK, Heiko: Measuring and modeling energy consumption of embedded systems for optimizing compilers. In: *Proceedings of the 21st International Workshop on Software and Compilers for Embedded Systems*, 2018, 86–89
- [Ros60] ROSENBROCK, H. H.: An Automatic Method for Finding the Greatest or Least Value of a Function. In: *The Computer Journal* Vol. 3 (1960), 01, Nr. 3, 175-184. <http://dx.doi.org/10.1093/comjnl/3.3.175>. – DOI 10.1093/comjnl/3.3.175. – ISSN 0010-4620
- [Ros61] ROSENBLATT, Frank: Principles of neurodynamics. perceptrons and the theory of brain mechanisms / Cornell Aeronautical Lab Inc Buffalo NY. Version: 1961. <http://dx.doi.org/10.21236/ad0256582>. 1961. – Forschungsbericht
- [RSF13] ROHMER, Eric ; SINGH, Surya P. N. ; FREESE, Marc: V-REP: A versatile and scalable robot simulation framework. In: *2013 IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2013, 1321-1326
- [RZL17] RAMACHANDRAN, Prajit ; ZOPH, Barret ; LE, Quoc V.: *Searching for Activation Functions*. 2017
- [Ses91] SESSLER, GM: Acoustic sensors. In: *Sensors and Actuators A: Physical* Vol. 26 (1991), Nr. 1-3, 323–330. [http://dx.doi.org/10.1016/0924-4247\(91\)87011-Q](http://dx.doi.org/10.1016/0924-4247(91)87011-Q). – DOI 10.1016/0924-4247(91)87011-Q. – Elsevier
- [SLCY11] SEIDE, Frank ; LI, Gang ; CHEN, Xie ; YU, Dong: Feature engineering in Context-Dependent Deep Neural Networks for conversational speech transcription. In: *2011 IEEE Workshop on Automatic Speech Recognition Understanding*, 2011, 24-29
- [SS18] SADOWSKI, Sebastian ; SPACHOS, Petros: Rssi-based indoor localization with the internet of things. In: *IEEE Access* Vol. 6 (2018), 30149–30161. <http://dx.doi.org/10.1109/ACCESS.2018.2843325>. – DOI 10.1109/ACCESS.2018.2843325. – IEEE
- [Ste09] STEINBERG, Dan: CART: classification and regression trees. In: *The top ten algorithms in data mining* Vol. 9 (2009), 179-201. <http://dx.doi.org/10.1201/9781420089653-17>. – DOI 10.1201/9781420089653-17. – CRC Press New York, NY

LITERATURVERZEICHNIS

- [TDS⁺14] TIETE, Jelmer ; DOMÍNGUEZ, Federico ; SILVA, Bruno d. ; SEGERS, Laurent ; STEENHAUT, Kris ; TOUHAFI, Abdellah: SoundCompass: a distributed MEMS microphone array-based sensor for sound source localization. In: *Sensors* Vol. 14 (2014), Nr. 2, 1918–1949. <http://dx.doi.org/10.3390/s140201918>. – DOI 10.3390/s140201918. – Multidisciplinary Digital Publishing Institute
- [TH09] THOMPSON, Matthew J. ; HORSLEY, David A.: Resonant MEMS magnetometer with capacitive read-out. In: *SENSORS, 2009 IEEE*, 2009, 992-995
- [VKK⁺20] VENZKE, Marcus ; KLISCH, Daniel ; KUBIK, Philipp ; ALI, Asad ; MISSIER, Jesper D. ; TURAU, Volker: Artificial Neural Networks for Sensor Data Classification on Small Embedded Systems / arXiv.org e-Print Archive - Computing Research Repository (CoRR). Cornell University, Dezember 2020 (Report arXiv:2012.08403). – Forschungsbericht
- [WYM18] WANG, Xuyu ; YU, Zhitao ; MAO, Shiwen: DeepML: Deep LSTM for indoor localization with smartphone magnetic and light sensors. In: *2018 IEEE International Conference on Communications (ICC)* IEEE, 2018, 1–6
- [XZY16] XIAO, Jiang ; ZHOU, Zimu ; YI, Youwen ; NI, Lionel M.: A survey on wireless indoor localization from the device perspective. In: *ACM Computing Surveys (CSUR)* Vol. 49 (2016), Nr. 2, 1–31. <http://dx.doi.org/10.1145/2933232>. – DOI 10.1145/2933232. – ACM New York, NY, USA
- [YLL⁺15] YANG, Lei ; LIN, Qiongzheng ; LI, Xiangyang ; LIU, Tianci ; LIU, Yunhao: See Through Walls with COTS RFID System! In: *Proceedings of the 21st Annual International Conference on Mobile Computing and Networking*. New York, NY, USA : Association for Computing Machinery, 2015 (MobiCom '15). – ISBN 9781450336192, 487–499
- [ZGL19] ZAFARI, Faheem ; GKELIAS, Athanasios ; LEUNG, Kin K.: A survey of indoor localization systems and technologies. In: *IEEE Communications Surveys & Tutorials* Vol. 21 (2019), Nr. 3, 2568–2599. <http://dx.doi.org/10.1109/COMST.2019.2911558>. – DOI 10.1109/COMST.2019.2911558. – IEEE
- [ZLGZ16] ZHANG, Guojun ; LIU, Mengran ; GUO, Nan ; ZHANG, Wendong: Design of the MEMS piezoresistive electronic heart sound sensor. In: *Sensors* Vol. 16 (2016), Nr. 11, 1728. <http://dx.doi.org/10.3390/s16111728>. – DOI 10.3390/s16111728. – Multidisciplinary Digital Publishing Institute